

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE FACULTAD
Departamento de Departamento



**Caracterización de perfiles clínicos, demográficos y hospitalarios de
pacientes oncológicos en Chile mediante aprendizaje automático
supervisado explicable con datos GRD**

Branco Alberto García Santana

Profesor guía: Manuel Villalobos Cid

Profesor co-guía:

Tesis de grado presentada en
conformidad a los requisitos
para obtener el grado de Grado

Santiago – Chile

2026

© **Branco Alberto García Santana** , 2026



• Algunos derechos reservados. Esta obra está bajo una Licencia Creative Commons Atribución-Chile 3.0. Sus condiciones de uso pueden ser revisadas en:
<http://creativecommons.org/licenses/by/3.0/cl/>.

RESUMEN

Contrariamente a la creencia popular, Lorem Ipsum no es simplemente texto aleatorio. Tiene sus raíces en una pieza de la literatura clásica latina de 45 aC, por lo que es más de 2000 años de antigüedad. Richard McClintock, un profesor de latín en Hampden-Sydney College en Virginia, encontró una de las palabras latinas más oscuras, Consectetur, a partir de un pasaje de Lorem Ipsum, y pasando por la cita de la palabra en la literatura clásica, descubrió la fuente indudable. Lorem Ipsum viene de las secciones 1.10.32 y 1.10.33 de "De finibus" (Los Extremos del Bien y del Mal) por Cicerón, escrito en el año 45 aC. Este libro es un tratado sobre la teoría de la ética, muy popular durante el Renacimiento. La primera línea de Lorem Ipsum, "Lorem ipsum dolor sit amet ..", viene de una línea en la sección 1.10.32.

La porción estándar de Lorem Ipsum usado desde el año 1500. A continuación se reproduce para los interesados. Las secciones 1.10.32 y 1.10.33 de "De finibus" por Cicerón también se reproducen en su forma original exacta, acompañadas por versiones en Inglés de la traducción en 1914 por H. Rackham.

Palabras Claves: Palabras; Claves

ABSTRACT

Contrary to popular belief, Lorem Ipsum is not simply random text. It has roots in a piece of classical Latin literature from 45 BC, making it over 2000 years old. Richard McClintock, a Latin professor at Hampden-Sydney College in Virginia, looked up one of the more obscure Latin words, *consectetur*, from a Lorem Ipsum passage, and going through the cites of the word in classical literature, discovered the undoubtable source. Lorem Ipsum comes from sections 1.10.32 and 1.10.33 of "*de Finibus Bonorum et Malorum*" (The Extremes of Good and Evil) by Cicero, written in 45 BC. This book is a treatise on the theory of ethics, very popular during the Renaissance. The first line of Lorem Ipsum, "Lorem ipsum dolor sit amet..", comes from a line in section 1.10.32.

The standard chunk of Lorem Ipsum used since the 1500s is reproduced below for those interested. Sections 1.10.32 and 1.10.33 from "*de Finibus Bonorum et Malorum*" by Cicero are also reproduced in their exact original form, accompanied by English versions from the 1914 translation by H. Rackham.

Keywords: Key; words

Dedicado a...

AGRADECIMIENTOS

Agradezco a

TABLA DE CONTENIDO

1	Introducción	1
1.1	Antecedentes y motivación	1
1.1.1	Contexto	1
1.1.2	Motivación	2
1.1.3	Impacto esperado	3
1.2	Descripción del problema	4
1.2.1	Pregunta de investigación	5
1.3	Solución propuesta	8
1.3.1	Hipótesis de trabajo	9
1.3.2	Características de la solución	9
1.4	Objetivos y alcance del proyecto	11
1.4.1	Objetivo general	11
1.4.2	Objetivos específicos	11
1.4.3	Alcances	12
1.5	Metodología y herramientas utilizadas	14
1.5.1	Metodología	14
1.5.2	Herramientas de desarrollo	18
1.6	Organización del documento	19
2	Antecedentes	22
2.1	El cáncer como problema de salud pública y su impacto	22
2.1.1	Definición de cáncer	22
2.1.2	Impacto global del cáncer	22
2.1.3	Epidemiología e impacto socioeconómico del cáncer en Chile	23
2.1.4	Clasificación y caracterización de las neoplasias malignas	24
2.2	Sistema de Grupos Relacionados por el Diagnóstico (GRD)	27
2.2.1	Origen y evolución del modelo GRD en Chile	27
2.2.2	Estructura de datos y componentes del estándar IR-GRD	28
2.2.3	Relevancia de los procedimientos médicos y quirúrgicos en la gestión hospitalaria	29
2.3	Marco teórico metodológico y computacional	30
2.3.1	Remuestreo estadístico y robustez mediante Bootstrapping	30
2.3.2	Modelos de aprendizaje automático y algoritmos de ensamble	31
2.3.3	Inteligencia artificial explicable (XAI) y valores de Shapley (SHAP)	33
2.4	Estado del arte	35
2.4.1	Estrategia de búsqueda y selección de estudios	35
2.4.2	Estudios sobre caracterización de cohortes oncológicas mediante aprendizaje automático e inteligencia artificial explicable	37
2.4.3	Caracterización de cohortes oncológicas mediante análisis epidemiológico y estadística descriptiva	45
2.4.4	Enfoques de solución	50
2.4.5	Justificación del enfoque seleccionado	51
3	Marco Metodológico	52
3.1	Fase 1: Entendimiento del problema (<i>Business Understanding</i>)	52
3.2	Fase 2: Comprensión y preparación inicial de los datos	53
3.2.1	Adquisición e identificación de formatos	53
3.2.2	Limpieza básica y clasificación de la cohorte oncológica	54
3.2.3	Análisis de variables identificadoras	55
3.2.4	Análisis de distribución y cardinalidad de variables categóricas	55

3.2.5	Análisis de variables temporales	56
3.2.6	Limpieza y normalización de variables numéricas	57
3.2.7	Procesamiento de las variables objetivo (<i>Targets</i>)	57
3.2.8	Simulación de impacto y reducción de cardinalidad	58
3.2.9	Ingeniería de características (<i>Feature Engineering</i>)	59
3.2.10	Análisis de correlación y reducción de multicolinealidad	60
3.2.11	Codificación One-Hot y partición estratificada del conjunto de datos	60
3.3	Fase 4: Modelado algorítmico (<i>Modeling</i>)	61
3.3.1	Estrategia de balanceo basal	61
3.3.2	Selección y entrenamiento de algoritmos	62
3.3.3	Validación de estabilidad de variables mediante <i>Bootstrapping</i>	63
3.4	Fase 5: Evaluación de los modelos (<i>Evaluation</i>)	63
4	Resultados y análisis	66
4.1	Resultados de la exploración de datos (Fase 2)	66
4.1.1	Resultados del análisis de los archivos brutos de GRD	66
4.1.2	Distribución oncológica y control de la cohorte	67
4.2	Análisis de variables demográficas, clínicas y hospitalarias	70
4.2.1	Análisis de variables identificadoras	70
4.2.2	Análisis de variables temporales	73
4.2.3	Análisis de variables categóricas	75
4.2.3.1	Variables categóricas objetivo (targets)	76
4.2.3.2	Variables categóricas de entrada	78
4.2.4	Análisis de variables numéricas	88
4.2.4.1	Variable numérica objetivo (consumo de recursos)	88
4.2.4.2	Análisis de variables numéricas de entrada	93
4.3	Resultados del procesamiento de variables objetivo	94
4.4	Resultados del procesamiento de variables de entrada	96
4.5	Resultados de la generación de variables derivadas	104
4.5.1	Análisis de las variables derivadas categóricas	104
4.5.2	Comportamiento de las Variables Numéricas Derivadas	104
4.5.3	Depuración de Anomalías Temporales	106
5	Conclusiones	108
	Glosario	109
	Referencias bibliográficas	110
	Anexos	114
A	Título del anexo ejemplo	114
	Apéndices	115
A	Título del apéndice ejemplo	115

ÍNDICE DE TABLAS

Tabla 1.1	Variables a predecir y su definición operativa en los escenarios de riesgo. . . .	5
Tabla 1.2	Variables demográficas del sistema GRD.	6
Tabla 1.3	Variables clínicas, diagnósticas y neonatales.	6
Tabla 1.4	Variables hospitalarias y de gestión.	7
Tabla 1.5	Desglose de entregables por nivel.	10
Tabla 1.6	Espacio de búsqueda de hiperparámetros utilizado para la optimización mediante Grid Search.	13
Tabla 1.7	Librerías y dependencias del proyecto.	20
Tabla 2.1	Resumen de estudios sobre caracterización de cohortes oncológicas mediante aprendizaje automático e inteligencia artificial explicable.	46
Tabla 2.2	Resumen de estudios sobre caracterización de cohortes oncológicas mediante análisis epidemiológico y estadística descriptiva.	50
Tabla 4.1	Resultados de la auditoría técnica y estructural de los archivos brutos GRD (2019-2024).	66
Tabla 4.2	Distribución anual de episodios hospitalarios: Cohorte oncológica versus grupo de control (2019-2024).	68
Tabla 4.3	Cardinalidad de variables identificadoras en el registro hospitalario GRD (2019-2024).	72
Tabla 4.4	Casos críticos de reingreso hospitalario: Identificadores con máxima frecuencia anual de episodios (2019-2024).	72
Tabla 4.5	Concentración de episodios asistenciales en los 5 establecimientos de salud de mayor volumen (2019-2024).	72
Tabla 4.6	Auditoría de consistencia, formato y cobertura de variables temporales (2019-2024).	75
Tabla 4.7	Distribución anual de la condición al egreso (Tipo de Alta, sin procesar): Cohorte oncológica vs. grupo control (2019-2024).	77
Tabla 4.8	Distribución porcentual de los niveles de severidad: Cohorte oncológica vs. grupo control (2019-2024).	78
Tabla 4.9	Estadística descriptiva anual del Peso Relativo GRD: Población Total (2019-2024).	90
Tabla 4.10	Estadística descriptiva anual del Peso Relativo GRD: Cohorte Oncológica (2019-2024).	91
Tabla 4.11	Estadística descriptiva anual del Peso Relativo GRD: Grupo Control (2019-2024).	91
Tabla 4.12	Distribución de clases del Consumo de Recursos tras la discretización global (2019-2024).	92
Tabla 4.13	Distribución anual de los niveles de Consumo de Recursos (Terciles) por cohorte (2019-2024).	93
Tabla 4.14	Auditoría de completitud y estadísticos descriptivos globales de variables neonatales (2019-2024).	93
Tabla 4.15	Auditoría de pérdida de datos por depuración de variables objetivo (2019-2024).	94
Tabla 4.16	Frecuencias definitivas del target Mortalidad por cohorte (2019-2024).	94
Tabla 4.17	Frecuencias definitivas del target Severidad (Niveles 0 al 3) por cohorte (2019-2024).	95
Tabla 4.18	Frecuencias definitivas del target Consumo de Recursos (Terciles 0 al 2) por cohorte.	95
Tabla 4.19	Resumen de reducción de cardinalidad y depuración anual de nulos por variable categórica.	96

Tabla 4.20 Impacto de la exclusión de nulos en SEX0 sobre las variables objetivo.	100
Tabla 4.21 Impacto de la exclusión de nulos en ETNIA (ES_PUEBLO_ORIGINARIO).	101
Tabla 4.22 Impacto de la exclusión de nulos en PROVINCIA (REGION_RESIDENCIA).	101
Tabla 4.23 Impacto de la exclusión de nulos en NACIONALIDAD (ES_EXTRANJERO).	101
Tabla 4.24 Impacto de la exclusión de nulos en PREVISION (TIPO_PREVISION).	101
Tabla 4.25 Impacto de la exclusión de nulos en SERVICIO_SALUD (TIPO_SERVICIO_SALUD).	102
Tabla 4.26 Impacto de la exclusión de nulos en TIPO_PROCEDENCIA.	102
Tabla 4.27 Impacto de la exclusión de nulos en TIPO_INGRESO.	102
Tabla 4.28 Impacto de la exclusión de nulos en ESPECIALIDAD_MEDICA.	102
Tabla 4.29 Impacto de la exclusión de nulos en TIPO_ACTIVIDAD.	103
Tabla 4.30 Impacto de la exclusión de nulos en SERVICIOINGRESO.	103
Tabla 4.31 Impacto de la exclusión de nulos en PROCEDIMIENTO01 (TIPO_PROCEDIMIENTO).	103
Tabla 4.32 Proporción anual de episodios médicos versus quirúrgicos (2019-2024).	104
Tabla 4.33 Distribución anual exhaustiva de la variable derivada Comorbilidad Principal (2019-2024).	105
Tabla 4.34 Estadística descriptiva de las variables numéricas derivadas (resumen 2019 vs 2024).	106
Tabla 4.35 Auditoría de eliminación de episodios con anomalías cronológicas (Edades y Estadías negativas).	107

ÍNDICE DE ILUSTRACIONES

Figura 1.1	Pipeline de trabajo propuesto (CRISP-DM) para el análisis.	16
Figura 4.1	Proporción total de pacientes y desglose de diagnósticos oncológicos (2019-2024). Fuente: Elaboración propia, 2026.	68
Figura 4.2	Distribución de episodios según categoría CIE-10 frente al grupo de control. Fuente: Elaboración propia, 2026.	69
Figura 4.3	Distribución y valores atípicos del Peso Relativo GRD por cohorte de estudio.	91

ÍNDICE DE ALGORITMOS

CAPÍTULO 1. INTRODUCCIÓN

1.1 ANTECEDENTES Y MOTIVACIÓN

1.1.1 Contexto

En el escenario sanitario chileno, el **cáncer** se ha consolidado como una de las principales prioridades epidemiológicas y de salud pública (OECD (2024); Pardo (2025)). De acuerdo con estimaciones de la Organización para la Cooperación y el Desarrollo Económicos (OCDE), se proyecta que, entre 2023 y 2050, el cáncer provocará alrededor de 9.900 muertes prematuras anuales (antes de los 75 años) en el país, lo que implica que una de cada seis muertes prematuras será directamente atribuible a esta enfermedad (OECD (2024)).

Esta realidad impone una presión económica y asistencial creciente sobre el sistema sanitario, exigiendo optimizar la planificación estratégica de los recursos sanitarios mediante información unificada y estandarizada que supere la fragmentación de fichas clínicas locales, con el fin de asegurar la trazabilidad y comparabilidad de la información en toda la red de salud pública, incluyendo el seguimiento de la trayectoria de cada paciente (DEIS (2023)).

En este contexto, Chile adoptó el sistema internacional de **Grupos Relacionados por el Diagnóstico (GRD)**, un modelo de clasificación que agrupa los egresos hospitalarios de establecimientos públicos dependientes del Fondo Nacional de Salud (FONASA) en categorías clínicamente coherentes y con un consumo homogéneo de recursos, bajo el estándar clínico y económico internacional IR-GRD (International Refined). En este sistema, a cada patología o enfermedad se le asigna un código único conocido como CIE-10 (Clasificación Internacional de Enfermedades, décima revisión) (Metamodelo (2024b)). De este modo, se trasciende la variabilidad existente en los registros médicos locales, instaurándose un lenguaje común de evaluación y clasificación de diagnósticos (Sigesa (2019a)).

A nivel de gestión estatal, la implementación del sistema GRD ha evolucionado significativamente en los últimos años (Cid et al. (2024); Clapes UC (2023)). Tras diversos programas piloto en el sector público, en 2020 FONASA instauró formalmente el GRD como mecanismo oficial de pago para los hospitales públicos. Posteriormente, en 2023, el programa fue reformado y ampliado para abarcar 68 hospitales de alta complejidad en todo el país, reconociéndose oficialmente un aumento en la severidad y complejidad de los pacientes atendidos tras la pandemia (Cid et al. (2024)).

Cabe destacar que el sistema GRD genera un volumen masivo de datos estructurados, ya que integra de manera centralizada diversas variables demográficas (como edad,

nacionalidad, etnia y provincia), clínicas (como diagnósticos principales y secundarios codificados en CIE-10) y hospitalarias (como el tipo de procedencia y los procedimientos realizados) correspondientes a egresos hospitalarios públicos (Metamodelo (2024b)).

1.1.2 Motivación

A pesar de que el sistema GRD constituye un registro de información centralizada, su uso actual se limita principalmente a la gestión financiera, la evaluación de la eficiencia hospitalaria y la asignación presupuestaria de FONASA (Clapes UC (2023); Cid et al. (2024)). Esta práctica predominantemente contable ignora la exploración del valor clínico y predictivo latente en los datos, impidiendo la generación de conocimiento epidemiológico y operativo basado en evidencia oncológica masiva. En particular, se desaprovecha el potencial de los registros GRD como una base de datos masiva y fundamental para modelar perfiles de riesgo oncológicos mediante técnicas avanzadas de aprendizaje automático.

En ese mismo sentido, diversos estudios internacionales han demostrado que registros clínicos y administrativos análogos a los GRD, como los *Registros de Salud Electrónicos (EHR)*, contienen patrones complejos que permiten anticipar distintos desenlaces críticos en pacientes con cáncer, tales como mortalidad hospitalaria (Luo et al. (2025)), supervivencia del paciente (Zhou et al. (2024)) y tiempos de hospitalización (Hwang et al. (2023); Alsinglawi et al. (2022)), mediante modelos predictivos basados en aprendizaje automático e inteligencia artificial, los cuales han permitido generar diversos perfiles de riesgo oncológicos (Luo et al. (2025)). En donde los EHR presentan similitudes con los GRD, ya que poseen un alto volumen de variables demográficas, diagnósticos codificados y desenlaces hospitalarios en formato estructurado (Luo et al. (2025)).

Sin embargo, en Chile la investigación oncológica tradicional se ha restringido principalmente a estudios epidemiológicos descriptivos o a análisis de episodios locales en centros específicos. Estas investigaciones suelen adoptar enfoques estadísticos clásicos que asumen relaciones lineales y simplificadas (Orrego et al. (2025); Ortega-Ceavichay et al. (2023)), omitiendo la captura de relaciones multidimensionales y no lineales entre las variables que caracterizan la trayectoria de un paciente con neoplasias malignas dentro de la red hospitalaria.

Por ende, la motivación de esta tesis consiste en explorar si el uso de los registros GRD puede extenderse desde un ámbito administrativo hacia la caracterización de perfiles de riesgo oncológicos que complementen la gestión clínica existente, mediante algoritmos de aprendizaje automático supervisado capaces de identificar patrones no lineales que los métodos estadísticos tradicionales tienden a simplificar (Hastie et al. (2009); Li et al. (2020)). Esto, con el

fin de dotar al sistema público de conocimiento de caracterización a nivel de episodio clínico.

No obstante, el despliegue de estos modelos en la toma de decisiones estratégicas requiere mecanismos de confianza y explicación que trasciendan el uso de modelos convencionales de aprendizaje automático que operan como cajas negras, sin justificar sus predicciones. Por lo tanto, se propone integrar metodologías de Inteligencia Artificial Explicable (XAI), específicamente mediante el uso de valores de Shapley (SHAP), para cuantificar la contribución marginal de diversos factores demográficos, clínicos y hospitalarios en los desenlaces de interés de los episodios clínicos (Lundberg & Lee (2017)). Esto permitirá transformar las variables de los episodios en herramientas analíticas transparentes que evidencien el impacto de dichas variables en los distintos escenarios de riesgo.

Cabe destacar que se busca trascender el análisis descriptivo tradicional para obtener una capacidad predictiva que permita identificar características influyentes en los escenarios de riesgo, y no únicamente describir eventos ya ocurridos.

1.1.3 Impacto esperado

El desarrollo de esta solución analítica proyecta un impacto estructurado en tres niveles:

- **Impacto estratégico e institucional:** se espera transformar los registros administrativos del GRD en insumos de inteligencia sanitaria utilizables a nivel de red por autoridades centrales, como FONASA y el Ministerio de Salud. Esto posibilitaría transitar desde una asignación presupuestaria basada en promedios históricos hacia una planificación adaptada a la complejidad real y al perfil de riesgo operativo de la red pública oncológica nacional.
- **Impacto en la gestión operativa de la red hospitalaria:** se espera que la generación de perfiles de riesgo explicables, presentados en formato de reglas de decisión, permita a los gestores hospitalarios anticipar demandas críticas de infraestructura. Por ejemplo, identificar un perfil de alta severidad en pacientes mayores de 65 años con cáncer gástrico y estancias hospitalarias prolongadas permitiría priorizar camas críticas, optimizar la programación quirúrgica y reducir los tiempos de estancia, fortaleciendo así la capacidad de respuesta del sistema público.
- **Impacto técnico y científico:** desde una perspectiva metodológica, se espera que esta investigación contribuya a cerrar la brecha existente en el estado del arte nacional, mediante el establecimiento de un marco reproducible para la aplicación de técnicas de minería de datos y modelos de aprendizaje automático sobre episodios oncológicos del sistema público

chileno. Asimismo, este trabajo podría servir como precedente para el estudio de otras patologías de alta complejidad aún no abordadas mediante registros GRD.

1.2 DESCRIPCIÓN DEL PROBLEMA

El **problema central** de esta investigación radica en la siguiente pregunta: *¿Cómo se asocian las características demográficas, clínicas y hospitalarias de los pacientes oncológicos registrados en el sistema GRD de Chile con los desenlaces de severidad, mortalidad y consumo de recursos en pacientes oncológicos chilenos?*. Esta interrogante refleja la limitada disponibilidad de conocimiento práctico y sistemático que apoye la planificación sanitaria pública. Si bien el sistema GRD recopila un volumen masivo de información estructurada, las metodologías tradicionales de análisis estadístico utilizadas en la gestión hospitalaria oncológica suelen asumir relaciones lineales y aditivas, simplificando la complejidad multidimensional inherente a los episodios oncológicos y limitando la capacidad de extraer perfiles operativos robustos.

En particular, para abordar este problema se seleccionarán tres variables objetivo (desenlaces de riesgo): la **mortalidad**, por constituir un indicador de efectividad clínica y asistencial; la **severidad**, por estimar la infraestructura crítica requerida; y el **consumo de recursos**, por representar un indicador relevante para el ajuste de presupuestos hospitalarios (Cid et al. (2024); Metamodelo (2024b)).

Con el propósito de transformar los registros GRD en conocimiento accionable que apoye la planificación sanitaria, el problema será abordado como una tarea de clasificación de episodios hospitalarios independientes ocurridos entre 2019 y 2024. La cohorte contempla un total de 272.093 egresos por neoplasias malignas como diagnóstico principal (4,7%), 226.525 egresos con neoplasias malignas como diagnóstico secundario (3,9%) y 5.309.837 egresos sin cáncer (91,42%).

En este contexto, el desafío metodológico no consiste en construir un modelo predictivo orientado a generalizar sobre datos futuros, sino en desarrollar un análisis profundo basado en la selección de características influyentes en los distintos escenarios de riesgo. Para ello, la mortalidad será tratada como una tarea de clasificación binaria (fallecido o vivo); la severidad, como una clasificación multiclase ordinal (0: sin gravedad, 1: menor, 2: moderada y 3: mayor); y el consumo de recursos será discretizado en tres niveles (bajo, medio y alto) según los terciles de la cohorte. Estas variables se detallan en la Tabla 1.1.

Sin embargo, aunque los algoritmos de aprendizaje automático son capaces de capturar y clasificar relaciones complejas y no lineales, estos no explican de manera inherente la naturaleza de dichas asociaciones, operando como cajas negras. Por lo tanto, surge el

Tabla 1.1: Variables a predecir y su definición operativa en los escenarios de riesgo.

Variable	Descripción	Valores
Severidad	Nivel de severidad del caso (0-3).	0 = sin gravedad, 1 = menor, 2 = moderada, 3 = mayor.
Mortalidad	Variable binaria construida a partir del atributo TIP0ALTA . Se definirá la clase positiva (1) como aquellos episodios con egreso por fallecimiento, y la clase negativa (0) agrupará todos los demás tipos de alta (domicilio, traslados, hospitalización domiciliaria), reflejando la supervivencia al episodio hospitalario.	Fallecido (1) y vivo (0).
Peso GRD (recursos)	Peso relativo del GRD, que refleja cuánto recurso se consume en el episodio en comparación con un caso promedio. Esta variable tiene distribución continua y se transformará en una variable categórica ordinal (Bajo, Promedio, Alto) mediante discretización por cuantiles (q-cut), método que ordena los episodios según su peso y divide la muestra en tres grupos de igual tamaño (33,3% de los casos cada uno), generando umbrales dinámicos adaptados a la cohorte oncológica. Esto garantiza clases estadísticamente balanceadas para el entrenamiento, evitando el sesgo de los cortes fijos del sistema general.	Bajo (Tercil 1), Promedio (Tercil 2), Alto (Tercil 3).

problema de la interpretabilidad, ya que, una vez seleccionadas las variables relevantes para cada desenlace, resulta necesario comprender cómo contribuyen al riesgo asociado. Para ello, se propone utilizar metodologías de **Inteligencia Artificial Explicable (XAI)**, específicamente mediante **valores de Shapley (SHAP)**, con el objetivo de otorgar explicabilidad a las variables seleccionadas, cuantificando su contribución marginal al riesgo de un desenlace determinado, ya sea aumentando o disminuyendo la probabilidad de una mayor severidad, mortalidad o consumo de recursos.

Cabe destacar que los datos GRD ofrecen un amplio conjunto de variables demográficas (edad, sexo, previsión de salud y comuna), clínicas (diagnóstico principal y diagnósticos secundarios) y hospitalarias (tipo de procedencia, tipo de ingreso y traslados), definidas en las Tablas 1.2, 1.3 y 1.4.

En consecuencia, el problema no radica en la disponibilidad de datos, sino en la ausencia de metodologías analíticas capaces de transformarlos en conocimiento accionable para el área oncológica, lo que actualmente conduce a decisiones de planificación sanitaria sustentadas principalmente en información clínica general o registros locales.

1.2.1 Pregunta de investigación

¿En qué medida las características demográficas, clínicas y hospitalarias registradas en el sistema GRD en Chile se asocian con las diferencias en severidad, mortalidad y consumo

Tabla 1.2: Variables demográficas del sistema GRD.

Variable	Descripción	Valores
CIP_ENCRIPADO	Código único de identificación del paciente de carácter anonimizado para asegurar confidencialidad.	Alfanumérico (tiene un gran volumen de valores únicos).
SEXO	Sexo biológico registrado del paciente.	HOMBRE, MUJER, DESCONOCIDO.
FECHA_NACIMIENTO	Fecha exacta de nacimiento del paciente, utilizada para el cálculo dinámico de su edad.	Formato fecha (AAAA-MM-DD).
ETNIA	Pertenencia autoidentificada del paciente a alguno de los pueblos originarios reconocidos legalmente en Chile.	NINGUNO, MAPUCHE, AY-MARA, RAPA NUI, DIAGUITA, QUECHUA, entre otras.
PROVINCIA	Provincia de residencia político y administrativa del paciente en el territorio chileno.	SANTIAGO, VALPARAISO, CONCEPCION, ARICA, COPIAPO, CAUTIN, entre otras.
COMUNA	Comuna de residencia específica del paciente, para la cobertura local.	PUENTE ALTO, LA FLORIDA, MAIPU, VALPARAISO, ARICA, entre otras.
NACIONALIDAD	País de origen o ciudadanía declarada por el paciente hospitalizado.	CHILE, VENEZUELA, PERU, COLOMBIA, BOLIVIA, HAITI, entre otras.
PREVISION	Régimen de cobertura financiera o seguro de salud del paciente al momento del ingreso hospitalario.	Tramos FONASA (MAI A, B, C, D o FMLE), ISAPRE, PARTICULAR, FFAA (DIPRECA, CAPREDENA, SISA).

Tabla 1.3: Variables clínicas, diagnósticas y neonatales.

Variable	Descripción	Valores
DIAGNOSTIC01 DIAGNOSTIC035	a Diagnósticos médicos del episodio codificados bajo la Clasificación Internacional de Enfermedades (CIE-10). El primero representa el diagnóstico principal.	Códigos alfanuméricos (ej. C50.9 Cáncer de mama, C16.9 Cáncer gástrico, entre otros).
PROCEDIMIENTO1 PROCEDIMIENTO30	a Procedimientos e intervenciones quirúrgicas o clínicas realizadas al paciente durante el episodio hospitalario.	Codificación numérica (ej. 85.23 Mastectomía parcial, 99.25 Inyección de quimioterapia).
CONDICIONDEALTANEONATO1 ... 4	a Estado vital de egreso exclusivo para casos de partos múltiples o atención de neonatos en el mismo episodio clínico.	VIVO, FALLECIDO, Nulo.
PESORN1 a PESORN4	Peso en gramos registrado al nacer para cada uno de los neonatos asociados al parto actual.	Variable numérica continua (ej. 3200, 1500).
SEXORN1 a SEXORN4	Sexo asignado al nacer para cada uno de los neonatos del episodio.	HOMBRE, MUJER, DESCONOCIDO.
RN1ESTADO a RN4ESTADO	Puntuación del Test de Apgar al primer minuto, empleado para evaluar la vitalidad inmediata del recién nacido.	Valores enteros en un rango del 0 al 10.
MEDICOINTERV1_ENCRIPADO	Identificador anonimizado del médico principal responsable de realizar la primera intervención quirúrgica.	Código alfanumérico encriptado.
FECHAPROCEDIMIENTO1	Fecha exacta en la cual se ejecutó el primer procedimiento clínico registrado en la ficha del paciente.	Formato fecha (AAAA-MM-DD).
FECHAINTERV1	Fecha en la que tuvo lugar la primera intervención principal dentro de pabellón.	Formato fecha (AAAA-MM-DD).
ESPECIALIDADINTERVENCION	Especialidad médica o quirúrgica del profesional que lideró el procedimiento principal en quirófano.	CIRUGIA GENERAL, UROLOGIA, OBSTETRICIA Y GINECOLOGIA, entre otras.

Tabla 1.4: Variables hospitalarias y de gestión.

Variable	Descripción	Valores
COD_HOSPITAL	Identificador institucional único asignado a cada establecimiento de la red de salud de Chile.	377 códigos únicos (ej. 114102 Hospital San José de Maipo).
SERVICIO_SALUD	Jurisdicción territorial de la red asistencial a la cual pertenece administrativamente el hospital actual.	METROPOLITANO SURORIENTE, CONCEPCION, DEL MAULE, VALDIVIA, entre otros (29 Servicios).
HOSPPROCEDENCIA	Nombre del hospital de origen en los casos donde el paciente es derivado externamente hacia el centro actual.	Ej. HOSPITAL SAN PABLO (COQUIMBO), HOSPITAL SAN JOSE (CORONEL).
TIPO_PROCEDENCIA	Origen o canal de derivación específico desde el cual ingresa el paciente para su hospitalización.	SERVICIO EMERGENCIA (DOMICILIO), APS URGENCIA, LISTA DE ESPERA, UGCC, entre otras.
TIPO_INGRESO	Carácter administrativo-clínico bajo el cual se ejecuta el ingreso formal a una cama de hospitalización.	URGENCIA, NO PROGRAMADA, PROGRAMADA, OBSTETRICA.
ESPECIALIDAD_MEDICA	Especialidad del servicio clínico asignado que toma la responsabilidad del cuidado del paciente al ingreso.	MEDICINA INTERNA, CIRUGIA GENERAL, ONCOLOGIA MEDICA, PEDIATRIA, entre otras.
TIPO_ACTIVIDAD	Modalidad o régimen de atención bajo el cual se estructura el desarrollo del episodio de salud actual.	HOSPITALIZACION, HOSPITALIZACION EN URGENCIA, HOSPITALIZACION DIURNA, CMA.
FECHA_INGRESO	Fecha formal de inicio del episodio de hospitalización.	Formato fecha (AAAA-MM-DD).
SERVICIOINGRESO	Unidad o servicio clínico físico inicial donde se ubica internado al paciente al entrar al centro.	MEDICINA, CIRUGIA, OBSTETRICA, UNIDAD DE RECUPERACION DE PABELLONES, entre otros.
FECHATRASLADO1 a ...9	Fechas de los traslados internos de servicio realizados dentro del mismo hospital durante el episodio.	Formato fecha (AAAA-MM-DD) o Nulo (si no hubo traslados).
SERVICIOTRASLADO1 a ...9	Unidades clínicas específicas de destino hacia donde se traslada internamente al paciente.	MEDICINA, CIRUGIA, UNIDAD DE CUIDADOS INTENSIVOS ADULTO, entre otras.
FECHAALTA	Fecha oficial de egreso o alta administrativa y clínica del paciente del establecimiento.	Formato fecha (AAAA-MM-DD).
SERVICIOALTA	Último servicio clínico donde permaneció internado el paciente justo antes de su egreso definitivo.	MEDICINA, CIRUGIA, OBSTETRICA, PEDIATRIA, entre otras.
MEDICOALTA_ENCRIPTADO	Identificador encriptado del médico que autoriza y firma el egreso o la epicrisis del paciente.	Código alfanumérico encriptado.
USOSPABELLON	Tipo de infraestructura quirúrgica o sala de procedimientos utilizada durante la atención del caso.	Categorías del 1 al 8 (ej. 1 Pabellón Central, 2 Ambulatorio, 5 Pabellón de Urgencia).
IR_29301_COD_GRD	Código final del GRD asignado al caso, resultante del algoritmo determinista que cruza diagnósticos, procedimientos y edad.	Códigos numéricos de salida (ej. 174132, 174133, 161201).
IR_29301_MORTALIDAD	Índice sintético precalculado por el agrupador GRD que estima el nivel de riesgo intrínseco de mortalidad del caso.	0 = Sin gravedad, 1 = Menor, 2 = Moderada, 3 = Mayor.

de recursos en episodios clínicos de pacientes oncológicos?

1.3 SOLUCIÓN PROPUESTA

La solución propuesta consiste en desarrollar un análisis computacional basado en **minería de datos y aprendizaje automático supervisado explicable (XAI)** como motor analítico principal. En este contexto, la minería de datos abarcará las etapas de preparación y comprensión de los datos, mientras que el aprendizaje automático supervisado explicable utilizará como variables predictoras las características demográficas, clínicas y hospitalarias del sistema GRD para estimar los niveles de severidad, mortalidad y consumo de recursos asociados a los egresos hospitalarios.

A diferencia de los enfoques predictivos tradicionales orientados a generalizar sobre datos futuros, esta investigación se enfoca en caracterizar las asociaciones estadísticas y dependencias subyacentes presentes en la cohorte histórica de episodios clínicos del sistema GRD entre 2019 y 2024.

Por ende, el **propósito central** de esta solución es transformar los datos GRD en evidencia accionable para el área oncológica, mediante la caracterización de perfiles asistenciales de cáncer, la explicación de los factores que determinan los desenlaces y la cuantificación de la importancia relativa de las variables involucradas. Además, se busca generar insumos que sirvan como soporte para la toma de decisiones estratégicas en el sistema de salud pública chileno, apoyando la planificación sanitaria y la gestión de recursos a nivel macro (red), dirigidos a instituciones como FONASA y el Ministerio de Salud (MINSAL), y no a decisiones clínicas individuales en tiempo real.

Asimismo, esta solución generará **perfiles de riesgo explicables**, definidos como reglas de decisión que integran antecedentes, predicciones y explicaciones locales mediante valores SHAP (SHapley Additive exPlanations), los cuales asignan a cada variable un valor de importancia según su contribución marginal al resultado final (Lundberg & Lee (2017)). Posteriormente, estas contribuciones serán traducidas en perfiles orientados a la toma de decisiones de gestión, indicando qué factores demográficos, clínicos y hospitalarios impulsan en mayor medida la severidad, la mortalidad y el consumo de recursos asociados a los egresos hospitalarios.

1.3.1 Hipótesis de trabajo

Existen combinaciones específicas de variables demográficas, clínicas y hospitalarias en los registros GRD que presentan una dependencia estadísticamente significativa con los niveles de severidad, mortalidad y consumo de recursos en episodios oncológicos, y cuyos efectos direccionales (positivos o negativos), así como sus interacciones, pueden ser cuantificados e interpretados mediante técnicas de Inteligencia Artificial Explicable (XAI) aplicadas sobre las características de dichos registros.

1.3.2 Características de la solución

Las características principales de esta solución son las siguientes:

- **Inclusión de cohorte de control y análisis bivariado:** para evitar el sesgo estadístico inherente a caracterizar únicamente a la población oncológica, se integrarán al análisis episodios de pacientes sin cáncer, separando los registros en dos grandes grupos: pacientes sin cáncer y pacientes con cáncer, subdivididos a su vez en diagnósticos oncológicos principales y diagnósticos oncológicos secundarios. Esto permitirá aislar los factores que discriminan y caracterizan la trayectoria oncológica frente a otras patologías presentes en la red pública de salud.
- **Naturaleza explicativa (caja blanca):** la solución se enfocará en cuantificar la influencia de cada variable sobre los resultados, con el propósito de explicar la lógica subyacente de cada perfil de riesgo mediante técnicas de aprendizaje automático supervisado explicable (XAI). Para ello, se analizarán las interacciones entre variables utilizando valores SHAP, los cuales permitirán cuantificar la direccionalidad de cada característica y revelar qué atributos contribuyen positiva o negativamente a los distintos desenlaces oncológicos.
- **Modularidad analítica:** se desarrollarán modelos y análisis independientes para cada dimensión del problema (severidad, mortalidad y consumo de recursos), permitiendo obtener caracterizaciones diferenciadas y evitando asumir que los mismos factores impactan de igual forma en todas las dimensiones analizadas.
- **Orientación a perfiles operativos:** el resultado final consistirá en la **definición de perfiles de riesgo operativo**, diseñados para caracterizar poblaciones y apoyar la planificación sanitaria y económica a nivel de red hospitalaria, facilitando la identificación de patrones de comportamiento relevantes en los datos.

- **Incorporación de variables posteriores a la admisión del paciente:** se incluirán variables que no se encuentran disponibles al momento del ingreso hospitalario, como procedimientos médicos realizados durante la estancia clínica. Esto se justifica debido a que el objetivo metodológico de la propuesta se centra en la selección de características y la caracterización de perfiles, y no en la predicción anticipada de nuevos ingresos. Por ende, la utilización de estas variables no constituirá fuga de datos (*data leakage*) y permitirá dimensionar de manera más precisa la trayectoria hospitalaria del paciente.
- **Aplicación de bootstrapping:** para obtener una representación más robusta de la distribución natural de los datos y manejar el desbalance poblacional existente entre diagnósticos oncológicos y no oncológicos, se extraerán múltiples submuestras aleatorias balanceadas mediante técnicas de *bootstrapping*. Estas submuestras emparejarán subconjuntos de pacientes con cáncer y sin cáncer, permitiendo estimar la frecuencia de aparición y estabilidad de las variables a lo largo de las distintas iteraciones.
- **Selección de características mediante SHAP:** se seleccionarán las 20 variables más relevantes según su importancia calculada mediante valores SHAP, con el propósito de generar perfiles demográficos, clínicos y hospitalarios asociados a cada variable objetivo (severidad, mortalidad y consumo de recursos).
- **Niveles de entregables:** se generarán entregables técnicos (código fuente y documentación), analíticos (reportes y visualizaciones) y de validación (contraste clínico), los cuales se detallan en la Tabla 1.5.

Tabla 1.5: Desglose de entregables por nivel.

Tipo de entregable	Productos entregables
1. Técnicos y documentación	• Repositorio de código: Scripts documentados (Python/Jupyter) que cubren el ciclo de preparación de datos, entrenamiento de modelos y evaluación. • Manual de ejecución: Guía paso a paso para reproducir el entorno (ambiente Conda) y ejecutar los scripts. • Documentación técnica: Reporte de dependencias (con un archivo <code>requirements.txt</code>) y versiones de las librerías utilizadas.
2. Analíticos	• Informe de rendimiento: Reporte detallado con métricas finales (F1-Score, AUPRC, AUC-ROC) por modelo y variable objetivo. • Visualizaciones XAI: Gráficos de interpretabilidad (SHAP Summary Plots, Dependence Plots) que explican las decisiones de cada modelo y todas las visualizaciones obtenidas con SHAP. • Documento de perfiles de riesgo: Documento destinado a indicar y explicar la caracterización de los perfiles de riesgo operativo detectados.
3. Validación	• Matriz de evidencia: Cuadro comparativo que contrasta las reglas extraídas por cada modelo con la literatura médica y guías clínicas como GES (Garantías Explícitas en Salud). • Reporte de experto: Informe con el feedback cualitativo sobre la coherencia de los perfiles generados.

1.4 OBJETIVOS Y ALCANCE DEL PROYECTO

1.4.1 Objetivo general

Caracterizar perfiles clínicos, demográficos y hospitalarios de pacientes oncológicos mediante modelos de aprendizaje automático supervisado explicable aplicados a registros GRD, identificando combinaciones de atributos asociadas a severidad, mortalidad y consumo de recursos, y validando los resultados mediante métricas de rendimiento y coherencia clínica, con el fin de generar un insumo analítico estandarizado que apoye la planificación sanitaria en la red hospitalaria pública de Chile.

1.4.2 Objetivos específicos

1. **Procesar** los episodios de neoplasias malignas registrados en el sistema GRD de Chile entre 2019 y 2024, aplicando técnicas de depuración y preprocesamiento para asegurar la calidad, consistencia e integridad de la información.
2. **Desarrollar** modelos de clasificación supervisada para severidad, mortalidad y consumo de recursos, optimizando sus hiperparámetros mediante validación cruzada y métricas de rendimiento, además de aplicar técnicas de *bootstrapping* para analizar la estabilidad de las variables a lo largo de múltiples iteraciones, con el propósito de generar herramientas robustas que permitan identificar variables influyentes en distintos escenarios de riesgo para la planificación sanitaria.
3. **Generar** perfiles de riesgo operativo interpretables mediante técnicas de Inteligencia Artificial Explicable (XAI), extrayendo reglas que cuantifiquen la influencia de las variables sobre los desenlaces analizados, abordando un problema bivariado entre pacientes con cáncer y sin cáncer, con el objetivo de transformar las predicciones en conocimiento explicable que apoye la gestión estratégica sanitaria.
4. **Validar** la coherencia de los perfiles obtenidos mediante contraste con estudios oncológicos previos y evaluación de hallazgos contraintuitivos a través de métricas SHAP y juicio experto, con el fin de garantizar la confiabilidad de los resultados y su alineación con la evidencia científica vigente.

1.4.3 Alcances

A continuación, se consideran los siguientes alcances de la solución:

- **Cohorte de estudio:** el análisis se acotará a episodios clínicos registrados en el sistema GRD entre 2019 y 2024. Además de considerar pacientes con cáncer, se incluirá una muestra de pacientes sin cáncer que actuará como cohorte de control, lo que permitirá establecer un escenario base de clasificación binaria y reducir sesgos en la identificación de factores de riesgo. Para los casos oncológicos, se considerará como referencia que el diagnóstico principal (de ingreso) o secundario corresponda a alguna neoplasia maligna asociada a los códigos CIE-10 C00–C97, descritas más adelante en la lista 2.1.4. Asimismo, se realizará una partición aleatoria de los datos correspondientes al período entre 2019 y 2024, destinando un 80% para **entrenamiento** y un 20% para **prueba**. Cabe destacar que esta distribución se fundamenta en estudios del estado del arte y supera ampliamente el volumen de datos utilizado en investigaciones previas, las cuales trabajaron con cohortes de entre 1.400 y 29.000 pacientes (Lai et al. (2022); Jacobson et al. (2022); Peterson et al. (2021); Chen et al. (2021)). Además, cada episodio clínico será caracterizado de manera independiente, considerando múltiples hospitalizaciones de un mismo paciente, dado que este puede presentar distintos niveles de complejidad a lo largo de diferentes ingresos hospitalarios.
- **Variables de entrada (predictores):** se utilizarán variables demográficas, clínicas y hospitalarias disponibles en los registros GRD, descritas anteriormente en las Tablas 1.2, 1.3 y 1.4. Debido a que el objetivo metodológico se centra en la selección de características y en la identificación de asociaciones estadísticas dentro del mismo conjunto de datos, y no en la construcción de un modelo predictivo orientado a generalizar eventos futuros, se incluirán variables no disponibles al momento del ingreso hospitalario (como procedimientos realizados durante la estancia clínica), lo cual no constituirá fuga de datos (*data leakage*).
- **Variables objetivo (salidas):** se entrenarán modelos independientes para la clasificación de mortalidad, severidad y consumo de recursos. Estas variables se describieron en la Tabla 1.1.
- **Modelos aplicados:** se implementarán algoritmos representativos del estado del arte, incluyendo Random Forest, XGBoost y regresión logística como línea base. Esta última será configurada con regularización L1/L2 para manejar la alta dimensionalidad de los datos y con ajuste de pesos de clase (*class weights*) para abordar el desbalance poblacional, permitiendo así una comparabilidad adecuada con los modelos no lineales.

Los hiperparámetros iniciales de cada modelo se detallan en la Tabla 1.6. Adicionalmente, el modelo con mejor rendimiento será interpretado mediante valores SHAP, exceptuando el caso de la regresión logística, cuya interpretación se realizará mediante sus coeficientes (*odds ratios*), los cuales indican cuánto aumenta o disminuye el riesgo asociado por unidad de incremento de una variable. Por ejemplo, un incremento de un año en la edad podría asociarse con un aumento porcentual en la probabilidad de mortalidad.

Tabla 1.6: Espacio de búsqueda de hiperparámetros utilizado para la optimización mediante Grid Search.

Algoritmo	Hiperparámetro	Rango de valores	Justificación e influencia
Regresión logística	penalty (penalización)	['l1', 'l2']	Define el tipo de regularización (Lasso vs. Ridge) utilizada para la selección de variables. La penalización l1 (Lasso) es más estricta, ya que elimina completamente las variables irrelevantes, simplificando el modelo, mientras que l2 (Ridge) es más suave, reduciendo el impacto de las variables sin eliminarlas, evitando que alguna domine excesivamente el modelo (Hastie et al. (2009)).
	c	[0.1, 1.0, 10.0]	Inverso de la fuerza de regularización. Los valores pequeños (0.1) imponen mayor regularización, favoreciendo modelos más simples y con mejor capacidad de generalización, mientras que los valores más altos (10.0) permiten un mayor ajuste a los datos de entrenamiento.
Random Forest	n_estimators	[100, 200, 500]	Número de árboles del ensamble. Los valores menores (100) reducen el tiempo de entrenamiento, pero pueden generar estimaciones más inestables. Por otro lado, los valores mayores (500) incrementan la estabilidad y robustez del modelo al reducir la varianza del error, a costa de mayor tiempo computacional (Probst et al. (2019)).
	max_depth (profundidad máxima)	[10, 20, None]	Controla la complejidad del modelo para evitar sobreajuste. Con <code>None</code> , los árboles crecen sin restricción hasta clasificar perfectamente los datos; pero valores como 10 limitan la profundidad y favorecen una mejor generalización.
	min_samples_split (mínimo de muestras para dividir)	[2, 5, 10]	Número mínimo de observaciones requeridas para dividir un nodo. Los valores bajos permiten subdivisiones muy pequeñas, mientras que los valores más altos exigen grupos más grandes, promoviendo reglas más estables y menos sensibles al ruido.
XGBoost	learning_rate (tasa de aprendizaje)	[0.01, 0.1, 0.3]	Controla la magnitud de actualización de los pesos. Los valores bajos (0.01) requieren más iteraciones, pero suelen generalizar mejor; los valores altos (0.3) aceleran el aprendizaje, aunque aumentan el riesgo de sobrepasar el óptimo (Chen & Guestrin (2016)).
	max_depth (profundidad máxima)	[3, 6, 10]	Profundidad de los árboles base. En modelos de boosting se prefieren árboles menos profundos, ya que la combinación secuencial de modelos simples captura la complejidad global.
	scale_pos_weight (peso de clases)	[Auto]	Ajuste automático de pesos para manejar clases desbalanceadas, especialmente relevante para la variable de mortalidad. Permite asignar mayor importancia a la clase minoritaria, evitando que sea ignorada durante el entrenamiento.

Por otro lado, este estudio presenta las siguientes limitaciones:

- **Naturaleza de los datos:** los registros GRD corresponden a datos administrativos de egreso hospitalario y, aunque contienen variables clínicas relevantes (como diagnósticos

principales y secundarios), no constituyen una historia clínica completa y detallada. Por ejemplo, no incluyen resultados de laboratorio ni biomarcadores específicos, como marcadores genéticos.

- **Variables latentes:** existe riesgo de sesgo derivado de variables omitidas que podrían ser determinantes en oncología, tales como factores sociales o condiciones clínicas específicas no capturadas por el sistema GRD. Esto puede limitar la capacidad explicativa de los modelos y afectar parcialmente su validez clínica.
- **Asociación y causalidad:** los resultados obtenidos mediante el enfoque explicativo, particularmente la cuantificación de la influencia de las variables sobre las predicciones de los modelos, no deben interpretarse como relaciones causales directas, sino que los hallazgos deben considerarse como hipótesis analíticas que contribuyan a la gestión sanitaria y no como leyes clínicas definitivas o inmutables.

1.5 METODOLOGÍA Y HERRAMIENTAS UTILIZADAS

1.5.1 Metodología

Se realizará una adaptación del marco metodológico **CRISP-DM (Cross-Industry Standard Process for Data Mining)**, seleccionado por ser el estándar de facto para garantizar la fiabilidad y reproducibilidad en proyectos de analítica avanzada. Además, este enfoque sitúa la comprensión del problema como eje central y permite iteraciones flexibles entre sus distintas fases (Schröer et al. (2021)), las cuales se describen a continuación e ilustran en la Figura 1.1:

- **Fase 1 - Comprensión del problema:** etapa inicial, abordada preliminarmente en esta propuesta, en la que se traducen las necesidades de planificación oncológica y las brechas de información existentes en objetivos técnicos de minería de datos, tales como la construcción de perfiles de riesgo relevantes para la gestión sanitaria.
- **Fase 2 - Preparación de los datos:** etapa representativa de la minería de datos, que incluirá la exploración de la base histórica correspondiente al período 2019–2024, considerando tanto la cohorte oncológica como la cohorte de control (sin cáncer). En esta fase se analizarán las frecuencias de variables categóricas, las medidas de tendencia central y dispersión de variables numéricas, incluyendo detección de *outliers*, procesos de limpieza y transformación de datos, identificación y estandarización de formatos de

fecha, generación de variables derivadas, análisis de correlación y codificación de variables categóricas mediante One-Hot Encoding. Como resultado, se obtendrá el conjunto final de datos para el modelado. Por último, para garantizar representatividad y evitar sesgos temporales, se realizará una partición aleatoria de los registros de todos los años del estudio, destinando un 80% para entrenamiento y un 20% para evaluación.

- **Fase 3 - Modelado y análisis de estabilidad (*Bootstrapping*):** etapa en la que se aplicarán técnicas de aprendizaje automático supervisado orientadas a tareas de clasificación, utilizando validación cruzada junto con optimización de hiperparámetros mediante *Grid Search* para obtener métricas de rendimiento por pliegue. En variables con mayor desbalance de clases, como mortalidad, se incorporarán técnicas de remuestreo, específicamente SMOTE, dentro de los pliegues de entrenamiento para mitigar dicho desbalance. En particular, se entrenarán modelos de regresión logística y modelos de clasificación basados en árboles de decisión, específicamente Random Forest y XGBoost, utilizando todas las variables codificadas en la fase anterior. Asimismo, para analizar la estabilidad de las variables, el proceso de entrenamiento será repetido múltiples veces sobre distintas submuestras balanceadas, incluyendo registros oncológicos y de control. Este procedimiento aprovechará el teorema del límite central para aproximar la distribución natural de los datos, permitiendo medir la estabilidad y robustez estadística de la importancia de cada característica.
- **Fase 4 - Evaluación del modelo:** etapa en la que se analizarán las métricas obtenidas mediante validación cruzada con el fin de seleccionar el modelo óptimo para cada variable objetivo. Posteriormente, los modelos seleccionados serán evaluados sobre el conjunto de prueba, garantizando así su confiabilidad frente a datos distintos de aquellos utilizados durante el entrenamiento. Adicionalmente, se verificará la alineación de los resultados obtenidos con los objetivos de planificación sanitaria definidos en la Fase 1.
- **Fase 5 - Interpretación y generación de perfiles:** etapa en la que se implementará una estrategia de explicabilidad dual, tanto global como local. En este contexto, el análisis descriptivo bivariado se concentrará en las características más estables e importantes del conjunto de datos (Top 20), mientras que SHAP permitirá cuantificar la direccionalidad de dichas variables, revelando cuáles contribuyen positivamente hacia cada variable objetivo en presencia de cáncer y cuáles favorecen la clase no oncológica. En caso de que la regresión logística obtenga el mejor rendimiento, se interpretarán sus coeficientes mediante *odds ratios*; no obstante, SHAP será aplicado igualmente sobre el modelo no lineal más robusto (XGBoost o Random Forest) para capturar interacciones complejas que los modelos lineales tienden a omitir. A partir de ello, se definirán perfiles de riesgo operativo, identificando qué

atributos, y en qué magnitud, influyen sobre cada desenlace. Además, ante la presencia de variables dominantes en el análisis SHAP, se realizarán análisis estratificados, procesos de *bootstrapping* y pruebas de estabilidad de reglas.

- **Fase 6 - Validación interpretativa:** finalmente, los perfiles generados serán contrastados con evidencia clínica y literatura científica especializada, con el propósito de validar que los patrones identificados posean respaldo científico. Por otro lado, los patrones contraintuitivos serán evaluados considerando su importancia global, varianza explicada y juicio experto.




Figura 1.1: Pipeline de trabajo propuesto (CRISP-DM) para el análisis.

Fuente: Elaboración propia, 2026.

Cabe mencionar que las seis fases oficiales de **CRISP-DM** son las siguientes:

1. **Comprensión del negocio o problema.**
2. **Comprensión de los datos.**
3. **Preparación de los datos.**
4. **Modelado.**
5. **Evaluación.**
6. **Despliegue.**

Sin embargo, dado que esta propuesta no contempla la implementación de un software productivo, sino la generación de conocimiento analítico, la fase de **despliegue** fue adaptada y desglosada en las fases de **interpretación** y **validación interpretativa**. Por otro

lado, la Figura 1.1 contempla flujos de retroalimentación críticos destinados a asegurar la calidad y consistencia metodológica de la solución:

- **De preparación a comprensión (Fase 2 → Fase 1):** este flujo permite validar tempranamente la viabilidad técnica de los objetivos planteados. Por ejemplo, si durante la exploración de datos se detectan limitaciones críticas, como variables con más del 30% de valores nulos, inconsistencias temporales (por ejemplo, fechas de alta anteriores a la fecha de ingreso) o variables con un desbalance de clases extremadamente elevado (superior al 90%), será necesario regresar a la fase 1 para realizar ajustes acotados en la definición de las variables objetivo o de entrada, garantizando así que el problema formulado sea técnicamente viable con los datos disponibles. Por ejemplo, si la variable de previsión de salud presenta valores nulos en el 99% de los registros, resultaría inviable utilizarla como predictor, debiendo redefinirse las variables consideradas en la Fase 1.
- **De modelado a preparación (Fase 4 → Fase 3):** este constituye el ciclo iterativo más frecuente, ya que, si los modelos aplicados (como Random Forest o XGBoost) obtienen un desempeño insuficiente (por ejemplo, un F1-Score inferior a 0,6), será necesario regresar a la fase de preparación para reprocesar los datos y experimentar con nuevas estrategias de imputación, transformación o balanceo de clases. Por ejemplo, si el modelo XGBoost evidencia un sobreajuste severo (*overfitting*), se retornará a la Fase 3 para aplicar una ingeniería de características más agresiva, como agrupar códigos CIE-10 en categorías diagnósticas más generales, reduciendo así la dimensionalidad y favoreciendo la capacidad de generalización del modelo.
- **De evaluación a comprensión (Fase 5 → Fase 1):** este flujo representa un mecanismo de contingencia frente a resultados no concluyentes. Si, tras la evaluación final, los modelos no alcanzan los umbrales de rendimiento esperados o presentan métricas anómalas (por ejemplo, un AUC-ROC igual a 1), el trabajo realizado no será descartado. En su lugar, se regresará a la Fase 1 para recalibrar los criterios de éxito, siempre que los resultados se mantengan dentro de un margen de tolerancia del 15% respecto de los umbrales definidos inicialmente. En caso contrario, se documentará la inviabilidad predictiva como un hallazgo relevante acerca de las limitaciones actuales de los registros GRD, sin necesidad de reiniciar la investigación desde cero.
- **De validación a interpretación (Fase 6 → Fase 5):** este flujo ocurre cuando los perfiles de riesgo obtenidos son matemáticamente consistentes, pero clínicamente redundantes debido a la presencia de variables dominantes. Por ejemplo, si en el análisis SHAP la variable más influyente corresponde al tipo de cáncer, esta podría aportar un valor limitado para la gestión hospitalaria en comparación con el conocimiento clínico ya existente. En dicho escenario,

se regresará a la fase de interpretación para activar un protocolo de **análisis estratificado**, generando explicaciones SHAP específicas para distintos subgrupos diagnósticos.

1.5.2 Herramientas de desarrollo

Para la ejecución de los scripts de procesamiento de datos, modelado, evaluación y explicabilidad, se utilizará un computador de escritorio con sistema operativo Windows 10 de 64 bits, cuyas características principales son las siguientes:

- **Procesador (CPU):** AMD Ryzen 5 5500 @ 3.60 GHz, con 6 núcleos y 12 hilos de procesamiento lógico, lo que permitirá paralelizar el entrenamiento de algoritmos de ensamble, como Random Forest.
- **Memoria RAM:** 16 GB DDR4 a 2667 MHz, capacidad suficiente para cargar y manipular en memoria el conjunto de datos GRD de episodios oncológicos mediante estructuras de datos en *Pandas*.
- **Tarjeta gráfica (GPU):** NVIDIA GeForce RTX 3050 con 6 GB de VRAM, la cual permitirá habilitar aceleración por hardware mediante CUDA, tecnología soportada nativamente por la librería XGBoost. El uso de GPU se justifica por la necesidad de reducir los tiempos de entrenamiento asociados a la búsqueda de hiperparámetros (*Grid Search*) sobre un conjunto de datos de alta dimensionalidad y volumen considerable (más de 270.000 instancias), donde la ejecución exclusiva en CPU podría resultar computacionalmente costosa.
- **Almacenamiento:** unidades SSD con una capacidad total aproximada de 2 TB (Crucial BX500 y ADATA Legend 710), garantizando altas velocidades de lectura y escritura (I/O) para el procesamiento eficiente de los datos.

Adicionalmente, se utilizará **Overleaf** para la redacción de informes y entregables en formato LaTeX, **Visual Studio Code** como editor de código para el desarrollo y mantenimiento de los scripts, y **GitHub** como sistema de control de versiones, con el objetivo de mantener la trazabilidad de los cambios realizados durante el procesamiento y modelado de datos, asegurando así la reproducibilidad de los experimentos.

Respecto al ambiente de desarrollo, el software será implementado utilizando el lenguaje de programación **Python** (versión 3.9 o superior), seleccionado por constituir el estándar actual en ciencia de datos y por disponer de un ecosistema robusto de librerías orientadas al

aprendizaje automático y a la inteligencia artificial explicable (XAI), como SHAP (Raschka et al. (2020); Molnar (2020)).

El entorno de trabajo se configurará mediante la distribución **Anaconda**, utilizando **Jupyter Notebook** como interfaz de desarrollo interactivo para las distintas etapas del proyecto (preparación de datos, modelado, evaluación e interpretación). Esta elección se fundamenta en la naturaleza exploratoria de la metodología CRISP-DM, donde resulta necesario visualizar resultados intermedios y facilitar tanto la depuración técnica como el análisis clínico de los hallazgos.

Las principales librerías y dependencias técnicas a utilizar serán las siguientes, las cuales están detalladas en la Tabla 1.7:

- **Pandas y NumPy:** utilizadas para la manipulación matricial, estructuración de bases de datos, limpieza de registros y análisis exploratorio inicial.
- **Scikit-Learn:** empleada para el escalamiento de datos, partición aleatoria de conjuntos, cálculo de métricas estadísticas y entrenamiento de modelos de clasificación tradicionales, como Random Forest y regresión logística.
- **XGBoost y LightGBM:** frameworks de aprendizaje automático basados en *Gradient Boosting*, utilizados por su alta eficiencia computacional y capacidad para capturar relaciones no lineales complejas presentes en los datos GRD.
- **SHAP:** herramienta matemática basada en teoría de juegos que permite otorgar explicabilidad local y global a modelos de caja negra, cuantificando la contribución marginal de cada variable sobre las predicciones generadas.
- **Matplotlib y Seaborn:** librerías utilizadas para la generación de visualizaciones estadísticas, matrices de correlación y gráficos de resumen asociados a los valores SHAP.

1.6 ORGANIZACIÓN DEL DOCUMENTO

El presente documento se estructura en cinco capítulos, los cuales guían de manera progresiva y sistemática el desarrollo de la investigación orientada a la caracterización descriptiva de episodios oncológicos en la red pública de salud chilena. A continuación, se detalla brevemente el propósito y contenido de cada apartado:

- **Capítulo 1 - Introducción:** establece el marco inicial del estudio mediante la descripción del contexto epidemiológico y operativo del cáncer en Chile, así como de la implementación

Tabla 1.7: Librerías y dependencias del proyecto.

Librería (versión)	Propósito	Justificación en el proyecto
Pandas (v2.0+) / NumPy (v1.24+)	Manipulación de datos	Se usarán para el procesamiento vectorial de los registros GRD y el manejo eficiente de estructuras de datos tabulares (DataFrames), aprovechando el soporte nativo para tipos de datos nulos de las versiones recientes (McKinney et al. (2010)).
Matplotlib (v3.7+) / Seaborn (v0.12+)	Visualización	Se usarán para la generación de gráficos estáticos de alta calidad para el Análisis Exploratorio de Datos (EDA) y para reportes visuales de resultados (como matrices de confusión) (Hunter (2007)).
Scikit-learn (v1.3+)	Modelado base	Para la implementación de algoritmos clásicos (regresión logística, Random Forest), técnicas de preprocesamiento (One-Hot Encoding, imputación) y el cálculo de métricas de evaluación (Pedregosa et al. (2011)).
XGBoost (v2.0+)	Modelado avanzado	Implementación del algoritmo de <i>Gradient Boosting</i> optimizado. Se selecciona esta versión por su soporte mejorado para aceleración por GPU y el manejo nativo de valores faltantes (Chen & Guestrin (2016)).
SHAP (v0.42+)	Explicabilidad (XAI)	Cálculo de valores de Shapley para interpretar modelos de caja negra (Random Forest, XGBoost), permitiendo extraer reglas de decisión globales y locales consistentes (Lundberg & Lee (2017)).
Imbalanced-learn (v0.12+)	Balanceo de datos	Librería auxiliar que proporciona técnicas de remuestreo (SMOTE) para manejar el desbalance severo de clases, compatible con las versiones recientes de Scikit-learn (Lemaître et al. (2017)).

institucional del sistema de Grupos Relacionados por el Diagnóstico (GRD). En esta sección se define el problema de investigación, formulando la pregunta de investigación, la hipótesis de trabajo, los objetivos generales y específicos, las delimitaciones del alcance y una síntesis de la metodología y herramientas de desarrollo a utilizar.

- **Capítulo 2 - Antecedentes:** aborda la revisión del estado del arte y el sustento teórico de la investigación. En esta sección se presentan los fundamentos clínicos de las neoplasias malignas y los mecanismos operativos del estándar International Refined (IR-GRD) bajo la administración de FONASA. Adicionalmente, se examina literatura científica nacional e internacional relacionada con el uso de registros clínico-administrativos masivos, técnicas estadísticas para el análisis de asociaciones no lineales y fundamentos matemáticos de la Inteligencia Artificial Explicable (XAI).
- **Capítulo 3 - Metodología:** expone el diseño experimental e investigativo basado en una adaptación del ciclo de vida CRISP-DM. Se detalla el proceso de extracción, análisis de variables numéricas y categóricas, limpieza, transformación, derivación y codificación bivariada de la base de datos histórica correspondiente al período 2019–2024, incorporando tanto la cohorte oncológica como la cohorte de control (sin cáncer). Además, se describe el entrenamiento de modelos, la optimización de hiperparámetros mediante *Grid Search* y validación cruzada, la implementación de remuestreo iterativo (*bootstrapping*) para medir la estabilidad de las variables, la evaluación de los modelos sobre el conjunto de prueba y la extracción de valores SHAP para la interpretación direccional de cada desenlace de riesgo.

- **Capítulo 4 - Resultados y análisis:** presenta los hallazgos empíricos derivados del flujo analítico desarrollado, incluyendo la identificación y jerarquización de las variables estadísticamente más relevantes en los episodios hospitalarios, así como la visualización cuantitativa de los impactos locales y globales de cada atributo sobre las variables objetivo mediante SHAP. El análisis considera tanto la discriminación basal entre pacientes con cáncer y sin cáncer como la caracterización específica de los distintos perfiles oncológicos. Finalmente, los resultados son discutidos críticamente, contrastando las reglas de asociación identificadas con la práctica médica oncológica y la realidad de la gestión sanitaria pública.
- **Capítulo 5 - Conclusiones:** sintetiza las conclusiones generales del estudio en función del cumplimiento de los objetivos planteados y de la validación de la hipótesis de trabajo. Asimismo, se destacan las principales contribuciones metodológicas derivadas del uso descriptivo de modelos avanzados aplicados sobre datos administrativos en Chile, se exponen de manera transparente las limitaciones conceptuales y técnicas de los registros GRD, y se proponen futuras líneas de investigación orientadas al diseño de políticas de planificación hospitalaria basadas en evidencia.

CAPÍTULO 2. ANTECEDENTES

2.1 EL CÁNCER COMO PROBLEMA DE SALUD PÚBLICA Y SU IMPACTO

2.1.1 Definición de cáncer

El término cáncer, también conocido como tumor maligno o neoplasia maligna, no se refiere a una única enfermedad, sino que engloba un grupo amplio y heterogéneo de patologías que pueden originarse en prácticamente cualquier órgano o tejido del cuerpo humano (Organización Mundial de la Salud (OMS) (2022)).

Según la Organización Mundial de la Salud (OMS), el cáncer se caracteriza por la multiplicación rápida de células anormales que se extienden más allá de sus límites habituales y pueden invadir partes adyacentes del cuerpo o propagarse a otros órganos en un proceso denominado metástasis. En específico, esta enfermedad se produce cuando las células normales se transforman en células tumorales a través de un proceso de múltiples etapas, que generalmente consiste en la progresión desde una lesión precancerosa hacia un tumor maligno. Estas alteraciones son provocadas por la interacción entre factores genéticos propios de la persona afectada y agentes carcinógenos físicos (como radiaciones ultravioletas e ionizantes), químicos (como el tabaco, el asbesto, las aflatoxinas y el arsénico) y biológicos (como determinados virus, bacterias y parásitos) (Organización Mundial de la Salud (OMS) (2022)).

2.1.2 Impacto global del cáncer

El cáncer se ha convertido en una de las principales causas de mortalidad a nivel mundial. Según el Reporte Mundial de Cáncer 2020 de la OMS, esta enfermedad corresponde a la segunda causa más frecuente de mortalidad global (16,3%), siendo superada únicamente por las enfermedades cardiovasculares (32%). En particular, durante el año 2020 el cáncer constituyó la primera y segunda causa (en algunos países) de mortalidad prematura en 134 de 183 países. En América (incluyendo América del Norte, América del Sur y el Caribe), el cáncer se posicionó como la segunda causa principal de muerte, registrándose más de 1,4 millones de fallecimientos asociados a esta enfermedad, equivalentes al 14% de las muertes oncológicas a nivel mundial. De estas defunciones, aproximadamente 713.414 correspondieron específicamente a Sudamérica y el Caribe (5% del total mundial), destacando Brasil, México y

Argentina como los países con mayor cantidad de casos (Ministerio de Salud de Chile (2022)).

Respecto de los tipos de cáncer, aquellos que registraron el mayor número de muertes a nivel mundial según GLOBOCAN al año 2020 fueron el cáncer de pulmón (18%), el cáncer colorrectal (9,4%), el cáncer de hígado (8,3%), el cáncer de estómago (7,7%) y el cáncer de mama (6,9%). En relación con la mortalidad oncológica según sexo, en mujeres la mayor tasa de defunción corresponde al cáncer de mama, con una tasa de mortalidad de 13,6 por cada 100.000 mujeres, seguido del cáncer de pulmón (11,2), el cáncer cervicouterino (7,3) y el cáncer colorrectal (7,2 por cada 100.000 mujeres). En hombres, predomina el cáncer de pulmón con una tasa de 25,9 por cada 100.000 hombres, seguido por el cáncer de hígado (12,9), el cáncer colorrectal y el cáncer de estómago, ambos con una tasa cercana a 11 por cada 100.000 hombres (Ministerio de Salud de Chile (2022)).

En síntesis, la OMS estima que el cáncer ocasiona alrededor de 9 millones de muertes anuales a nivel mundial, representando aproximadamente una de cada seis muertes en el mundo. Además, cerca del 30% de las muertes por cáncer se atribuyen a factores de riesgo modificables, como el consumo de tabaco y alcohol, el índice de masa corporal, la alimentación inadecuada y el sedentarismo, lo que evidencia un importante potencial de prevención mediante estrategias de salud pública orientadas a reducir su impacto (Ministerio de Salud de Chile (2022)).

Siguiendo esta línea, a partir del año 2013 la OMS impulsó un plan de acción mundial para la prevención y control de enfermedades no transmisibles, estableciendo como meta reducir en un 25% la mortalidad prematura causada por las cuatro principales enfermedades crónicas hacia el año 2025, entre ellas el cáncer. Este plan contempla estrategias centradas en prevención, diagnóstico precoz, acceso oportuno a tratamiento de calidad y monitoreo continuo de los resultados sanitarios (Ministerio de Salud de Chile (2022)).

Respecto de las proyecciones epidemiológicas, se estima que, si las condiciones estratégicas y epidemiológicas se mantienen sin cambios significativos en el tiempo (asumiendo estabilidad demográfica, poblacional y en las tasas de incidencia), el número anual de nuevos casos diagnosticados en Sudamérica y el Caribe aumentará desde 1,4 millones de casos en 2018 a aproximadamente 2,5 millones en 2040, lo que representaría un incremento cercano al 78% (Ministerio de Salud de Chile (2022)).

2.1.3 Epidemiología e impacto socioeconómico del cáncer en Chile

En el transcurso de las últimas décadas, Chile ha experimentado una profunda transición demográfica y epidemiológica, caracterizada por el envejecimiento progresivo de la población y el aumento de las enfermedades crónicas no transmisibles (ECNT). En este contexto,

el cáncer ha desplazado a las enfermedades cardiovasculares en múltiples regiones del país, consolidándose como una de las principales causas de mortalidad y morbilidad a nivel nacional (Ministerio de Salud de Chile (2022)).

Respecto de los casos de cáncer registrados durante el año 2020, según GLOBOCAN (*Global Cancer Observatory*), en mujeres los cánceres con mayor incidencia en Chile fueron el cáncer de mama, colorrectal, cervicouterino, de pulmón y de tiroides. Mientras que en hombres, los de mayor incidencia correspondieron al cáncer de próstata, colorrectal, de estómago, de pulmón y de riñón. En relación con la mortalidad oncológica, en mujeres los principales tipos de cáncer fueron mama, pulmón, colorrectal, estómago y cervicouterino, mientras que en hombres correspondieron al cáncer de estómago, pulmón, próstata, colorrectal e hígado (Ministerio de Salud de Chile (2022)).

Por otro lado, según estimaciones recientes de la Organización para la Cooperación y el Desarrollo Económicos (OCDE), publicadas en su informe de 2024 sobre el impacto del cáncer en Chile, se proyecta que entre los años 2023 y 2050 el cáncer será responsable del 18% de las muertes prematuras (antes de los 75 años) en el país, lo que equivale a que una de cada seis muertes prematuras será consecuencia directa de esta enfermedad. Esto se traduce en un estimado de 9.900 muertes prematuras anuales y una reducción promedio de 1,6 años en la esperanza de vida de la población chilena (OECD (2024)).

Más allá de la carga de mortalidad y morbilidad que impone esta enfermedad, la atención oncológica ejerce una presión significativa sobre la infraestructura de la red asistencial pública y el presupuesto estatal. El mismo informe de la OCDE estima que el gasto per cápita en salud asociado al cáncer en Chile experimentará un incremento del 123% hacia el año 2050, impulsado principalmente por el envejecimiento poblacional (OECD (2024)). Frente a este escenario, el Ministerio de Salud (MINSAL) formuló el Plan Nacional del Cáncer 2022–2027, marco estratégico y normativo derivado de la Ley Nacional del Cáncer (Ley 21.258), el cual reconoce oficialmente las deficiencias históricas en el acceso a atención oncológica, la saturación de centros de alta complejidad y la necesidad de fortalecer los sistemas de registro e inteligencia sanitaria. Asimismo, este plan destaca la importancia de optimizar los recursos hospitalarios y la vigilancia epidemiológica con el objetivo de mitigar el impacto socioeconómico de la enfermedad y garantizar la sostenibilidad de la red pública de salud (Ministerio de Salud de Chile (2022)).

2.1.4 Clasificación y caracterización de las neoplasias malignas

Para abordar estadísticamente el impacto del cáncer, resulta fundamental comprender tanto su naturaleza biológica como su estandarización clínica. El cáncer no corresponde a

una patología única, sino a un conjunto complejo y heterogéneo de más de cien enfermedades distintas, caracterizadas por una proliferación celular anormal, descontrolada e invasiva. Debido a esta heterogeneidad, dichas patologías fueron estandarizadas a nivel internacional mediante la Clasificación Internacional de Enfermedades en su décima revisión (CIE-10), elaborada por la OMS, donde las neoplasias ocupan el Capítulo II (códigos C00 a D48). Esta clasificación proporciona un lenguaje codificado universal que permite la interoperabilidad entre registros clínicos y administrativos en contextos hospitalarios (Organización Panamericana de la Salud (OPS) y Organización Mundial de la Salud (OMS) (2018)).

Con base en esta codificación, las neoplasias malignas pueden dividirse en dos grandes categorías basales:

- **Neoplasias sólidas (C00–C80):** corresponden a tumores originados en órganos o tejidos específicos, como el cáncer de pulmón, mama o próstata. Estas neoplasias constituyen la mayoría de los casos oncológicos y su manejo suele requerir intervenciones quirúrgicas complejas, radioterapia y estancias hospitalarias prolongadas (Departamento de Estadísticas e Información de Salud (DEIS) (2018)).
- **Neoplasias del tejido linfático y hematopoyético (C81–C96):** incluyen patologías como leucemias, linfomas y mielomas, originadas en la médula ósea o en los ganglios linfáticos. Debido a su naturaleza sistémica, presentan patrones de consumo de recursos y requerimientos de infraestructura distintos a los de las neoplasias sólidas, incluyendo necesidades como aislamiento clínico o trasplantes de médula ósea. Además, pueden originarse simultáneamente en múltiples localizaciones (Departamento de Estadísticas e Información de Salud (DEIS) (2018)).

No obstante, el sistema CIE-10 contempla distintos bloques principales de neoplasias malignas que determinan la naturaleza clínica de cada episodio hospitalario (Organización Panamericana de la Salud (OPS) y Organización Mundial de la Salud (OMS) (2018)):

- **C00-C14 (Neoplasias malignas de labio, cavidad bucal y faringe):** Incluyen tumores originados en el tracto aerodigestivo superior, los cuales son altamente asociados a factores de riesgo como el consumo de tabaco y alcohol.
- **C15-C26 (Neoplasias malignas de los órganos digestivos):** Agrupan tumores del esófago, estómago, colon, recto e hígado, los cuales representan una alta carga de morbilidad y suelen implicar resecciones quirúrgicas mayores.
- **C30-C39 (Neoplasias malignas de los órganos respiratorios e intratorácicos):** Principalmente el cáncer de pulmón y laringe, caracterizados por una alta letalidad y requerimientos de soporte ventilatorio o cuidados críticos.

- **C40-C41 (Neoplasias malignas de los huesos y de los cartílagos articulares):** Tumores óseos primarios, como el osteosarcoma, que afectan la movilidad funcional del paciente y requieren cirugías traumatológicas complejas.
- **C43-C44 (Melanoma y otras neoplasias malignas de la piel):** Tumores cutáneos de diverso grado de agresividad, en donde el melanoma destaca por su alto potencial metastásico sistémico.
- **C45-C49 (Neoplasias malignas de los tejidos mesoteliales y de los tejidos blandos):** Incluyen mesoteliomas y diversos tipos de sarcomas originados en músculos, grasa o vasos sanguíneos.
- **C50 (Neoplasias malignas de la mama):** Una de las patologías oncológicas con mayor incidencia global en mujeres, cuyo abordaje es multidisciplinario (mastectomía, quimioterapia, hormonoterapia).
- **C51-C58 (Neoplasias malignas de los órganos genitales femeninos):** Tumores de cuello uterino, ovario y endometrio, fuertemente vinculados a planes de salud pública preventiva (como el Papanicolaou).
- **C60-C63 (Neoplasias malignas de los órganos genitales masculinos):** Dominado epidemiológicamente por el cáncer de próstata, cuyo manejo varía desde la vigilancia activa hasta la prostatectomía radical.
- **C64-C68 (Neoplasias malignas de las vías urinarias):** Neoplasias renales y de vejiga, que a menudo son diagnosticadas por hematuria y exigen procedimientos urológicos especializados.
- **C69-C72 (Neoplasias malignas del ojo, del encéfalo y de otras partes del sistema nervioso central):** Tumores cerebrales que, por su ubicación, presentan un riesgo neurológico crítico y demandan intervenciones neuroquirúrgicas de alta complejidad.
- **C73-C75 (Neoplasias malignas de la glándula tiroides y de otras glándulas endocrinas):** Tumores que afectan el sistema hormonal, generalmente con tasas de supervivencia altas si se detectan a tiempo.
- **C76-C80 (Neoplasias malignas de sitios mal definidos, secundarios y de sitios no especificados):** Códigos utilizados cuando el tumor primario es desconocido o se trata de una diseminación metastásica generalizada sin origen claro, lo que usualmente indica estados terminales o de diagnóstico tardío.

- **C81-C96 (Neoplasias malignas del tejido linfático, de los órganos hematopoyéticos y de tejidos afines):** Patologías sistémicas como leucemias y linfomas. Al no ser sólidas, su abordaje es predominantemente hematológico y farmacológico.
- **C97 (Neoplasias malignas de sitios múltiples independientes):** Casos clínicos excepcionales donde el paciente presenta dos o más tumores primarios malignos distintos desarrollados de forma simultánea.

Respecto de la localización tumoral, el sistema CIE-10 introduce una distinción topográfica relevante entre localización primaria y localización secundaria (metástasis). Un tumor maligno primario corresponde al sitio original donde se inicia el crecimiento neoplásico, mientras que un tumor secundario representa la diseminación de células malignas hacia otros órganos o tejidos, lo que implica un estadio más avanzado de la enfermedad (Organización Panamericana de la Salud (OPS) y Organización Mundial de la Salud (OMS) (2018)).

Esta diferenciación clínica constituye la base sobre la cual los sistemas de clasificación hospitalaria, como el estándar GRD, asignan en cada episodio hospitalario un diagnóstico principal (motivo central de ingreso) y diagnósticos secundarios (comorbilidades o metástasis), los cuales interactúan directamente para determinar la severidad del episodio, el riesgo de mortalidad y el nivel de intervenciones terapéuticas o quirúrgicas requeridas (Departamento de Estadísticas e Información de Salud (DEIS) (2018)).

2.2 SISTEMA DE GRUPOS RELACIONADOS POR EL DIAGNÓSTICO (GRD)

2.2.1 Origen y evolución del modelo GRD en Chile

El sistema de Grupos Relacionados por el Diagnóstico (GRD) fue desarrollado originalmente por investigadores de la Universidad de Yale durante la década de 1970, con el objetivo de clasificar los episodios de hospitalización en categorías clínicamente coherentes y con un consumo de recursos homogéneo, relacionando así la complejidad clínica de un hospital con su utilización de recursos. Su adopción a nivel internacional transformó la gestión sanitaria, permitiendo a los hospitales transitar desde modelos presupuestarios basados en promedios históricos hacia esquemas de financiamiento sustentados en la complejidad real de los casos atendidos. En síntesis, los GRD constituyen un sistema de clasificación de hospitalizaciones que permite analizar y caracterizar los distintos tipos de pacientes atendidos (Cid et al. (2024)).

En Chile, la implementación del sistema GRD comenzó mediante una serie de pilotos

aislados orientados principalmente a la medición de la eficiencia clínica. En particular, durante el año 2001 los GRD fueron introducidos en un contexto académico; posteriormente, el Fondo Nacional de Salud (FONASA) comenzó a utilizarlos en el sector privado y desarrolló un piloto en el sector público en 2015. Tras casi dos décadas de avances y ajustes institucionales, en el año 2020 FONASA instauró formalmente el programa GRD como mecanismo oficial de pago para la atención cerrada en los establecimientos de la red pública (Cid et al. (2024)).

Posteriormente, durante el año 2023, mediante la Ley de Presupuestos del Sector Público, FONASA consolidó y amplió el financiamiento basado en GRD a 68 hospitales de alta complejidad, incorporando tres nuevos hospitales al programa. Estos cambios obligaron a los centros de salud a registrar con mayor precisión sus diagnósticos y procedimientos, con el fin de asegurar una correcta asignación de los recursos estatales (Fondo Nacional de Salud (FONASA) (2023); Metamodelo (2024a)).

2.2.2 Estructura de datos y componentes del estándar IR-GRD

Con el propósito de garantizar comparabilidad internacional y precisión clínica, Chile adoptó el estándar internacional conocido como International Refined Diagnosis Related Groups (IR-GRD), desarrollado por 3M Health Information Systems. Este modelo se basa en la clasificación de episodios hospitalarios en grupos clínicamente coherentes y con consumo homogéneo de recursos, utilizando variables demográficas, clínicas y hospitalarias para asignar cada episodio a un grupo específico. En particular, el principal insumo del algoritmo agrupador IR-GRD corresponde al Conjunto Mínimo Básico de Datos (CMBD) de hospitalización, definido como un registro estructurado que resume la información clínica y administrativa esencial del paciente al momento del egreso hospitalario (Sigesa (2019b)).

Técnicamente, el CMBD se compone de múltiples dimensiones de variables, entre las cuales destacan:

- **Variables demográficas y administrativas:** incluyen la edad, sexo, previsión de salud y comuna de residencia del paciente.
- **Variables clínicas (CIE-10):** comprenden el diagnóstico principal (motivo principal del ingreso) y los diagnósticos secundarios (comorbilidades, metástasis o complicaciones), codificados según el sistema CIE-10.
- **Indicadores de eficiencia:** incluyen los días de estadía (tiempo de hospitalización) y el peso relativo del GRD que corresponde a un valor numérico que refleja el costo esperado del episodio en comparación con el caso hospitalario promedio.

A partir de estas variables de entrada, el software agrupador procesa los episodios hospitalarios y genera dos índices categóricos fundamentales que operan como variables de salida u objetivo:

- **Nivel de severidad o gravedad (GRS-S):** representa el nivel de descompensación o pérdida funcional de un órgano o sistema, considerando las características del paciente, los diagnósticos secundarios asociados al episodio y los procedimientos realizados. Este índice se encuentra estratificado en cuatro niveles: menor (1), moderado (2), mayor (3) y extremo (4) (Sociedad Castellano-Manchega de Patología Respiratoria (SOCAMPAR) (2023)).
- **Riesgo de mortalidad (GRD-M):** corresponde a un indicador del riesgo de fallecimiento del paciente durante el episodio hospitalario, entendido como un índice descriptivo y no como un predictor clínico directo. Este índice se clasifica en los mismos cuatro niveles estadísticos utilizados para la severidad (Sociedad Castellano-Manchega de Patología Respiratoria (SOCAMPAR) (2023)).

2.2.3 Relevancia de los procedimientos médicos y quirúrgicos en la gestión hospitalaria

Además de los diagnósticos clínicos, el sistema GRD incorpora la codificación de los procedimientos médicos e intervenciones terapéuticas, diagnósticas o quirúrgicas realizadas durante la hospitalización del paciente, utilizando el sistema CIE-9-MC (Clasificación Internacional de Enfermedades, 9ª revisión, Modificación Clínica) (Ministerio de Salud de El Salvador (2024)).

Respecto a la relevancia de los procedimientos, estos son fundamentales para capturar adecuadamente la complejidad clínica de los episodios hospitalarios. Por ejemplo, en pacientes oncológicos, dependiendo de la tipología y estadiaje del cáncer, pueden requerirse intervenciones específicas como resecciones tumorales, biopsias estereotáxicas, procedimientos reconstructivos o terapias invasivas. En consecuencia, los procedimientos reflejan las acciones terapéuticas concretas que determinan directamente mayores niveles de severidad, estancias hospitalarias prolongadas y un elevado consumo de recursos, dimensiones que precisamente busca gestionar y caracterizar el sistema GRD.

2.3 MARCO TEÓRICO METODOLÓGICO Y COMPUTACIONAL

2.3.1 Remuestreo estadístico y robustez mediante Bootstrapping

El desbalance masivo de clases corresponde a un problema frecuente en bases de datos poblacionales de salud pública, donde la proporción de episodios que presentan una determinada patología (como cáncer) frente a aquellos que no la presentan es significativamente asimétrica. Para abordar un desafío de esta naturaleza sin incurrir en sesgos deterministas ni perder variabilidad clínica, existen técnicas de remuestreo computacional no paramétrico, como el *bootstrapping*, introducido por Bradley Efron en 1979 (Efron (1979)).

La técnica de remuestreo mediante *bootstrapping* consiste en extraer aleatoriamente B muestras repetidas de tamaño N , permitiendo el reemplazo de las observaciones; es decir, una misma observación puede ser seleccionada múltiples veces en distintas muestras. Matemáticamente, si se dispone de un conjunto original de datos $Z = (z_1, z_2, \dots, z_n)$, una muestra *bootstrap* Z^{*b} contendrá elementos seleccionados desde Z con probabilidad $1/n$ (Efron (1979); Hastie et al. (2009)).

En el contexto específico de esta investigación, el remuestreo se utiliza para forzar artificialmente el balance de clases, por ejemplo, emparejando aleatoriamente una determinada cantidad de pacientes oncológicos con pacientes sin cáncer en cada iteración. Al repetir este proceso sobre cientos de submuestras aleatorias, el algoritmo reduce el sesgo inherente asociado a una única partición de los datos. La justificación matemática de este enfoque metodológico reside en el Teorema del Límite Central (TLC) y en la Ley de los Grandes Números, los cuales establecen que, a medida que el número de iteraciones *bootstrap* B tiende al infinito, la distribución empírica de la importancia de las características converge hacia la verdadera distribución poblacional subyacente. Esto asegura que las variables finalmente seleccionadas correspondan a aquellas que demuestran persistencia estadística estructural, aislando el ruido estocástico y garantizando que los perfiles operativos identificados mediante selección de características no sean un artefacto del azar presente en una muestra aislada (Hastie et al. (2009)).

2.3.2 Modelos de aprendizaje automático y algoritmos de ensamble

Para clasificar la información y extraer relaciones multivariadas entre las características de los datos GRD, este estudio emplea tres arquitecturas algorítmicas fundamentales: un modelo paramétrico utilizado como línea base (Regresión Logística) y dos algoritmos avanzados de ensamble basados en árboles de decisión, específicamente *Random Forest* y *XGBoost* (*eXtreme Gradient Boosting*) (Hastie et al. (2009)).

La **regresión logística** se seleccionó como modelo estadístico base debido a su elevada interpretabilidad inherente. Este algoritmo estima la probabilidad de que una instancia hospitalaria pertenezca a una determinada clase objetivo, como la condición de fallecido en el *target* de mortalidad ($Y = 1$), dada una matriz de características X , utilizando la función sigmoide definida en la Ecuación 2.1:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (2.1)$$

Donde β_0 corresponde al intercepto y β_i representa los coeficientes que cuantifican la influencia de cada variable x_i sobre los *log-odds* de la variable objetivo (por ejemplo, mortalidad). El ajuste óptimo de estos coeficientes se obtiene mediante la minimización de la función de pérdida de entropía cruzada binaria o *Log-Loss*, expresada en la Ecuación 2.2, donde y_k representa la etiqueta real del episodio hospitalario k y $\hat{y}_k = P(Y = 1|X_k)$ corresponde a la probabilidad estimada por el modelo para dicha instancia:

$$\mathcal{L}(\beta) = -\frac{1}{N} \sum_{k=1}^N [y_k \ln(\hat{y}_k) + (1 - y_k) \ln(1 - \hat{y}_k)] \quad (2.2)$$

Para operar de manera estable en entornos de alta dimensionalidad y controlar la multicolinealidad estructural característica de las bases de datos de salud, la función de pérdida base se optimiza mediante técnicas de regularización elástica (*Elastic Net*). Esta aproximación penaliza la magnitud de los coeficientes combinando simultáneamente regularización L1 (*Lasso*) y L2 (*Ridge*), transformando la función objetivo según la Ecuación 2.3:

$$\mathcal{L}_{\text{reg}}(\beta) = \mathcal{L}(\beta) + \lambda \left[\alpha \sum_{j=1}^m |\beta_j| + \frac{1 - \alpha}{2} \sum_{j=1}^m \beta_j^2 \right] \quad (2.3)$$

En esta fórmula, el hiperparámetro λ controla la intensidad global de la penalización aplicada al modelo, mientras que el parámetro de mezcla $\alpha \in [0, 1]$ regula la proporción relativa entre ambos tipos de regularización. Estos términos poseen distintas implicancias operativas sobre el comportamiento de los coeficientes (Hastie et al. (2009)):

- **Penalización L1 o Lasso ($\alpha = 1$):** añade un costo proporcional al valor absoluto de los coeficientes. Debido a la geometría de sus contornos normativos en forma de diamante, este operador induce dispersión (*sparsity*), forzando que los coeficientes de variables redundantes o con baja asociación estadística se reduzcan exactamente a cero. En la práctica, este comportamiento permite que el algoritmo actúe automáticamente como un selector de características descriptivas.
- **Penalización L2 o Ridge ($\alpha = 0$):** añade un costo proporcional al cuadrado de la magnitud de los coeficientes. Sus contornos elípticos contraen uniformemente los pesos hacia cero, pero sin anularlos completamente, como ocurre en la regularización L1. Esta penalización resulta especialmente efectiva para manejar grupos de variables correlacionadas, como diagnósticos concurrentes codificados, distribuyendo el peso de manera más equilibrada entre ellas.

Random Forest corresponde a un algoritmo de ensamble robusto basado en la técnica de agregación por arranque (*Bagging* o *Bootstrap Aggregating*), donde se construye un conjunto de B árboles de decisión profundos de manera independiente $T_1(X), T_2(X), \dots, T_B(X)$. Además, para garantizar la descorrelación estructural entre los árboles y evitar que aprendan patrones idénticos, en cada división de nodo (*split*) el algoritmo evalúa únicamente un subconjunto aleatorio de características extraídas desde la matriz global de datos. Finalmente, la predicción del ensamble para un problema de clasificación binaria ($Y \in \{0, 1\}$) se obtiene formalmente mediante votación por mayoría, descrita en la Ecuación 2.4:

$$\hat{Y}(X) = \arg \max_{c \in \{0, 1\}} \sum_{b=1}^B \mathbb{I}(C_b(X) = c) \quad (2.4)$$

Donde $C_b(X)$ representa la predicción de clase emitida por el árbol número b e $\mathbb{I}(\cdot)$ corresponde a la función indicadora, la cual toma el valor de 1 cuando la condición interna se cumple y 0 en caso contrario. La naturaleza no paramétrica de este algoritmo le permite modelar interacciones altamente no lineales sin requerir transformaciones previas de los datos, además de presentar una elevada resistencia al sobreajuste (*overfitting*) debido al promedio estocástico de sus componentes (Hastie et al. (2009)).

XGBoost (eXtreme Gradient Boosting), a diferencia del enfoque basado en *bagging*, utiliza la técnica de *boosting*, la cual consiste en construir árboles de decisión de manera secuencial y aditiva. Cada nuevo árbol, denominado aprendiz débil, se optimiza específicamente para corregir los errores residuales (gradientes) calculados en las etapas anteriores; es decir, los errores cometidos por el conjunto previo de árboles. Matemáticamente, XGBoost minimiza directamente una función objetivo regularizada $\mathcal{L}$ en cada iteración k , equilibrando el ajuste

empírico con la complejidad estructural de cada árbol f_k , tal como se expresa en la Ecuación 2.5:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (2.5)$$

Donde $l(\cdot)$ representa la función de pérdida diferenciable (por ejemplo, entropía cruzada para clasificación binaria), encargada de medir la discrepancia entre la etiqueta real y_i y la estimación $\hat{y}_i$. Por otro lado, el término diferenciador clave del algoritmo corresponde al penalizador de complejidad topológica $\Omega(f_k)$, el cual restringe explícitamente el tamaño de la estructura para mitigar el sobreajuste. Este término de regularización se define mediante la Ecuación 2.6:

En donde $l(\cdot)$ representa la función de pérdida diferenciable (como la entropía cruzada para variables binarias) que mide la discrepancia entre la etiqueta real y_i y la estimación $\hat{y}_i$. Por otro lado, el término diferenciador clave del algoritmo es el penalizador de complejidad topológica $\Omega(f_k)$, el cual restringe explícitamente el tamaño de la estructura para mitigar el sobreajuste. Este término de regularización se define específicamente en la Ecuación 2.6 (Chen & Guestrin (2016)):

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.6)$$

En esta expresión, T corresponde al número total de hojas presentes en el árbol f_k , mientras que w_j representa el peso asociado a cada hoja j . El hiperparámetro γ actúa como una penalización sobre el número de divisiones del árbol, funcionando como un umbral mínimo de ganancia requerido para permitir una nueva partición. En paralelo, el parámetro λ aplica regularización L2 (*Ridge*) sobre los pesos de las hojas, suavizando las actualizaciones numéricas individuales. Esta combinación matemática otorga a XGBoost una elevada estabilidad computacional en estructuras tabulares dispersas y una capacidad nativa para manejar desbalances de clases mediante ajuste de gradientes (Chen & Guestrin (2016)).

2.3.3 Inteligencia artificial explicable (XAI) y valores de Shapley (SHAP)

Si bien los modelos de aprendizaje automático avanzados como *Random Forest* y *XGBoost* ofrecen altos rendimientos predictivos en la identificación de patrones no lineales, operan arquitectónicamente como modelos de caja negra (*black-box*), lo que significa que permiten clasificar o predecir un desenlace (como el fallecimiento de pacientes), pero no explican

de forma transparente cómo cada variable de entrada contribuye a esa predicción. Esta falta de interpretabilidad algorítmica dificulta la toma de decisiones clínicas y limita su aporte a la gestión sanitaria pública, donde la transparencia constituye un requisito ético y regulatorio. Para superar esta barrera, la investigación integra la metodología SHAP (*SHapley Additive exPlanations*) Lundberg & Lee (2017).

Este método fue desarrollado por Lundberg y Lee, y traduce los principios de la teoría de juegos cooperativos (introducida por Lloyd Shapley en 1953) al dominio del aprendizaje automático. En esta analogía matemática, la predicción del modelo equivale al pago total del juego, mientras que las características del paciente (como la edad, los procedimientos o los diagnósticos) actúan como jugadores. En este contexto, SHAP calcula la contribución marginal exacta ϕ_i de cada variable evaluando su impacto sobre todas las permutaciones posibles de características, según la Ecuación 2.7:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)] \quad (2.7)$$

En donde F corresponde al conjunto de todas las características, S representa un subconjunto de características que excluye a la variable i (cuya contribución se desea calcular), y $f_x(S)$ corresponde a la predicción del modelo condicionada únicamente a las características presentes en el subconjunto S Lundberg & Lee (2017).

Si se aplica SHAP directamente sobre un problema de clasificación binaria (por ejemplo, fallecido y sobreviviente), el valor SHAP parte de un valor base correspondiente a la prevalencia promedio o probabilidad base estimada por el modelo. A partir de dicho punto, la metodología entrega una atribución direccional transparente:

- **Valores SHAP positivos:** indican que la presencia (o una magnitud elevada) de una variable empuja la predicción del modelo a favor de la Clase 1, atribuyendo estadísticamente el riesgo hacia la presencia de esa clase (por ejemplo, mortalidad).
- **Valores SHAP negativos:** indican que la variable ejerce una contribución inversa, disminuyendo, por ejemplo, la probabilidad de fallecimiento y asociando el perfil clínico del paciente hacia la Clase 0 (pacientes sobrevivientes).

2.4 ESTADO DEL ARTE

2.4.1 Estrategia de búsqueda y selección de estudios

Para la revisión sistemática de la literatura se establecieron dos estrategias diferentes, una búsqueda global en **Scopus** para identificar el estado del arte internacional y una búsqueda local en Chile en **SciELO**.

En primer lugar, se ejecutó una consulta en Scopus para responder las siguientes preguntas de investigación sobre variables, tecnologías y metodologías utilizadas en la caracterización de pacientes oncológicos:

- **Variables y factores asociados:** ¿Qué atributos o variables hospitalarias, administrativas y clínicas (registradas en GRD u otros sistemas de datos hospitalarios) se han utilizado en la literatura para caracterizar pacientes con cáncer, tanto en Chile como a nivel internacional?
- **Tecnologías:** ¿Qué enfoques computacionales (estadística, minería de datos y aprendizaje automático) se han aplicado para caracterizar perfiles de pacientes oncológicos utilizando registros clínicos y administrativos, como datos hospitalarios (por ejemplo, GRD), registros electrónicos o seguros de salud?
- **Metodologías exitosas o existentes:** ¿Qué metodologías han demostrado ser más efectivas para identificar patrones y atributos relevantes en la caracterización del cáncer a partir de registros clínicos u hospitalarios?

Dicha consulta fue la siguiente:

```
1 ("cancer" OR "oncology" OR "neoplasms")
2 AND
3 ("Diagnosis Related Groups" OR DRG OR "hospital discharge data"
4 OR "administrative hospital data" OR "hospital data"
5 OR "electronic health records" OR EHR OR "claims data")
6 AND
7 (attributes OR features OR variables OR "risk factors"
8 OR "clinical profile" OR "patient profiling"
9 OR "patient characterization" OR "clinical characterization")
10 AND
11 ("machine learning" OR "data mining" OR "artificial intelligence"
12 OR "statistical analysis" OR "predictive modeling"
13 OR "risk prediction" OR "pattern recognition" OR "feature selection")
```

De los 182 resultados iniciales, se aplicaron los siguientes filtros, reduciendo la búsqueda a 104 resultados:

- **Año:** 2020–2025
- **Área temática:** Medicina, Informática, Multidisciplinaria y Profesionales de la Salud
- **Tipo de documento:** Artículo y revista
- **Idioma:** Inglés y español

Posteriormente, se aplicó un proceso de selección basado en tres filtros secuenciales para identificar los artículos más relevantes para el objetivo de esta propuesta, a través de la lectura de sus títulos y resúmenes:

1. **Filtro de relevancia central:** Se seleccionaron principalmente artículos que utilizan aprendizaje automático supervisado en oncología con datos análogos a GRD (como datos EHR y administrativos), y se descartaron artículos cuyo enfoque principal no correspondía al aprendizaje automático, como NLP puro o análisis de imágenes y radiomía.
2. **Filtro de alineación de objetivos:** Se priorizaron estudios que predicen resultados similares a los de esta propuesta, como mortalidad, supervivencia, severidad, complicaciones y consumo de recursos o costos.
3. **Filtro de relevancia metodológica:** Se seleccionaron artículos que utilizan técnicas de interpretabilidad como SHAP para crear perfiles de riesgo.

Finalmente, este proceso resultó en la selección de 12 artículos internacionales, los cuales se resumen más adelante en la Tabla 2.1.

En segundo lugar, se ejecutó una búsqueda en SciELO orientada a identificar estudios sobre la aplicación de aprendizaje automático sobre datos GRD en el área de oncología; sin embargo, esta consulta arrojó 0 resultados.

Entonces, con el fin de adoptar un enfoque descriptivo y responder a la necesidad de construir una línea base contextual sólida, se ejecutó una segunda búsqueda ampliada orientada a identificar estudios que, mediante estadística descriptiva o análisis epidemiológico, caracterizaran el cáncer en la población chilena utilizando datos locales. Para ello, se ejecutó la siguiente consulta:

```
1 (TITLE:("cancer" OR "oncologia" OR "tumor" OR "neoplasia"))
2 AND (clínico OR demográfico OR epidemiológico OR "egreso hospitalario" OR "carga de
   enfermedad")
3 AND (Chile OR "población chilena" OR "hospital chileno")
```


De 1583 resultados iniciales, se aplicaron los siguientes filtros, reduciendo la búsqueda a 44 resultados:

- **Año:** 2018–2025
- **País:** Chile, para captar estudios locales.

Tras aplicar los filtros anteriores, se leyeron los resúmenes de los artículos y se aplicaron los siguientes criterios de selección final para asegurar su relevancia con el problema de los GRD:

- **Enfoque poblacional o de cohorte:** Se seleccionaron estudios con muestras significativas ($N > 100$) o estadísticas nacionales (DEIS), descartando reportes de casos únicos que no permiten generalizar perfiles.
- **Contexto local y territorial:** Se incluyeron investigaciones de hospitales públicos chilenos (Temuco y Chillán) para validar variables territoriales, como la ruralidad y el tipo de establecimiento.
- **Variables presentes en GRD:** Se seleccionaron estudios que analizaron variables presentes en GRD, como edad, sexo y mortalidad.

Finalmente, en la búsqueda de SciELO se seleccionaron 4 artículos fundamentales, los cuales constituyen la evidencia base sobre la carga demográfica y hospitalaria del cáncer en Chile, indicados más adelante en la Tabla 2.2.

2.4.2 Estudios sobre caracterización de cohortes oncológicas mediante aprendizaje automático e inteligencia artificial explicable

En la literatura se identifican dos principales corrientes metodológicas en el uso de datos sanitarios en oncología. La primera corresponde a la predicción clínica mediante aprendizaje automático e inteligencia artificial, donde se ha demostrado que los registros clínicos y administrativos, análogos a los GRD (como los Registros de Salud Electrónicos, EHR), contienen patrones latentes capaces de predecir desenlaces como mortalidad, supervivencia, duración de la hospitalización y readmisión, utilizando algoritmos como Random Forest, XGBoost y regresión LASSO (Zhou et al. (2024); Hwang et al. (2023); Chen et al. (2021)).

Para enfrentar el desbalance de clases, se aplicaron técnicas de remuestreo, como submuestreo o SMOTE, que consiste en crear muestras sintéticas de la clase minoritaria interpolando entre ejemplos existentes (Lai et al. (2022); Jacobson et al. (2022); Alsinglawi

et al. (2022)). Además, se emplearon validaciones temporales o prospectivas, separando el conjunto de entrenamiento y prueba por fecha para evitar fugas de datos (uso de información en el entrenamiento que no estaría disponible en el momento de la predicción). La calibración de los modelos se evaluó mediante la puntuación de Brier, que cuantifica la diferencia cuadrática media entre las probabilidades predichas y los desenlaces observados (Luo et al. (2025); Peterson et al. (2021); Yuan et al. (2021)).

Asimismo, se incorporaron técnicas de interpretabilidad como SHAP, estableciendo un estándar de explicabilidad dual: global, para caracterizar factores de riesgo a nivel poblacional, y local, para justificar decisiones individuales, cuantificando la influencia de cada variable en las predicciones (Luo et al. (2025); Lai et al. (2022); Yamashita et al. (2022); Li et al. (2020)). Finalmente, estos modelos alcanzaron desempeños moderados y altos, con valores de AUC-ROC entre 0.71 y 0.94, evidenciando una capacidad predictiva superior al azar.

En específico, para esta corriente se tienen los siguientes estudios:

- **Desarrollo y validación de un modelo de aprendizaje automático explicable para predecir el pronóstico en pacientes con sepsis y antecedentes de cáncer ingresados en la unidad de cuidados intensivos:** El objetivo de este estudio fue construir y validar un modelo de aprendizaje automático explicable para predecir la mortalidad intrahospitalaria en pacientes con sepsis y antecedentes de cáncer ingresados en la unidad de cuidados intensivos (UCI). Para ello, se realizó un análisis retrospectivo de 3364 pacientes presentes en los registros de salud electrónicos (EHR) de la base de datos MIMIC-IV, que contiene información de pacientes ingresados en la UCI del hospital Beth Israel Deaconess Medical Center. Como metodología, la variable a predecir fue la mortalidad hospitalaria (como variable binaria); se seleccionaron 11 variables pronósticas clave mediante regresión LASSO y eliminación recursiva de características (RFE); se entrenaron ocho algoritmos de aprendizaje automático, como Random Forest (RF), XGBoost, árbol de decisión (DT) y SVM; y se aplicaron técnicas de interpretabilidad mediante SHAP y gráficos de dependencia parcial (PDPs). Finalmente, Random Forest fue el modelo con mayor precisión predictiva, con un AUC de 0.78 y el menor Brier Score. Además, el análisis de explicabilidad reveló que la característica más influyente para la mortalidad fue la puntuación de gravedad APSIII (que mide la disfunción fisiológica aguda III), junto con la puntuación SOFA, la saturación de oxígeno (SpO_2), y la frecuencia cardíaca y respiratoria (Luo et al. (2025)).
- **Desarrollo de un modelo de IA para predecir el estado de hipoxia y el pronóstico en el cáncer de pulmón de células no pequeñas utilizando datos multimodales:** El objetivo de este estudio fue crear un modelo de inteligencia artificial (IA) para pacientes con cáncer de pulmón de células no pequeñas (NSCLC) que integrara datos multimodales para predecir el estado de hipoxia y la supervivencia general. Como metodología, se utilizaron datos de

452 pacientes provenientes de múltiples cohortes clínicas y bases públicas. En específico, se emplearon datos multimodales que incluyeron registros de salud electrónicos (EHR), características radiómicas de imágenes de tomografía computarizada (TC) y conjuntos de datos genómicos como The Cancer Genome Atlas (TCGA) y Gene Expression Omnibus (GEO). Para la construcción del modelo, los pacientes se clasificaron en grupos de hipoxia alta o baja en función de su expresión génica mediante el método ssGSEA. Posteriormente, se entrenaron modelos específicos para cada tipo de dato: LASSO para las características radiómicas de TC, ssuBERT para extraer información fenotípica estructurada desde textos libres de EHR y una red neuronal profunda (DNN) para integrar las características provenientes de las distintas fuentes de datos. Finalmente, el modelo multimodal obtuvo un AUC promedio de 0.8449, demostrando que la integración transversal de diferentes arquitecturas de datos mejoró sustancialmente la predicción pronóstica frente a enfoques unimodales. Además, se concluyó que niveles elevados de hipoxia se correlacionaban con peores resultados de supervivencia global, y el modelo unimodal con mejor desempeño fue ssuBERT, con un AUC de 0.7662 (Zhou et al. (2024)).

- **Hacia la predicción de la rehospitalización a los 30 días en pacientes oncológicos: identificación de factores de riesgo oportunos y accionables:** El objetivo de este estudio fue desarrollar modelos de predicción de readmisión hospitalaria no planificada a 30 días para pacientes oncológicos (variable binaria), con el fin de identificar intervenciones oportunas y accionables. Para ello, se utilizaron datos de registros de salud electrónicos (EHR) de una cohorte retrospectiva de 2460 pacientes oncológicos del centro de tratamiento Ann B. Barshinger Cancer Institute (ABBCI). Como metodología, se estableció un pipeline de trabajo que incluyó el preprocesamiento, la selección de características y el entrenamiento de 11 algoritmos de aprendizaje automático, como Random Forest, XGBoost y LGB; además, se utilizó Optuna (optimización bayesiana) para optimizar los hiperparámetros de los modelos, junto con métricas de evaluación como ROC y AUPRC, validación cruzada anidada de 10 pliegues y SHAP para la identificación de los factores de riesgo más importantes para las predicciones. Cabe destacar que los múltiples clasificadores de ML se entrenaron comparando el rendimiento al utilizar todas las variables de la visita clínica frente a utilizar solo aquellas disponibles durante las primeras 48 horas de admisión. Finalmente, el modelo Light Gradient Boosting (LGB) obtuvo el mejor rendimiento global (con un AUROC de 0.711) utilizando todas las características, mientras que Random Forest presentó el mejor desempeño utilizando datos limitados a las primeras 48 horas (con un AUROC de 0.684). Dentro de los predictores más influyentes de la readmisión hospitalaria se encontraron factores de riesgo dinámicos, como albúmina baja y frecuencia cardíaca elevada al alta, además del cambio de peso anual, síntomas de depresión y el nivel de ingresos según

código postal. Asimismo, se demostró que el aprendizaje automático puede igualar o superar modelos propietarios existentes y ofrecer perspectivas clínicas y socioeconómicas accionables de forma temprana (Hwang et al. (2023)).

- **Predicción dinámica de metástasis en ganglios linfáticos laterales mediante aprendizaje automático en pacientes con cáncer papilar de tiroides:** El objetivo de este estudio fue desarrollar un modelo de aprendizaje automático basado en la web para predecir dinámicamente la metástasis en ganglios linfáticos laterales (LLNM) en pacientes con cáncer papilar de tiroides (PTC) antes de la cirugía. Para ello, se analizaron retrospectivamente datos de ultrasonido y EHR clínicos de un centro médico en China (First Medical Centre of the Chinese PLA General Hospital), con una cohorte de 1815 pacientes. Como metodología, se aplicó regresión LASSO para seleccionar las 30 características más relevantes para construir los modelos; se entrenaron 6 algoritmos de aprendizaje automático, incluyendo XGBoost, Random Forest, árbol de decisión, SVM, red neuronal y KNN, y se compararon con un nomograma de regresión logística tradicional. Cada modelo fue evaluado en función de su precisión, sensibilidad, AUC y DCA; además, se utilizó SHAP para identificar las características más influyentes en las predicciones del modelo. Finalmente, el modelo Random Forest demostró ser el más robusto, con un AUC de 0.8 y una sensibilidad de 0.69. SHAP identificó que las características más influyentes para predecir LLNM fueron el tamaño del tumor, la edad, la microcalcificación, el tamaño de los ganglios linfáticos y la ubicación del tumor. Finalmente, la investigación entregó una herramienta accesible para facilitar la estratificación de riesgos a nivel individual (Lai et al. (2022)).
- **Comparación de la regresión logística con algoritmos de aprendizaje automático para la predicción del riesgo de cáncer gástrico en flujos de datos clínicos reales:** El objetivo de este estudio fue comparar la eficacia de la regresión logística (LR) frente a algoritmos de aprendizaje automático (ML) para predecir el riesgo de cáncer gástrico no cardial (NCGC) utilizando datos clínicos reales. Para ello, se analizaron retrospectivamente datos de registros de salud electrónicos (EHR) de dos sistemas de salud académicos en Estados Unidos: Stanford y la Universidad de Washington (UW), con una cohorte total de 59,000 pacientes. Como metodología, se comparó el modelo clásico de regresión logística (basado en factores de riesgo preestablecidos como histología, infección previa por *Helicobacter pylori*, raza, etnia, tabaquismo y anemia) con cuatro algoritmos de aprendizaje automático: Random Forest, SVM, LASSO penalizado y KNN (que seleccionaron variables de manera agnóstica), utilizando métricas de evaluación como exactitud, sensibilidad, especificidad y curvas AUC/ROC. Finalmente, el rendimiento del modelo de regresión logística no fue inferior al de los modelos de ML en la validación externa, logrando una precisión del 72.4%. Además, en validaciones tanto internas como externas, la regresión

logística mostró una precisión, sensibilidad y especificidad comparables a los modelos de aprendizaje automático optimizados. Por ende, el estudio concluyó que los modelos estadísticos clásicos contruidos sobre variables predictoras robustas y seleccionadas manualmente no son inferiores a los modelos de aprendizaje automático impulsados por datos masivos para la predicción del riesgo de cáncer gástrico. Por otra parte, dentro de los modelos de ML, el modelo KNN mostró una mayor precisión y especificidad (Huang et al. (2022)).

- **Factores de riesgo asociados con eventos relacionados con el esqueleto tras la interrupción del tratamiento con denosumab en pacientes con metástasis óseas de tumores sólidos: un enfoque de aprendizaje automático en el mundo real:** El objetivo de este estudio fue identificar los factores de riesgo asociados a la aparición de eventos relacionados con el esqueleto (SREs) tras la interrupción del tratamiento con denosumab (un anticuerpo monoclonal) en pacientes con metástasis óseas derivadas de tumores sólidos. Para ello, se analizaron retrospectivamente datos de registros de salud electrónicos (EHR) de Optum PanTher, considerando pacientes diagnosticados entre enero de 2007 y septiembre de 2019. Como metodología, se utilizó el algoritmo XGBoost para las predicciones; se gestionó el desbalance de clases mediante técnicas de sobremuestreo, submuestreo y penalización. Además, se ajustaron los hiperparámetros mediante optimización bayesiana con validación cruzada de 5 pliegues, y el rendimiento del modelo se evaluó mediante las métricas de precisión, sensibilidad, AUROC y especificidad. Para la interpretabilidad, se aplicó SHAP para evaluar sin sesgos la importancia de más de 60 variables predictoras. Como resultado, se obtuvo que el modelo XGBoost alcanzó un AUROC de 77% en la predicción de SREs, y dentro de los factores de riesgo más influyentes para la detección de SREs se encontraron los SREs previos, una menor duración del tratamiento con denosumab, la edad joven y la presencia de cáncer de próstata. Finalmente, este estudio demostró que el aprendizaje automático puede guiar las decisiones sobre la continuidad del tratamiento con denosumab para mejorar los desenlaces del paciente (Jacobson et al. (2022)).
- **Aprendizaje automático para la clasificación del estado postoperatorio del paciente utilizando datos médicos estandarizados:** Este estudio tuvo como objetivo identificar factores de riesgo e interacciones temporales que contribuyen a una hospitalización postoperatoria prolongada en pacientes con cáncer de pulmón. Para ello, el estudio empleó Datos del Mundo Real (RWD) estandarizados, provenientes de los sistemas Diagnosis Procedure Combination (DPC) y vías clínicas (Clinical Pathway o CP). Como metodología, se utilizaron métodos de agrupamiento o *clustering* (algoritmo CLUTO) para agrupar pacientes según patrones de ítems DPC, en conjunto con la construcción de

modelos de aprendizaje automático. Además, se aplicó la técnica SHAP para cuantificar la contribución de cada variable a la predicción de hospitalización prolongada, junto con un gráfico dirigido para explorar las relaciones temporales entre las variables que conducen a hospitalizaciones largas en vez de cortas. Como resultados, el modelo identificó que el factor de riesgo más influyente en la hospitalización prolongada fue la varianza de estreñimiento (en POD1-4), y el *clustering* agrupó variables como tabaquismo, obesidad, estado respiratorio y estreñimiento, por un lado, y el manejo de drenajes, heridas y goteo, por otro. Finalmente, este estudio demostró que la minería de datos sobre registros médicos estandarizados permite revelar vías causales que apoyan la toma de decisiones clínicas tempranas (Yamashita et al. (2022)).

- **Aprendizaje automático aplicado a los registros electrónicos de salud: identificación de pacientes de quimioterapia con alto riesgo de visitas evitables a urgencias e ingresos hospitalarios:** Este estudio tuvo como objetivo predecir el riesgo de uso prevenible de cuidados agudos (ACU), como visitas a urgencias o ingresos hospitalarios no planificados, en pacientes oncológicos que están iniciando quimioterapia. Para ello, se analizaron datos estructurados de registros de salud electrónicos (EHR) generados antes del inicio de la quimioterapia en pacientes adultos tratados en sitios comunitarios afiliados entre enero de 2013 y julio de 2019. Como metodología, se entrenaron, con información generada antes de iniciar el tratamiento, nueve modelos de aprendizaje automático, incluyendo LASSO, Random Forest, Ridge, Elastic Net, redes neuronales perceptrón multicapa (MLP), LightGBM, SVM, KNN y un modelo de votación ensamblado. Como resultado, el modelo LASSO obtuvo el mejor rendimiento predictivo a 180 días, con un AUROC de 0.783. Además, dentro de las variables clave seleccionadas por el modelo LASSO se encontraban hospitalizaciones previas, diagnóstico de depresión, saturación de oxígeno y pulso, entre otras. Finalmente, este estudio validó que los modelos de aprendizaje automático basados en EHR integrales pueden identificar eficazmente a los pacientes en riesgo para focalizar intervenciones preventivas (Peterson et al. (2021)).
- **Rendimiento de un algoritmo de aprendizaje automático que utiliza datos de registros médicos electrónicos para identificar y estimar la supervivencia en una cohorte longitudinal de pacientes con cáncer de pulmón:** El objetivo de este estudio consistió en investigar la viabilidad de ensamblar una cohorte clínica longitudinal de cáncer de pulmón a partir de datos de registros médicos electrónicos (EHR) mediante aprendizaje automático y utilizarla para desarrollar un modelo pronóstico de supervivencia. Para ello, se utilizaron registros de más de 76,000 pacientes del sistema de salud Mass General Brigham (MGB) desde julio de 1988 hasta octubre de 2018. Como metodología, se utilizó el algoritmo PheCAP para fenotipado, empleando dentro de este los métodos SAFE (para la selección

de características) y LASSO (para la clasificación principal a partir de las características seleccionadas por SAFE). Además, se aplicaron herramientas de Procesamiento de Lenguaje Natural (NLP) para extraer datos clínicos de textos libres escritos por médicos (datos no estructurados). En específico, se utilizaron los algoritmos NICE (desarrollado por los propios investigadores) y EXTEND (para extraer datos numéricos específicos, como el índice de masa corporal, IMC). Asimismo, para predecir la supervivencia de los pacientes, se utilizaron algoritmos de regresión de Cox penalizada y penalización MCP para seleccionar solo las variables más importantes en la predicción de la supervivencia global a 1, 2, 3, 4 y 5 años. Como resultados, el algoritmo identificó a 42,069 pacientes con cáncer de pulmón, logrando un valor predictivo positivo (VPP) del 94.4% y un AUROC de 0.927. Además, el modelo pronóstico de supervivencia basado en Cox obtuvo un AUROC de 0.828 para la predicción a 1 año y de 0.812 para la predicción a 5 años. Finalmente, este estudio demostró que los EHR proporcionan una alta fidelidad para extraer información compleja y predecir resultados a largo plazo (Yuan et al. (2021)).

- **Modelo de predicción de datos clínicos para identificar pacientes con cáncer de páncreas en etapa temprana:** El objetivo de este estudio fue evaluar un modelo de aprendizaje automático para identificar pacientes con cáncer de páncreas en etapas tempranas (ESPC), basándose exclusivamente en datos clínicos rutinarios alojados en registros médicos electrónicos (EHR). Para ello, se extrajeron datos de la base de datos Optum (de Estados Unidos), la cual contiene registros diagnósticos de pacientes entre 2009 y 2017, donde 3322 presentaban cáncer de páncreas en etapa temprana (ESPC), definidos por haber recibido cirugía pancreática mayor, y 25,908 presentaban cáncer de páncreas en etapa tardía (LSPC). Como metodología, se construyó y optimizó un modelo predictivo utilizando XGBoost, y se ajustaron los hiperparámetros mediante *Grid Search* y validación cruzada de 5 pliegues. Como resultado, el modelo XGBoost logró distinguir los casos con un AUC de 0.84. Además, el algoritmo demostró la capacidad de identificar el 58% de los casos de cáncer de páncreas diagnosticados en etapa tardía (LSPC) hasta 24 meses antes del diagnóstico clínico formal, con un 60% de sensibilidad, lo que resalta el potencial del aprendizaje automático para el diagnóstico temprano y la reducción de la mortalidad en neoplasias agresivas como el cáncer de páncreas (Chen et al. (2021)).
- **Un modelo multicéntrico de bosque aleatorio para la predicción eficaz del pronóstico en una red de investigación clínica colaborativa:** El objetivo de este estudio fue proponer un modelo de aprendizaje automático basado en Random Forest (RF) multicéntrico para la predicción de pronósticos (supervivencia a 5 años) en pacientes con cáncer colorrectal (CRC), permitiendo la minería de datos clínicos federados a partir de bases de datos particionadas horizontalmente, garantizando la privacidad de los pacientes sin necesidad

de compartir datos crudos y sensibles. Para ello, se utilizaron registros provenientes de la base de datos SEER (de Estados Unidos) y datos del hospital SAHZU (de China). Como metodología, el estudio desarrolló un enfoque de mejora de datos basado en Redes Generativas Antagónicas con privacidad diferencial (DPGAN) para generar datos sintéticos locales. Posteriormente, se evaluaron los modelos bajo diferentes niveles de heterogeneidad institucional y se comparó el modelo multicéntrico de Random Forest con uno entrenado de forma centralizada y con otros clasificadores clásicos, como regresión logística, SVM y redes neuronales. Adicionalmente, se comparó con un modelo de estadificación TNM como línea base clínica; se implementó un método de ranking de importancia de variables basado en la impureza de Gini y se utilizaron métricas de evaluación como AUC (ROC), exactitud, sensibilidad, especificidad y AUPRC. Como resultados, el modelo multicéntrico de Random Forest obtuvo un mejor rendimiento tanto en la validación cruzada interna (AUC de 0.875 con los datos SEER) como en la validación externa (AUC de 0.852 con los datos de SAHZU), mostrando un desempeño superior al de la regresión logística (AUC de 0.835) y al modelo de estadificación TNM (AUC de 0.771). Finalmente, el procedimiento de selección de características demostró ser efectivo para simplificar el modelo sin perder exactitud, concluyendo que este enfoque ofrece una técnica práctica y segura para construir modelos pronósticos robustos en redes de investigación oncológica colaborativas (Li et al. (2020)).

- **Un marco de aprendizaje automático explicable para la predicción de la duración de la estancia hospitalaria en pacientes con cáncer de pulmón:** El objetivo de este estudio fue desarrollar un marco de trabajo de aprendizaje automático explicable para predecir el tiempo de estancia hospitalaria (LOS) de pacientes con cáncer de pulmón ingresados en la unidad de cuidados intensivos (UCI), abordando el desafío del desbalance de clases en los registros de salud electrónicos (EHR). Para ello, se analizó la base de datos pública Medical Information Mart for Intensive Care (MIMIC-III), proveniente de pacientes adultos que estuvieron en la UCI del hospital Beth Israel Deaconess Medical Center (BIDMC), en Massachusetts, Estados Unidos, entre 2001 y 2012. Como metodología, se estructuró el problema predictivo como una clasificación binaria (estancia corta versus estancia larga) y se entrenaron modelos como Random Forest (RF), XGBoost y regresión logística. Para optimizar el entrenamiento, se aplicaron métodos de selección de variables (significancia clínica y eliminación recursiva de características, RFE) y se evaluaron seis técnicas de balanceo de clases, incluyendo sobremuestreo (SMOTE, ADASYN), submuestreo (ENN, TomekLinks) y métodos combinados (SMOTE-ENN, SMOTETomek). Para la evaluación de los modelos se utilizó validación cruzada de 10 iteraciones (*10-fold cross-validation*) y métricas de sensibilidad, especificidad, AUC e *Index Balanced Accuracy* (IBA). Por

último, se aplicó SHAP para la interpretabilidad clínica de las predicciones. Como resultado, el clasificador Random Forest demostró un rendimiento superior y resistente a variaciones en la selección de características. Las técnicas de sobremuestreo obtuvieron los mejores resultados predictivos, donde ADASYN y SMOTE alcanzaron un Área Bajo la Curva (AUC) de 100% y 98%, respectivamente. Además, el análisis SHAP identificó que las características más influyentes para predecir la estancia hospitalaria fueron la temperatura, la admisión por emergencia, la glucosa, las plaquetas y la frecuencia respiratoria. Finalmente, se concluyó que la integración del algoritmo SMOTE con Random Forest y SHAP constituye una herramienta valiosa para apoyar a gestores de camas en la optimización de los recursos de la UCI (Alsinglawi et al. (2022)).

Cabe mencionar que, en la Tabla 2.1 se presentan los resúmenes de cada uno de los artículos internacionales seleccionados sobre la caracterización de cohortes oncológicas mediante aprendizaje automático e inteligencia artificial explicable.

2.4.3 Caracterización de cohortes oncológicas mediante análisis epidemiológico y estadís-

tica descriptiva

La segunda corriente corresponde a la caracterización epidemiológica y estadística descriptiva tradicional, que, mediante medidas de tendencia central, dispersión y distribuciones de frecuencia, permitió identificar grupos de riesgo en cohortes chilenas, como una mayor incidencia de cáncer de pulmón en hombres fumadores (Orrego et al. (2025)), el predominio de fallecimientos por cáncer oral y orofaríngeo en hombres mayores de 75 años (Ortega-Ceavichay et al. (2023)), una mayor incidencia de cáncer de tiroides en mujeres (Rubio et al. (2021)) y un aumento del 109% en muertes por cáncer entre 1986 y 2016, proyectándose como una potencial causa de muerte en Chile (Parra-Soto et al. (2020)). Sin embargo, estos estudios se limitan a análisis descriptivos de centros médicos específicos y no modelan interacciones complejas (no lineales) entre variables, como la variabilidad en estancias hospitalarias y costos de atención (Wodchis et al. (2016)). Además, presentan sesgos ambientales, como la exposición a leña en la zona sur de Chile (Temuco) (Orrego et al. (2025)).

Por ende, la brecha identificada radica en la ausencia de metodologías que integren los registros oncológicos GRD con técnicas de aprendizaje automático supervisado explicable, capaces de transformar esta información en conocimiento accionable mediante perfiles que revelen los factores influyentes en las predicciones.

En específico, para esta corriente se tienen los siguientes estudios:

Tabla 2.1: Resumen de estudios sobre caracterización de cohortes oncológicas mediante aprendizaje automático e inteligencia artificial explicable.

Estudio	Objetivo principal	Datos y metodología	Hallazgos principales
Luo et al. (2025)	Predecir la mortalidad intrahospitalaria en pacientes con sepsis y antecedentes de cáncer en la UCI.	Datos: MIMIC-IV (EHR). Métodos: LASSO, RFE, 8 modelos ML (incluyendo RF y XGBoost), SHAP, PDPs.	RF obtuvo la mayor precisión (AUC 0.78). SHAP identificó las puntuaciones APSIII, SOFA y SpO ₂ como los predictores más influyentes.
Zhou et al. (2024)	Predecir el estado de hipoxia y la supervivencia global en cáncer de pulmón (NSCLC).	Datos: Multimodales (EHR, TC radiómica, TCGA, GEO). Métodos: ssGSEA, LASSO, ssuBERT, DNN (Red Neuronal Profunda)	El modelo multimodal superó a los unimodales (AUC 0.8449). Altos niveles de hipoxia se correlacionaron con una peor supervivencia.
Hwang et al. (2023)	Identificar factores de riesgo para predecir la readmisión hospitalaria a 30 días en oncología.	Datos: EHR (ABBCI). Métodos: 11 algoritmos ML, Optuna, validación cruzada anidada, SHAP.	LGB fue el mejor con datos completos (AUROC 0.711); RF destacó con datos de 48h (AUROC 0.684). SHAP: Albúmina baja, pulso y depresión como claves.
Lai et al. (2022)	Predecir dinámicamente la metástasis en ganglios linfáticos laterales (LLNM) en cáncer papilar de tiroides.	Datos: Ultrasonido y EHR clínicos (China). Métodos: LASSO, 6 algoritmos ML, nomograma logístico, SHAP.	F fue el modelo más robusto (AUC 0.80). SHAP reveló que el tamaño del tumor, edad y microcalcificación son factores críticos.
Huang et al. (2022)	Comparar la regresión logística (LR) frente al ML para predecir el riesgo de cáncer gástrico.	Datos: EHR (Stanford, UW). Métodos: LR tradicional vs. ML agnóstico (RF, SVM, LASSO, KNN).	LR no fue inferior al ML (precisión 72.4%), demostrando que los modelos clásicos con variables bien seleccionadas son altamente competitivos.
Jacobson et al. (2022)	Identificar riesgos de eventos relacionados con el esqueleto (SREs) tras interrumpir denosumab.	Datos: EHR (Optum PanTher). Métodos: XGBoost, optimización bayesiana, técnicas de remuestreo, SHAP.	XGBoost alcanzó un AUROC del 77%. Según SHAP: SREs previos, menor duración de tratamiento y cáncer de próstata aumentan el riesgo.
Yamashita et al. (2022)	Identificar interacciones que prolongan la estancia postoperatoria en cáncer de pulmón.	Datos: RWD estandarizados (DPC y vías clínicas). Métodos: Clustering (CLUTO), ML, SHAP, gráficos dirigidos.	La varianza de estreñimiento fue el mayor riesgo de estancia prolongada. El clustering diferenció perfiles respiratorios vs. manejo de heridas.
Peterson et al. (2021)	Predecir el uso prevenible de cuidados agudos (ACU) al iniciar quimioterapia.	Datos: EHR comunitarios. Métodos: 9 modelos ML entrenados con datos previos al tratamiento.	LASSO obtuvo el mejor rendimiento (AUROC 0.783). Hospitalizaciones previas y diagnóstico de depresión fueron predictores clave.
Yuan et al. (2021)	Ensamblar una cohorte longitudinal de cáncer de pulmón desde EHR para estimar supervivencia.	Datos: EHR (Mass General Brigham). Métodos: Algoritmos PheCAP, NLP (NICE, EXTEND), regresión de Cox penalizada.	Identificación de cohorte con VPP del 94.4%. El modelo de Cox estimó la supervivencia a 1 año con un excelente AUROC de 0.828.
Chen et al. (2021)	Identificar pacientes con cáncer de páncreas en etapas tempranas mediante datos rutinarios.	Datos: EHR (Optum). Métodos: XGBoost, Grid Search, validación cruzada (5 pliegues).	XGBoost discriminó casos con un AUC de 0.84, identificando el 58% de casos de etapa tardía hasta 24 meses antes del diagnóstico clínico.
Li et al. (2020)	Predecir pronóstico de supervivencia a 5 años en cáncer colorrectal preservando la privacidad.	Datos: Bases descentralizadas (SEER, SAHJU). Métodos: DPGAN (datos sintéticos), RF multicéntrico, Gini.	RF multicéntrico superó a LR y TNM (AUC 0.875) sin compartir datos crudos.
Alsinglawi et al. (2022)	Predecir el tiempo de estancia hospitalaria (LOS) en UCI para pacientes con cáncer de pulmón.	Datos: MIMIC-III. Métodos: RF, XGBoost, LR, RFE, SMOTE/ADASYN, SHAP.	RF con sobremuestreo (ADASYN/SMOTE) alcanzó AUCs de 100% y 98%. SHAP identificó temperatura, glucosa y emergencia como factores críticos.

- **Perfil clínico, demográfico y anatomopatológico de pacientes con cáncer pulmonar en el Hospital de Temuco (2019-2023):** El objetivo de este estudio consistió en caracterizar el perfil clínico y demográfico de pacientes adultos con diagnóstico de cáncer pulmonar confirmado en el Hospital Regional de Temuco entre 2019 y 2023, y analizar su asociación con factores de riesgo locales (como tabaquismo y exposición a biomasa), síntomas al diagnóstico y presencia de mutaciones moleculares. Para ello, se analizó una cohorte retrospectiva extraída de fichas clínicas de 220 pacientes del Hospital Hernán Henríquez Aravena (Temuco), mayores de 15 años, con confirmación histológica (biopsia) de cáncer pulmonar, entre octubre de 2019 y junio de 2023. Como metodología, el diseño de este estudio fue observacional y descriptivo, donde se utilizó estadística descriptiva y se realizó un análisis exploratorio de datos, calculando medidas de tendencia central (promedio y mediana) y dispersión (desviación estándar) para variables numéricas (como la edad). Para las variables categóricas (como sexo o etapa), se utilizaron distribuciones de frecuencia absoluta y relativa (porcentajes). En específico, se evaluaron variables biosociodemográficas y clínicas (escala ECOG y etapa TNM), además de tipos de biopsia y estudios de patología molecular (EGFR, ALK y PDL-1). Como resultado, de los 220 pacientes confirmados con cáncer de pulmón, se obtuvo un perfil de 55.3% de hombres con una edad promedio de 68 años (con una desviación estándar de 9.5 años), donde el 67.7% tenía antecedentes de tabaquismo y un 29.5% presentaba exposición a biomasa (leña). Además, se evidenció un diagnóstico alarmantemente tardío, con un 81.9% de los casos detectados en etapas avanzadas (III-IV), siendo el adenocarcinoma el subtipo principal (63.9%). Finalmente, se encontró una asociación significativa entre la expresión de PDL-1 y la exposición a biomasa, concluyendo que existe una necesidad urgente de implementar métodos de screening local (pruebas para detectar enfermedades o anomalías) para pacientes asintomáticos de alto riesgo (Orrego et al. (2025)).
- **Mortalidad por cáncer oral y orofaríngeo en Chile entre los años 1955 al 2021:** El objetivo de este estudio fue determinar y analizar la variación histórica y la tendencia de las tasas de mortalidad por cáncer oral y orofaríngeo en la población chilena a lo largo de un período de 66 años (entre 1955 y 2021). Para ello, se utilizaron los registros oficiales de defunción del Instituto Nacional de Estadísticas (INE) y del Departamento de Estadísticas e Información en Salud (DEIS). Se calcularon las tasas brutas de mortalidad por 100000 habitantes y se estratificaron los hallazgos por género. En específico, este estudio fue cuantitativo, descriptivo y observacional, donde se ajustaron las tasas de mortalidad por edad (estandarizadas según la población mundial de la OMS) para hacer comparables los datos en el tiempo, y se utilizó regresión Joinpoint, la cual identifica matemáticamente puntos de quiebre donde la tendencia cambia significativamente de dirección, calculando el

porcentaje de cambio anual (APC) para cada tramo: si es positivo, la mortalidad aumentó en ese período; si es negativo, disminuyó. Además, se usaron intervalos de confianza del 95% para asegurar que las tendencias observadas no fueran producto del azar; es decir, si el estudio se repitiera 100 veces, en 95 de ellas el resultado estaría dentro de ese rango. Como resultado, de un total de 9345 muertes analizadas en el período estudiado, las tasas brutas de mortalidad oscilaron entre 0.92 y 1.53 por cada 100000 habitantes, evidenciando una clara tendencia al alza a nivel nacional, especialmente desde el año 2011. Además, la tasa de mortalidad se concentró fuertemente en el grupo de 75 años o más, y aunque los hombres presentaron una tasa de mortalidad mayor (1.64) en comparación con las mujeres (0.67), la brecha histórica de género ha disminuido. Finalmente, este estudio valida que las variables edad y sexo son predictores críticos para la mortalidad por cáncer oral y orofaríngeo, concluyendo que, a pesar de la leve reducción nacional en el consumo de tabaco, la mortalidad sigue aumentando, lo que evidencia la falta de políticas públicas efectivas para la detección y diagnóstico temprano de estas patologías específicas (Ortega-Ceavichay et al. (2023)).

- **Comportamiento del cáncer de tiroides en la Unidad de Cirugía Adulto del Hospital Clínico Herminda Martín de Chillán. Período 2017 al 2019:** El objetivo de este estudio fue describir el comportamiento clínico, demográfico e histopatológico del cáncer de tiroides en pacientes de la Región de Ñuble sometidos a resolución quirúrgica en la Unidad de Cirugía Adulto. Para ello, se analizaron los registros clínicos de 124 pacientes operados por patología tiroidea en el Hospital Clínico Herminda Martín de Chillán entre 2017 y 2019, de los cuales 58 fueron confirmados con patología maligna. Como metodología, se tabuló la correspondencia diagnóstica del sistema citológico de Bethesda, el tipo de resección (tiroidectomía) y parámetros de extensión tumoral. Para ello, se revisaron fichas clínicas, protocolos operatorios y biopsias de pacientes operados por patología tiroidea, calculando frecuencias relativas (porcentajes) para las variables cualitativas (como tipo de cirugía y sexo) y promedios para las variables cuantitativas (como edad y tiempo de espera). Como resultado, de los 124 pacientes operados, 58 presentaban cáncer (46.8%), predominando las mujeres (86.2%) y una edad promedio de 47.5 años. El diagnóstico más frecuente fue el carcinoma papilar (93.1%) y el procedimiento más frecuente fue la tiroidectomía total (74.1%), que implica la extirpación completa de la glándula tiroides. Además, clínicamente se reportó un 98% de asociación simultánea entre la presencia de cáncer y cuadros de tiroiditis, y se midieron los tiempos de espera quirúrgica, encontrándose un promedio de 147 días para pacientes con cáncer. Finalmente, este estudio destaca que más de la mitad de los tumores femeninos medían más de 1 cm y que el 36% ya presentaba invasión extratiroidea al momento de la cirugía, variables de extensión que los autores relacionan críticamente

con los prolongados tiempos de espera en la red pública de salud. Cabe destacar que estos resultados son válidos para describir la realidad local del hospital, ya que se trató de un estudio censal de la unidad, considerando a todos los pacientes operados en el período, sin error de muestreo (Rubio et al. (2021)).

- **Cáncer en Chile y en el mundo: una mirada actual y su futuro escenario epidemiológico:** El objetivo de este estudio fue evaluar el escenario epidemiológico contemporáneo del cáncer a nivel mundial y realizar una proyección del impacto de esta enfermedad en la población chilena para orientar la planificación sanitaria. Para ello, se realizó una revisión narrativa de la literatura fundamentada en datos oficiales de agencias internacionales (como la OMS, GLOBOCAN e IARC) e instituciones nacionales (como el MINSAL, DEIS y encuestas nacionales de salud), analizando el incremento histórico de mortalidad y morbilidad entre 1986 y 2018, mediante la recopilación de estadísticas de incidencia, mortalidad y factores de riesgo asociados a la oncología, con el fin de sintetizar indicadores precalculados provenientes de fuentes secundarias validadas. Como resultado, en 2018 se diagnosticaron 53365 nuevos casos de cáncer en Chile y la mortalidad por neoplasias aumentó un 109% entre 1986 y 2016, proyectándose como una potencial causa de muerte en Chile. Se identificó que los cánceres más frecuentes fueron próstata, colorrectal, mama, estómago y pulmón, y se confirmó que, al momento del estudio (2020), el cáncer estaba desplazando a las enfermedades cardiovasculares como primera causa de muerte, siendo ya la principal causa en cinco regiones del país: Arica y Parinacota, Antofagasta, Coquimbo (mencionada como La Serena en la investigación), Los Lagos y Aysén. Por otro lado, las proyecciones estimaron un incremento del 77.6% en nuevos diagnósticos para 2040 y se consideró que cerca del 40% de los diagnósticos oncológicos están asociados a factores de riesgo modificables, concluyendo que es imperativo implementar un rediseño de las políticas de salud pública enfocado en el fomento de estilos de vida saludables, el control de la obesidad y la detección temprana de enfermedades o factores de riesgo. Cabe destacar que la validez del estudio se sustenta en la autoridad y confiabilidad de las fuentes citadas (Parra-Soto et al. (2020)).

Cabe mencionar que, en la Tabla 2.2 se presentan los resúmenes de cada uno de los artículos internacionales seleccionados sobre la caracterización de cohortes oncológicas mediante análisis epidemiológico y estadística descriptiva.

Tabla 2.2: Resumen de estudios sobre caracterización de cohortes oncológicas mediante análisis epidemiológico y estadística descriptiva.

Estudio	Objetivo principal	Datos y metodología	Hallazgos principales
Orrego et al. (2025)	Caracterizar el perfil clínico y demográfico de pacientes con cáncer pulmonar y su asociación con factores de riesgo locales.	Datos: Fichas clínicas de 220 pacientes (Hospital Regional de Temuco). Métodos: Estudio observacional y análisis de estadística descriptiva.	Predominio masculino y edad media de 68 años. Alta detección en etapas avanzadas (81.9%). Asociación significativa entre expresión de PDL-1 y exposición a biomasa.
Ortega-Ceavichay et al. (2023)	Analizar la variación histórica y tendencias de mortalidad por cáncer oral y orofaríngeo en Chile (1955-2021).	Datos: Registros de defunción oficiales (INE, DEIS). Métodos: Estudio descriptivo cuantitativo y análisis mediante regresión Joinpoint.	Clara tendencia al alza en la mortalidad. Mayor afectación en hombres, aunque la brecha de género disminuye. Evidencia la falta de políticas de detección temprana.
Rubio et al. (2021)	Describir el comportamiento del cáncer de tiroides en pacientes sometidos a resolución quirúrgica.	Datos: Registros clínicos de 124 pacientes operados (Hospital Clínico Herminda Martín). Métodos: Análisis descriptivo de variables clínicas y citología Bethesda.	Predominio en mujeres (86.2%) y carcinoma papilar (93.1%). El 36% presentó invasión extratiroidea, variable asociada críticamente a los largos tiempos de espera.
Parra-Soto et al. (2020)	Evaluar el escenario epidemiológico del cáncer a nivel mundial y proyectar su impacto en la población chilena.	Datos: Estadísticas oficiales (OMS, GLOBOCAN, DEIS, MINSAL). Métodos: Revisión narrativa y análisis de tasas de incidencia y mortalidad.	El cáncer desplazó a patologías cardiovasculares en cinco regiones. Se proyecta un aumento del 77.6% en diagnósticos para 2040, urgiendo políticas de prevención.

2.4.4 Enfoques de solución

Con base en la literatura (los estudios mencionados anteriormente), se identificaron tres enfoques analíticos aplicados al estudio de pacientes oncológicos. El primero, de **estadística tradicional**, emplea técnicas como la regresión logística y los modelos lineales, útiles para describir asociaciones lineales simples; sin embargo, asumen linealidad y aditividad entre las variables, lo que resulta insuficiente cuando los desenlaces en GRD dependen de interacciones no lineales y multidimensionales, patrones que la estadística clásica tiende a simplificar (Huang et al. (2022)).

El segundo enfoque, de **aprendizaje automático supervisado**, permite modelar relaciones complejas y descubrir patrones ocultos que la estadística tradicional omite, logrando clasificar desenlaces como severidad o mortalidad (Luo et al. (2025)). No obstante, su principal limitación es la ausencia de una justificación clara de las predicciones, lo que dificulta su interpretación y validación clínica, siendo incompatible con el objetivo de apoyar la toma de decisiones estratégicas.

El tercer enfoque, de **aprendizaje automático explicable (XAI)**, combina la precisión predictiva de los modelos de aprendizaje automático con la capacidad interpretativa, alineándose con la necesidad de generar perfiles y evidencia sanitaria accionable para instituciones como FONASA, en donde la explicabilidad se entiende como la cuantificación de la contribución marginal de cada variable a la predicción final, utilizando SHAP (SHapley Additive exPlanations) y midiendo su aporte en la identificación de reglas de decisión contrastadas con estudios científicos, con el fin de evaluar su coherencia clínica.

2.4.5 Justificación del enfoque seleccionado

Para esta propuesta, se seleccionó el enfoque de **aprendizaje automático supervisado explicable (XAI)** por su capacidad única para abordar la problemática central de este estudio, al permitir construir perfiles operativos que identifican qué combinaciones de factores clínicos, demográficos y hospitalarios determinan los distintos niveles de mortalidad, severidad y consumo de recursos en episodios oncológicos, transformando un problema técnico de clasificación en una herramienta de inteligencia sanitaria.

Además, aunque los datos GRD no fueron diseñados para la investigación clínica, este enfoque resulta pertinente porque el aprendizaje automático permite modelar y descubrir relaciones complejas entre las variables de entrada y las de salida, las cuales tienden a ser simplificadas por los métodos estadísticos tradicionales. Adicionalmente, la capa de explicabilidad posibilita validar la coherencia clínica de los patrones detectados o revelar hallazgos novedosos, mientras que el carácter supervisado se justifica en la definición de las variables de salida de interés en el conjunto de datos.

Por último, este enfoque aporta insumos prácticos para la gestión sanitaria, ya que la interpretabilidad permite implementar estrategias basadas en la identificación de factores específicos que elevan cada riesgo, apoyando la planificación sustentada en evidencia. De esta manera, se avanza desde asignaciones basadas en promedios históricos hacia una planificación ajustada a la complejidad real del sistema público, optimizando la respuesta de la red frente a la demanda oncológica.

CAPÍTULO 3. MARCO METODOLÓGICO

El presente capítulo detalla la metodología utilizada para el desarrollo de la investigación, estructurada bajo el estándar CRISP-DM (*Cross-Industry Standard Process for Data Mining*), la cual proporciona un enfoque iterativo y riguroso para la minería de datos, garantizando que los modelos analíticos desarrollados respondan directamente a las necesidades del negocio y del entorno clínico y administrativo (?). A continuación, se describen las fases del proyecto, comenzando por la comprensión del problema y la caracterización de los datos.

3.1 FASE 1: ENTENDIMIENTO DEL PROBLEMA (*BUSINESS UNDERSTANDING*)

El cáncer represente a una de las principales causas de mortalidad prematura y morbilidad en Chile, generando una presión asistencial y económica crítica sobre la red pública de salud. Sin embargo, a pesar de la urgencia epidemiológica de esta enfermedad, la caracterización de los pacientes con cáncer se ha sustentado históricamente en estudios clínicos locales, segmentados por centros hospitalarios específicos o basados en muestras reducidas, tal como se evidenció en el capítulo de estado del arte (sección 2.4.3). Esta fragmentación de la información dificulta contar con una visión nacional consolidada que refleje la complejidad operativa, las trayectorias intrahospitalarias y los múltiples factores asociados a la severidad de los episodios a lo largo de todo el sistema de salud.

Actualmente, el sistema de Grupos Relacionados por el Diagnóstico (GRD) reúne información estandarizada de los egresos hospitalarios de la red pública, representando una fuente masiva y valiosa de datos a nivel nacional, sin embargo, esta información no ha sido explotada en el ámbito oncológico. En la práctica, estos datos se utilizan principalmente con fines de facturación y asignación presupuestaria Fondo Nacional de Salud (FONASA) (2023); Clapes UC (2023), impidiendo responder preguntas fundamentales sobre los factores de riesgo clínico (como mortalidad y severidad) y el consumo de recursos en pacientes oncológicos. En consecuencia, existe una brecha crítica en la ausencia de una caracterización que permita identificar perfiles clínico, demográfico y hospitalarios para apoyar la toma de decisiones operativas.

Frente a la necesidad de transformar estos registros administrativos en una herramienta de inteligencia sanitaria, el objetivo de este estudio consiste en caracterizar perfiles de riesgo operativo en oncología, diferenciando los factores que determinan la severidad,

consumo de recursos y mortalidad de los pacientes internados en Chile. Para lograrlo, se aplicarán técnicas de aprendizaje automático y modelos de Inteligencia Artificial Explicable (XAI) sobre los datos del sistema GRD correspondientes al periodo 2019-2024, con el fin de superar el enfoque tradicional, aislando las variables más determinantes del proceso asistencial para contribuir al diseño de estrategias de gestión hospitalaria basadas en evidencia.

3.2 FASE 2: COMPRENSIÓN Y PREPARACIÓN INICIAL DE LOS DATOS

Esta fase tiene por objetivo adquirir los datos brutos provenientes de los registros administrativos, evaluar su calidad estructural y aplicar los primeros filtros lógicos para definir las cohortes de estudio. Dado el volumen y la complejidad de los archivos anuales, el proceso se dividió en las siguientes etapas:

3.2.1 Adquisición e identificación de formatos

Los datos utilizados en esta investigación fueron extraídos del repositorio de datos abiertos del Fondo Nacional de Salud (FONASA), específicamente del visor público del sistema GRD correspondiente al período 2019 hasta 2024. En específico, estos registros se encontraban particionados en 6 archivos de texto plano (.txt) separados por barras verticales (*pipes*), sumando un peso superior a 4.4 Gigabytes (Fondo Nacional de Salud (FONASA) (2024)).

Debido a que la recopilación de estos datos cuenta con distintas políticas de gestión de la información, se detectaron discrepancias en los formatos de origen. Es por ello que, el primer desafío técnico radicó en la heterogeneidad de los formatos de escritura de cada archivo. Para ello, se diseñó un algoritmo usando la librería *chardet* para detectar y validar la codificación (*encoding*) nativa de cada archivo, por ejemplo, codificaciones en UTF-8, UTF-8-SIG, y UTF-16.

Posteriormente, se hizo un análisis de la consistencia estructural de los archivos, enfocado en la arquitectura de las variables. Mediante operaciones de conjuntos lógicos, evaluando la diferencia asimétrica entre las listas de columnas de cada año, se mapearon sistemáticamente las características de cada archivo, identificando sus diferencias. Adicionalmente, para cada año se analizó si habían filas problemáticas que tuvieran más columnas que el resto de filas del archivo.

Cabe destacar que, este escaneo estructural tuvo como propósito identificar que variables fueron añadidas, eliminadas o renombradas por FONASA a lo largo del tiempo (entre

los años de 2019 hasta 2024), lo que es crítico en el ciclo de vida del dato (CRISP-DM), ya que detectar estas variaciones temporales de forma temprana permite consolidar una lectura robusta de las bases de datos para su posterior procesamiento y evitar la propagación de errores de dimensionalidad (como *NaNs* estructurales) en la etapa de modelamiento, asegurando que las características seleccionadas para los modelos de aprendizaje automático posean continuidad histórica en la red pública de salud.

3.2.2 Limpieza básica y clasificación de la cohorte oncológica

Para evitar sesgos de selección y permitir que los algoritmos de aprendizaje automático aprendan patrones contrastantes, el diseño experimental contempló mantener a la población sin diagnóstico oncológico como grupo de control, asignándole la etiqueta `SIN_CANCER`.

El primer paso de limpieza consistió en la exclusión de todos los episodios hospitalarios catalogados como registros inválidos, definidos como aquellas filas que carecían de un diagnóstico principal registrado (columna `DIAGNOSTIC01` nula). Posteriormente, se diseñó un algoritmo de clasificación basado en expresiones regulares para agrupar los códigos CIE-10, en donde todos los diagnósticos pertenecientes al capítulo II de la codificación CIE-10 (códigos cuyo prefijo oscila entre C00 y C97) fueron categorizados en 15 tipologías oncológicas según la localización del tumor maligno.

Además, para garantizar la captura exhaustiva de la morbilidad oncológica, la clasificación se ejecutó mediante una estrategia de escaneo dual, en donde aparte de evaluar el diagnóstico principal, se identificó si había un registro oncológico en el resto de diagnósticos:

1. **Detección de cáncer principal:** Se evaluó inicialmente la columna `DIAGNOSTIC01`, en donde los pacientes cuyo motivo principal de ingreso correspondía al código de una neoplasia maligna, fueron etiquetados bajo la categoría de tipo de cáncer principal (`TIPO_DIAGNOSTICO_ONCO: PRINCIPAL`).
2. **Detección de cáncer secundario:** Para los pacientes que inicialmente no presentaron cáncer en el diagnóstico principal, se implementó un escaneo iterativo sobre las 34 columnas de diagnósticos secundarios (`DIAGNOSTIC02` a `DIAGNOSTIC35`). En donde, si el algoritmo detectaba un código oncológico en alguna de estas comorbilidades, el paciente era reclasificado y etiquetado bajo la categoría de tipo de cáncer secundario (`TIPO_DIAGNOSTICO_ONCO: SECUNDARIO`).

Finalmente, aquellos episodios que superaron ambos escaneos sin presentar códigos del bloque C00-C97 fueron asignados definitivamente al grupo de control, es decir, sin

cáncer (CATEGORIA_CANCER: SIN_CANCER, TIPO_DIAGNOSTICO_ONCO: SECUNDARIO).

3.2.3 Análisis de variables identificadoras

Para no comprometer la capacidad de generalización de los modelos en la etapa de modelado, se evaluó el rol de las variables identificadoras (como el ID del paciente, los códigos de hospitales y las identificaciones médicas), ya que las variables con alta cardinalidad (es decir, con muchas categorías únicas) en conjuntos de datos clínicos a menudo actúan como ruido estadístico y pueden comprometer la inferencia lógica.

Por ello, primero se cuantificó la frecuencia de episodios por paciente único a través de las variables CIP_ENCRIPADO e ID_BENEFICIARIO. Cabe mencionar que, aunque se detecten pacientes con múltiples episodios históricos (readmisiones), se determinó que el enfoque metodológico de la investigación requería analizar los episodios hospitalarios como instancias independientes del consumo de recursos asistenciales, de modo que cada hospitalización se procesó como una unidad de análisis discreta.

De manera análoga, se analizó la distribución de los identificadores de los hospitales (COD_HOSPITAL) y de los profesionales de intervención y alta (MEDICOINTERV1 y MEDICOALTA), con el fin de evaluar su potencial como variables predictoras a través de su cardinalidad.

Cabe mencionar que, los datos se encuentran completamente anonimizados y no es posible revertir los identificadores de los pacientes (CIP_ENCRIPADO e ID_BENEFICIARIO), por lo cual se pueden utilizar estos registros sin requerir consentimiento informado ni revisión por comité ético.

3.2.4 Análisis de distribución y cardinalidad de variables categóricas

Dada la naturaleza de los registros GRD, gran parte de sus características descriptivas correspondían a variables categóricas (como el tipo de alta, procedencia, sexo, etnia y procedimientos), por ende, para procesar estas dimensiones, se implementó una estrategia de matriz de frecuencias simultánea, para comparar las distribuciones de las categorías de cada variable entre la cohorte oncológica y el grupo control, y de esta forma evaluar el potencial de la variable como predictor de los desenlaces clínicos al detectar su cardinalidad y prevalencia de cada una de sus clases en cada grupo.

Este preprocesamiento incluyó técnicas de normalización computacional (como la

codificación UTF-8, remoción de acentos y caracteres especiales) y homologación semántica de categorías para fusionar respuestas equivalentes (por ejemplo, homologar NINGUNA y SIN INFORMACION bajo la categoría única NINGUNO en variables sociodemográficas). Además, los valores originalmente ausentes en el texto libre (como campos vacíos o cadenas "NaN") fueron imputados explícitamente bajo la categoría "NULOS", preservando así la información sobre el patrón de ausencia de registro.

3.2.5 Análisis de variables temporales

Después de analizar las variables categóricas y su cardinalidad, se realizó un escaneo automatizado para evaluar la integridad y coherencia de las distintas fechas registradas en los episodios hospitalarios de GRD (como FECHA_NACIMIENTO, FECHA_INGRESO, FECHAALTA y las fechas de procedimientos quirúrgicos). Esto es debido a que las variables de tipo fecha pueden constituir un eje crítico para medir el consumo de recursos, severidad o mortalidad de los episodios, por ejemplo, para calcular los tiempos de estancia o el riesgo asociado a la edad.

Cabe destacar que este algoritmo de saneamiento identificó y manejó tres desafíos estructurales de las variables de tipo fecha:

- **Múltiples formatos de origen:** Este algoritmo identificó fechas codificadas en distintas normas (como formatos ISO YYYY-MM-DD, formatos locales DD-MM-YYYY o cadenas concatenadas YYYYMMDD). Esto se realizó mediante técnicas de expresiones regulares y análisis de patrones, las cuales estandarizaron todas las variables hacia el formato universal `Datetime` de Pandas, garantizando la coherencia temporal en todo el conjunto de datos.
- **Gestión de valores predeterminados de sistema:** Se detectaron registros en donde los campos temporales vacíos en el sistema clínico original habían sido auto completados con valores por defecto (como "0000-00-00" o "00000000"). Por ende, el algoritmo las reclasificó como verdaderos valores nulos (*missing values*) para evitar alteraciones en el cálculo numérico de la varianza temporal.
- **Validación de rangos lógicos:** Finalmente, se excluyeron los registros cuyas transformaciones de fecha generaban años lógicamente imposibles o proyecciones futuristas fuera del margen clínico coherente (por ejemplo, fechas de nacimiento con años futuristas).

3.2.6 Limpieza y normalización de variables numéricas

El análisis descriptivo e imputación de las variables cuantitativas requirió un enfoque minucioso para garantizar la validez estadística de los atributos de consumo de recursos. Entre las características analizadas destacaron los pesos relativos de los Grupos Relacionados por el Diagnóstico (peso del episodio) y los tiempos operativos expresados numéricamente.

El primer desafío consistió en la inconsistencia del formato de captura. Se detectaron caracteres alfabéticos residuales y el uso indistinto de comas y puntos como separadores decimales en distintos años del repositorio GRD. Estos errores tipográficos fueron corregidos programáticamente (mediante expresiones regulares) para homogeneizar las columnas hacia representaciones de punto flotante (*floats*).

Una vez estandarizados los formatos, se calcularon métricas de resumen estadístico (media, mediana, desviación estándar, rango intercuartílico y coeficiente de variación) de forma estratificada para la cohorte oncológica, el grupo de control y la población total. Este análisis estratificado permitió detectar asimetrías severas en las distribuciones e identificar valores atípicos (*outliers*) mediante el método del Rango Intercuartílico (IQR). A diferencia de enfoques puramente estadísticos donde los *outliers* suelen eliminarse para estabilizar las varianzas, en el contexto del aprendizaje automático aplicado a la gestión clínica de alta complejidad, estos valores atípicos (por ejemplo, pacientes con pesos relativos excepcionalmente altos) contienen información crítica sobre episodios de severidad extrema, por lo que fueron retenidos intencionalmente en el conjunto de entrenamiento.

3.2.7 Procesamiento de las variables objetivo (*Targets*)

El objetivo del presente trabajo consistió en desarrollar un análisis basado en Inteligencia Artificial Explicable para perfilar tres resultados asistenciales críticos en pacientes oncológicos. Para ello, se derivaron tres variables objetivo (*targets*) independientes a partir de los datos brutos, sobre las cuales se entrenarían posteriormente los algoritmos de clasificación. La discretización se realizó de la siguiente manera:

1. **Mortalidad hospitalaria (Clasificación binaria):** A partir de la variable categórica de condición al egreso (TIPOALTA), se generó una variable dicotómica donde el valor “1” representó la condición de fallecido intrahospitalario, mientras que el valor “0” agrupó al resto de las categorías de supervivencia (alta médica, traslados, fugas).

2. **Nivel de severidad (Clasificación multiclase ordinal):** Se procesó la variable IR_29301_SEVERIDAD, filtrando los códigos desconocidos y estandarizando la escala numérica para establecer cuatro niveles ordinales clínicos: menor (0), moderado (1), mayor (2) y extremo (3).
3. **Consumo de recursos (Clasificación multiclase categórica):** Dado que el peso relativo calculado por el algoritmo de 3M (IR_29301_PESO) es un valor numérico continuo con una distribución fuertemente sesgada a la derecha, se optó por discretizar dicha métrica para facilitar la identificación de perfiles de riesgo operativo. La variable fue transformada en terciles estadísticamente balanceados, generando las categorías ordinales de consumo de recursos: Bajo (0), Medio (1) y Alto (2).

Es fundamental destacar que, para evitar cualquier forma de ruido estocástico o distorsión durante la evaluación de los modelos, ****se aplicó una política estricta de eliminación de registros nulos sobre las variables objetivo****. A diferencia de las variables predictoras (donde los nulos pueden ser imputados), cualquier episodio clínico que careciera de información explícita sobre su condición de egreso, severidad o peso relativo fue eliminado de forma irreversible de la cohorte de estudio, evitando la falsificación del **Ground Truth**.

3.2.8 Simulación de impacto y reducción de cardinalidad

Antes de someter las variables explicativas (*features*) categóricas al modelo algorítmico, se implementó una estrategia sistemática para gestionar la alta cardinalidad y tratar los valores ausentes mediante técnicas de reducción de dimensionalidad semántica.

En lugar de aplicar codificación *One-Hot* indiscriminada (lo que multiplicaría exponencialmente la complejidad del modelo provocando *overfitting*), se utilizaron diccionarios de homologación basados en conocimiento experto. Por ejemplo, se agruparon 57 provincias administrativas distintas en 16 macro-categorías correspondientes a las Regiones del país, y se consolidaron decenas de registros de pueblos originarios bajo una única variable binaria representativa (ES_PUEBLO_ORIGINARIO).

Previo a la eliminación de cualquier categoría residual clasificada como "Desconocida" o de la depuración final de nulos, se diseñó e integró un simulador de impacto. Este algoritmo calculaba preventivamente cuántos episodios del grupo oncológico o del grupo de control se perderían al suprimir los datos incompletos y, fundamentalmente, verificaba si dichas eliminaciones afectaban asimétricamente a las clases de los *targets* (como los episodios de pacientes fallecidos). Si la simulación indicaba que la pérdida de registros superaba los márgenes estadís-

ticos aceptables o afectaba de manera desproporcionada a la clase minoritaria, la variable defectuosa era retenida y sus nulos encapsulados como una categoría propia (NULOS), asegurando así la preservación de la representatividad clínica de la base de datos maestra.

3.2.9 Ingeniería de características (*Feature Engineering*)

Con el fin de maximizar la capacidad predictiva de los algoritmos de aprendizaje automático sobre los episodios GRD, se diseñó e implementó un proceso de ingeniería de características. El objetivo de este paso fue construir variables derivadas sintéticas que capturaran la "intensidad" y el contexto del caso clínico con mayor fidelidad que los datos tabulares crudos.

A partir de la iteración y el análisis lógico de las variables base, se extrajeron las siguientes características operativas y clínicas:

- **Carga de enfermedad (Comorbilidades):** La literatura epidemiológica demuestra que un paciente con múltiples patologías concurrentes presenta un riesgo inherentemente mayor de complicaciones. Para cuantificar esto, se generaron tres variables: NUM_COMORBILIDADES (conteo de diagnósticos secundarios válidos, excluyendo el cáncer base), CARGA_ONCOLOGICA (conteo estricto de códigos neoplásicos para diferenciar tumores únicos de enfermedades metastásicas) y COMORBILIDAD_PRINCIPAL (mapeo del diagnóstico secundario primario hacia uno de los 16 macrogrupos del CIE-10).
- **Bandera quirúrgica (*Surgical Flag*):** En la gestión de camas y recursos hospitalarios, la distinción entre un manejo médico y uno quirúrgico es estructural. Mediante la inspección de la raíz del código del procedimiento principal (PROCEDIMIENTO1), se derivó la variable binaria ES_QUIRURGICO (1 si implicaba intervención de pabellón o incisión, y 0 en caso contrario).
- **Variables cronológicas (Edad y Días de estadía):** Aprovechando las fechas depuradas en etapas anteriores, se calculó la EDAD del paciente al momento del ingreso y la variable DIAS_ESTADIA (diferencia en días entre la fecha de ingreso y la fecha de alta).

Tras la creación de estas variables derivadas, se ejecutó un filtro final y estricto sobre el conjunto de datos. Cualquier episodio que contuviera errores irreversibles en el cálculo de estas métricas (como edades negativas producto de errores de digitación de los prestadores en el año de nacimiento) fue forzado a nulo y posteriormente eliminado, garantizando un *dataset* analítico libre de ruidos sistémicos o valores espurios.

3.2.10 Análisis de correlación y reducción de multicolinealidad

Para evitar que los modelos de aprendizaje automático sufrieran de sobreajuste por redundancia de información (*overfitting*) o que la posterior interpretabilidad algorítmica (valores SHAP) diluyera la importancia de las características entre variables gemelas, se realizó un análisis profundo de correlación y asociación.

En primera instancia, se calculó la correlación de Spearman para todas las variables numéricas y derivadas (como Días de Estadía y Número de Procedimientos), comprobando la ausencia de dependencias lineales perfectas que justificaran su eliminación cruzada.

Posteriormente, debido a la predominancia de características cualitativas, se calculó la matriz de asociación *V de Cramer* para todo el bloque de variables categóricas. Este escaneo estadístico detectó interacciones estructurales casi perfectas (> 0.99), lo que obligó a justificar la exclusión de determinadas variables del modelo final:

- Se excluyó la variable TIPO_ACTIVIDAD debido a su correlación absoluta con el *target* SEVERIDAD. Esta dependencia ocurría porque el algoritmo agrupador de 3M asigna el tipo de actividad evaluando los mismos parámetros clínicos que definen la severidad del episodio, lo que constituiría un caso crítico de fuga de datos (*Data Leakage*).
- Se excluyó la variable TIPO_SERVICIO_SALUD por su solapamiento perfecto con la variable REGION. Dado que la red de salud en Chile obedece a una distribución geográfica, mantener ambas variables inducía ruido estocástico; se optó por conservar únicamente la Región territorial por su mayor valor interpretativo para la salud pública.

3.2.11 Codificación One-Hot y partición estratificada del conjunto de datos

Para convertir el conjunto de datos final en una matriz matemática compatible con los tensores de los algoritmos de *Machine Learning*, se aplicó la técnica de codificación *One-Hot Encoding* (OHE) sobre las variables categóricas nominales, transformando cada categoría en una característica binaria independiente. Durante este proceso, se utilizó el parámetro de reducción estructural (*drop_first=True*) para eliminar la categoría base de cada variable, mitigando la multicolinealidad perfecta (trampa de la variable ficticia).

Como paso final de la preparación de datos (y cierre de la iteración retrospectiva del modelo), el conjunto consolidado entre los años 2019 y 2024 se separó topológicamente en la cohorte oncológica y la cohorte de control.

Posteriormente, con el objetivo de garantizar la validez del entrenamiento y la legitimidad de las pruebas de rendimiento, se realizó la partición del conjunto de datos (*Train/Test Split*) en una proporción de 80% para entrenamiento y 20% para validación. Dado el severo desbalance natural en desenlaces críticos del sistema hospitalario, esta división se ejecutó mediante un ****muestreo aleatorio estratificado**** utilizando la variable de MORTALIDAD como ancla. Esta estrategia matemática fue fundamental para garantizar que la distribución probabilística de la clase hiper-minoritaria (pacientes fallecidos) se mantuviera idéntica tanto en el subconjunto de entrenamiento como en el de prueba, asegurando que los algoritmos pudieran aprender los patrones de riesgo sin sufrir colapsos de sesgo estadístico.

3.3 FASE 4: MODELADO ALGORÍTMICO (*MODELING*)

El núcleo analítico de la investigación consistió en el entrenamiento y optimización de modelos de aprendizaje automático capaces de predecir la severidad, el consumo de recursos y la mortalidad hospitalaria. Para garantizar la rigurosidad estadística y evitar que los modelos aprendieran patrones sesgados hacia la clase mayoritaria (pacientes sin cáncer o pacientes vivos), se implementó un flujo de trabajo estructurado en tres etapas: balanceo estocástico, optimización de hiperparámetros y selección robusta de características mediante remuestreo iterativo (*Bootstrapping*).

3.3.1 Estrategia de balanceo basal

Dado el carácter masivo del conjunto de datos y la asimetría poblacional entre pacientes oncológicos y no oncológicos, se aplicó una técnica de submuestreo aleatorio (*Random Undersampling*) sobre la cohorte de control en la fase de entrenamiento.

Específicamente, se extrajo una submuestra aleatoria del grupo control de tamaño exactamente igual a la cantidad total de pacientes oncológicos presentes en el conjunto de entrenamiento (*Train set*), fijando una semilla matemática (`random_state=42`) para garantizar la reproducibilidad. Esta matriz resultante (*Train maestro balanceado*) fue el insumo exclusivo utilizado para enseñar los patrones de asociación a los algoritmos, asegurando que los modelos no subestimaran las características del cáncer debido a una baja prevalencia poblacional.

3.3.2 Selección y entrenamiento de algoritmos

Se evaluaron tres arquitecturas algorítmicas de distinta complejidad estructural para modelar cada una de las tres variables objetivo. Para todas las arquitecturas, se empleó validación cruzada estratificada de 5 pliegues (*Stratified K-Fold*) durante la búsqueda exhaustiva de hiperparámetros (*Grid Search*):

1. **Regresión Logística con regularización:** Utilizado como modelo base (*baseline*) interpretable. El algoritmo se optimizó dentro de un *Pipeline* secuencial que garantizó el escalado estándar previo de las variables numéricas para evitar fuga de información entre pliegues. Se exploraron penalizaciones L1 (*Lasso*) y L2 (*Ridge*) ajustando el inverso de la fuerza de regularización (parámetro *C*). Para los *targets* de Severidad y Consumo de Recursos (multiclase), se empleó una estrategia de entropía cruzada multinomial en lugar del enfoque *One-vs-Rest*, garantizando consistencia probabilística.
2. **Random Forest:** Algoritmo de ensamble basado en *Bagging*. Su hiper-parametrización se centró en la profundidad máxima de los árboles, el número de estimadores y el mínimo de muestras para la división de nodos (*min_samples_split*), activando en todo momento el parámetro `class_weight='balanced'` para gestionar los desbalances internos de las propias variables objetivo.
3. **XGBoost (eXtreme Gradient Boosting):** Algoritmo avanzado basado en *Boosting*. Para acelerar la convergencia sobre el gran volumen de datos, se configuró con el método de construcción de árboles `tree_method='hist'`. En el escenario de mortalidad (variable binaria), se calculó e inyectó dinámicamente el parámetro `scale_pos_weight` evaluando la proporción exacta de pacientes vivos respecto a los fallecidos en el conjunto de entrenamiento.

Como criterio metodológico de selección, no solo se priorizó la configuración que maximizara la métrica F1-Macro, sino que se descartaron automáticamente todas aquellas parametrizaciones que presentaran una desviación estándar superior a 0.10 entre los pliegues de validación cruzada. Esto aseguró la elección de modelos estables y resistentes a perturbaciones en los datos.

3.3.3 Validación de estabilidad de variables mediante *Bootstrapping*

Incluso empleando validación cruzada, los algoritmos de árbol (como Random Forest y XGBoost) son susceptibles de otorgar importancia a variables que resultan transitoriamente útiles en un subconjunto específico de datos, pero que carecen de causalidad clínica sistémica. Para resolver esta vulnerabilidad y consolidar un modelo final parsimonioso para la fase de explicabilidad, se ejecutó un procedimiento de *Stability Selection* mediante *Bootstrapping*.

Basado en el Teorema del Límite Central, el procedimiento consistió en un bucle computacional de 100 iteraciones sobre las mejores arquitecturas resultantes del *Grid Search*. En cada ciclo:

1. Se extrajo una muestra de entrenamiento del mismo tamaño que la original, pero con reemplazo (*Bootstrap sample*).
2. Se entrenó el algoritmo desde cero utilizando dicha muestra estocástica.
3. Se calculó y almacenó el vector de importancia relativa (*Feature Importances*) asignado por el modelo.
4. Las instancias no seleccionadas en el sorteo (muestras *Out-Of-Bag* u OOB) se utilizaron como un conjunto de validación en la sombra, registrando las métricas F1-Macro y AUPRC para auditar el decaimiento del rendimiento.

Al finalizar el bucle, se determinó la **Tasa de Selección Porcentual** y la **Varianza de Importancia** para cada variable de manera agregada. Únicamente aquellas variables que demostraron una tasa de aparición consistente y un impacto promedio alto durante las 100 reconstrucciones independientes fueron retenidas como el vector de características definitivo para la posterior extracción de reglas mediante valores SHAP.

3.4 FASE 5: EVALUACIÓN DE LOS MODELOS (*EVALUATION*)

Una vez definidos los hiperparámetros óptimos y seleccionadas las características más estables mediante *Bootstrapping*, se procedió a la evaluación del rendimiento predictivo de los algoritmos. Para garantizar que los resultados reflejaran la verdadera capacidad de generalización de los modelos frente a escenarios clínicos futuros, la evaluación se ejecutó estrictamente sobre el conjunto de prueba (*Test set*), el cual representaba el 20% de la cohorte histórica y que fue mantenido completamente oculto durante la fase de entrenamiento.

Dada la naturaleza crítica del dominio oncológico y el severo desbalance natural de clases (especialmente en la predicción de mortalidad, donde la clase positiva es hiper-minoritaria), el uso de la exactitud global (*Accuracy*) fue descartado por resultar en una métrica engañosa. En su lugar, el desempeño de los modelos se auditó utilizando un conjunto de métricas avanzadas centradas en la precisión, la exhaustividad y la calibración probabilística:

- **F1-Score (Macro y Clase Minoritaria):** Se utilizó como métrica principal para evaluar el equilibrio armónico entre la Precisión (proporción de predicciones correctas) y la Exhaustividad o *Recall* (capacidad de encontrar todos los casos reales). Para los problemas multiclase (Severidad y Consumo de Recursos), se empleó el F1-Macro para otorgar el mismo peso a todas las categorías, independientemente de su volumen. Para el modelo de Mortalidad, se aisló adicionalmente el F1-Score de la Clase 1 (fallecidos) para medir la efectividad específica sobre el evento letal.
- **Área Bajo la Curva de Precisión-Exhaustividad (AUPRC):** En contextos de alto desbalance, el AUPRC es estadísticamente superior al ROC tradicional. Esta métrica evalúa qué tan preciso se mantiene el modelo a medida que se le exige encontrar más casos positivos. Para los *targets* multiclase, se calculó mediante una estrategia *One-vs-Rest* (OvR) ponderada por el soporte de cada clase.
- **Validación de Lift (Ganancia sobre el azar):** Para dotar de significado clínico al AUPRC, se implementó un algoritmo de validación automática del *Lift*. Este indicador calculó la tasa base poblacional (prevalencia real de la clase en el conjunto de prueba) y la comparó contra el AUPRC obtenido por el modelo. Se estableció como estándar de éxito que el modelo debía multiplicar al menos por tres ($3.0x$) la capacidad de detección respecto a un sistema de selección aleatoria.
- **Área Bajo la Curva ROC (AUC-ROC):** Se incluyó como métrica estándar de la industria para evaluar la capacidad general de discriminación del modelo entre las distintas clases (separación de distribuciones).
- **Puntuación de Brier (*Brier Score Loss*):** Dado que en la gestión hospitalaria es vital saber no solo qué ocurrirá, sino con qué nivel de certeza, se incorporó esta métrica para medir la calibración del modelo. El *Brier Score* cuantifica el error cuadrático medio entre la probabilidad predicha (ej. 85% de riesgo) y el desenlace binario real (1 o 0), donde valores más cercanos a 0 indican que el algoritmo es altamente confiable en sus estimaciones probabilísticas.

Esta rigurosa batería de métricas permitió comparar de manera estandarizada el desempeño entre la Regresión Logística, Random Forest y XGBoost, estableciendo los

fundamentos matemáticos para seleccionar a los "modelos campeones" que pasarían a la fase final de explicabilidad clínica.

CAPÍTULO 4. RESULTADOS Y ANÁLISIS

Resultados y análisis.

4.1 RESULTADOS DE LA EXPLORACIÓN DE DATOS (FASE 2)

4.1.1 Resultados del análisis de los archivos brutos de GRD

Durante la auditoría estructural sobre los archivos planos y anuales de GRD descargados desde la plataforma de datos abiertos, se obtuvo la siguiente codificación de caracteres para cada archivo, la presencia de anomalías de dimensionalidad en filas específicas (filas con más columnas que el resto) y modificaciones en las variables identificadoras de los pacientes. Estos resultados se resumen en la Tabla 4.1:

Tabla 4.1: Resultados de la auditoría técnica y estructural de los archivos brutos GRD (2019-2024).

Período	Tamaño físico (Bytes)	Codificación aprobada	Volumen Total (Filas / columnas)	Hallazgos y observaciones estructurales
2019	572.538.020	utf-8	1.151.475 / 129	Estructura íntegra sin presencia de filas defectuosas. Preserva identificador histórico CIP_ENCRIPTADO.
2020	397.026.707	utf-8	781.912 / 129	Disminución del volumen total debido probablemente al impacto sanitario pandémico. Hay consistencia del esquema de columnas.
2021	428.657.825	utf-8-sig	816.909 / 129	Inclusión programática de la marca de orden de bytes (BOM) al inicio del archivo. Hubo ingesta limpia sin pérdida.
2022	960.774.530	utf-16	932.840 / 129	Migración sistémica a codificación de 16 bits. Hubo una detección de una anomalía posicional (línea 120.127 con 130 columnas, en vez de 129), corregida en preprocesamiento.
2023	1.075.450.968	utf-16	1.039.587 / 129	Incremento del volumen de registros por sobre el millón de egresos. Obtuvo un esquema libre de problemas de delimitación.
2024	566.268.922	latin1	1.085.813 / 129	Error crítico del analizador heurístico de codificación (hp-roman8, con confianza 0.01). Estabilizado mediante decodificación manual latin1. Y hubo una modificación del identificador del paciente a ID_BENEFICIARIO (en el resto de años se le asignaba la variable CIP_ENCRIPTADO).

El análisis comparativo determinó que todas las columnas mantuvieron una equivalencia funcional a lo largo de los 6 años analizados y no cambiaron sus nombres, con excepción del cambio nominal del identificador del paciente en 2024 (que cambió

de CIP_ENCRIPTADO a ID_BENEFICIARIO). Esta inconsistencia fue mitigada en la etapa de clasificación oncológica para evitar la pérdida de continuidad en el análisis temporal.

Cabe destacar que los años 2019 y 2024 presentaron mayor cantidad de episodios (filas) que en los años intermedios, por otro lado, en los años 2020 y 2021 se observó una disminución del volumen de registros, probablemente debido al impacto sanitario de la pandemia de COVID-19.

4.1.2 Distribución oncológica y control de la cohorte

Tras la el filtrado inicial y clasificación de diagnósticos, el proceso de limpieza y unificación permitió retener un total de 5.808.455 episodios clínicos válidos. Al aplicar el algoritmo de clasificación basado en el Capítulo II de la CIE-10 (C00-C97), se detectaron 498.618 episodios que presentaron al menos un diagnóstico oncológico activo durante su estadía hospitalaria, tanto en su diagnóstico principal (DIAGNOSTIC01) como secundario (DIAGNOSTIC02-35).

Respecto a los episodios oncológicos identificados, se observaron diferencias entre los motivos de ingreso directo (diagnóstico principal) y las comorbilidades oncológicas (diagnósticos secundarios). En específico, el análisis reveló que el 4,68% de los episodios de ingreso tenían un diagnóstico oncológico principal (272.093 instancias), mientras que un 3,90% presentaban cáncer como diagnóstico secundario (226.525 instancias). En su conjunto, la cohorte oncológica representó el 8,58% de todos los egresos hospitalarios de la red pública en el período estudiado, conformando un grupo de control (SIN_CANCER) masivo de 5.309.837 episodios (91,42%).

Como se ve en la tabla 4.2, en 2024 hubo un mayor número de episodios oncológicos respecto al resto de años, con un total de 55.111 episodios con cáncer como diagnóstico principal y 44.042 episodios con cáncer como diagnóstico secundario, representando a un 9,14% de los episodios hospitalarios de ese año, alineándose con la tendencia de proyección del cáncer indicada en antecedentes. En contraste, el año 2020 presentó la menor cantidad de episodios oncológicos, con 35.294 episodios con cáncer como diagnóstico principal y 29.632 episodios con cáncer como diagnóstico secundario, representando a un 8,30% de los episodios hospitalarios de ese año, probablemente debido al impacto sanitario de la pandemia de COVID-19.

Por otro lado, la Figura 4.1 muestra la distribución de los diagnósticos oncológicos en la población general, demostrando que la mayoría de episodios oncológicos se presentaron como diagnóstico principal (4,68%) en comparación con los diagnósticos secundarios (3,90%). Esto sugiere que el cáncer es a menudo la razón primaria de hospitalización, aunque también es común que los pacientes ingresen por otras urgencias y tengan cáncer como comorbilidad.

Tabla 4.2: Distribución anual de episodios hospitalarios: Cohorte oncológica versus grupo de control (2019-2024).

Período	Cáncer Principal	Proporción Principal	Cáncer Secundario	Proporción Secundario	Sin Cáncer (Control)	Proporción Sin cáncer	Total de episodios
2019	46.241	4,02%	51.588	4,48%	1.053.569	91,50%	1.151.398
2020	35.294	4,51%	29.632	3,79%	716.985	91,70%	781.911
2021	38.836	4,75%	29.090	3,56%	748.983	91,68%	816.909
2022	44.827	4,81%	33.242	3,56%	854.768	91,63%	932.837
2023	51.784	4,98%	38.931	3,74%	948.872	91,27%	1.039.587
2024	55.111	5,08%	44.042	4,06%	986.660	90,87%	1.085.813
TOTAL GENERAL	272.093	4,68%	226.525	3,90%	5.309.837	91,42%	5.808.455

En conjunto, la cohorte oncológica representó el 8,58% de todos los egresos hospitalarios, lo que resalta la significativa carga que el cáncer impone sobre el sistema de salud pública chileno. Además, como se tenía previsto, la mayor cantidad de episodios corresponden a pacientes sin diagnóstico oncológico (grupo de control, SIN_CANCER), representando el 91,42% de los episodios hospitalarios. Este grupo masivo de control es fundamental para evitar sesgos de selección y para permitir comparaciones robustas entre pacientes oncológicos y no oncológicos en las fases posteriores del análisis, especialmente al evaluar factores de riesgo asociados al cáncer.




Figura 4.1: Proporción total de pacientes y desglose de diagnósticos oncológicos (2019-2024).
Fuente: Elaboración propia, 2026.

Finalmente, se realizó un gráfico de barra para visualizar la distribución de cada tipo de cáncer según la codificación CIE-10 (Figura 4.2), en donde se observa que la mayoría de los

episodios oncológicos se concentraron en cáncer de órganos digestivos (C15-C26) con 133.249 episodios, seguidos por neoplasias de tejidos linfoides, hematopoyético y relacionados (C81-C96) con 85.492 episodios, cáncer de mama (C50) con 59.990 episodios y tumores en órganos genitales femeninos (C51-C58) con 42.030 episodios. En donde, esta distribución confirma la alta demanda de recursos especializados que estas localizaciones específicas exigen dentro del sistema hospitalario chileno, lo que tiene implicaciones directas para la planificación de servicios oncológicos y la asignación de recursos.




Figura 4.2: Distribución de episodios según categoría CIE-10 frente al grupo de control.
Fuente: Elaboración propia, 2026.

4.2 ANÁLISIS DE VARIABLES DEMOGRÁFICAS, CLÍNICAS Y HOSPITALARIAS

4.2.1 Análisis de variables identificadoras

Para esta fase, se analizó la cardinalidad y distribución de cada variable identificadora presente en el registro hospitalario GRD, en donde la Tabla 4.3 expone el volumen de identificadores únicos para los pacientes, hospitales y médicos. En esta tabla se puede observar que todos los identificadores presentan un número alto de cardinalidad, en especial la cantidad de pacientes únicos (CIP_ENCRIPTADO) que cuenta con más de 98.000 pacientes únicos en 2020. Por otro lado, hay entre 65 y 72 hospitales únicos durante el período analizado y más de 9.400 médicos únicos en cada año.

Respecto al análisis de reingresos de pacientes, registrados en la Tabla 4.4, se observa que en los años 2019 y 2020, la frecuencia máxima es dominada de forma artificial por la etiqueta SIN INFORMACIÓN, registrando 8.307 y 1.893 episodios respectivamente, sin embargo, este hallazgo evidencia un defecto de la codificación de pacientes en la base de datos de origen, ya que el sistema agrupó por defecto bajo una misma cadena de texto (SIN INFORMACIÓN) a todos aquellos egresos hospitalarios cuyos datos de identificación civil no pudieron ser encriptados o resultaron ilegibles en el nodo central. Por otro lado, a partir del año 2021, se destacó el identificador anónimo 95162030, el cual obtuvo la mayor cantidad de registros hospitalarios durante tres períodos consecutivos, registrando un mínimo de 294 reingresos en 2021 y un máximo de 523 episodios durante 2022.

En relación a los hospitales, en la Tabla 4.5 se evidencia que, a pesar de que la cantidad de recintos hospitalarios creció de 65 (en 2019) a 72 (en 2024), la distribución de la carga asistencial fue marcadamente asimétrica. De forma consistente durante el periodo evaluado, los cinco recintos de mayor envergadura absorbieron entre el 16,5% y el 18,6% de la totalidad de los egresos hospitalarios de la red nacional, siendo el hospital codificado como 114101 el centro que lideró invariablemente este indicador de volumen asistencial (correspondiente al hospital Complejo Hospitalario Dr. Sótero del Río, de Santiago, Puente Alto).

Además del hospital 114101, dentro de los recintos más frecuentes se encontraron los hospitales codificados como 106100 (Hospital Carlos Van Buren, Valparaíso), 118100 (Hospital Clínico Regional Dr. Guillermo Grant Benavente, Concepción), 109100 (Complejo Hospitalario San José, Santiago, Independencia), 121109 (Hospital Dr. Hernán Henríquez Aravena, Temuco), 113100 (Hospital Barros Luco Trudeau, Santiago, San Miguel), 116105 (Hospital Dr. César Garavagno Burotto, Talca), 120101 (Complejo Asistencial Dr. Víctor Ríos Ruiz, Los Ángeles) y

124105 (Hospital de Puerto Montt). Cabe mencionar que estas codificaciones están especificadas en las tablas maestras GRD obtenidas en el tablero de datos abiertos (Fondo Nacional de Salud (FONASA) (2024)).

En base a las cardinalidades y frecuencias de cada identificador, se tomó la siguiente decisión para cada variable identificadora:

- **Identificador de paciente (CIP_ENCRYPTADO o ID_BENEFICIARIO) (variable demográfica):**

Se descartó su uso en la fase de modelado, ya que el identificador encriptado de cada paciente no presenta una relación clínica ni operativa con su nivel de criticidad. Además, se identificaron pacientes con volúmenes de ingresos sospechosamente elevados o humanamente imposibles, como 8.307 episodios en 2019 asociados al registro SIN INFORMACIÓN o 523 episodios para el identificador 95162030 en 2022. Esto sugiere que la variable se encuentra probablemente contaminada con identificadores institucionales o códigos por defecto utilizados para pacientes sin registro. En consecuencia, la aplicación de transformaciones como *One-Hot Encoding* sobre una variable con miles de categorías generaría un conjunto de datos altamente dimensional y propenso al sobreajuste (*overfitting*), afectando negativamente el rendimiento de los algoritmos de selección de características. Asimismo, cada episodio será evaluado como una instancia independiente según su contexto clínico.

- **Identificador de hospital (COD_HOSPITAL) (variable hospitalaria):** Se descartó su uso en la fase de modelado debido a su elevada dimensionalidad (entre 65 y 72 categorías distintas por año). Además, esta variable se encuentra jerárquicamente anidada dentro de la variable SERVICIO_SALUD, la cual agrupa establecimientos según macrozonas geográficas y presenta una menor cardinalidad. Por lo tanto, mantener ambas variables podría introducir colinealidad en el modelo. Adicionalmente, el propósito principal de este estudio es apoyar la planificación sanitaria y la gestión de recursos a nivel macro, orientadas a organismos como FONASA y MINSAL. En este contexto, un análisis centrado en hospitales individuales excede el alcance epidemiológico de la caracterización propuesta.

- **Identificador del médico de la primera intervención (MEDICOINTERV1_ENCRYPTADO) (variable hospitalaria):** Se descartó su uso en la fase de modelado, ya que registra hasta 11.164 valores únicos por año, lo que generaría una matriz altamente dispersa y penalizaría el desempeño de los algoritmos de selección de características. Por esta razón, su utilización resulta metodológicamente inviable. Además, el objetivo del estudio es caracterizar aspectos clínicos y asistenciales, tales como los procedimientos realizados, y no identificar a los profesionales que los ejecutaron.

- **Identificador del médico de alta (MEDICOALTA_ENCRYPTADO) (variable hospitalaria):** Se

descartó su uso en la fase de modelado debido a su cardinalidad extremadamente alta, alcanzando hasta 17.743 valores únicos por año. Esto generaría una matriz dispersa que afectaría negativamente el desempeño de los algoritmos de selección de características, haciendo inviable su incorporación desde un punto de vista metodológico. En términos prácticos, la transformación de esta variable sería computacionalmente ineficiente y desviaría al modelo de su objetivo principal, que es identificar perfiles clínicos, demográficos y hospitalarios a nivel de red de salud.

Tabla 4.3: Cardinalidad de variables identificadoras en el registro hospitalario GRD (2019-2024).

Identificador	2019	2020	2021	2022	2023	2024
CIP_ENCRPTADO (Pacientes únicos repetidos)	165.128	98.379	108.690	129.107	151.694	161.533
COD_HOSPITAL (Hospitales emisores)	65	65	65	65	68	72
MEDICOINTERV1 (Médicos tratantes)	9.617	10.388	9.476	10.198	10.569	11.164
MEDICOALTA (Médicos de egreso)	14.104	16.051	15.500	15.720	16.479	17.743

Tabla 4.4: Casos críticos de reingreso hospitalario: Identificadores con máxima frecuencia anual de episodios (2019-2024).

Año	Identificador del paciente (CIP_ENCRPTADO)	Frecuencia máxima (Episodios)
2019	SIN INFORMACIÓN	8.307
2020	SIN INFORMACIÓN	1.893
2021	95162030	294
2022	95162030	523
2023	95162030	341
2024	78492052	140

Tabla 4.5: Concentración de episodios asistenciales en los 5 establecimientos de salud de mayor volumen (2019-2024).

Año	Top 5 Hospitales (Código: Episodios)	Total episodios (Top 5)	Porcentaje de concentración
2019	Códigos 114101 (55.726), 106100 (42.026), 118100 (40.134), 109100 (35.921), 121109 (35.091)	208.898	18,1%
2020	Códigos 114101 (37.040), 113100 (28.652), 116105 (25.321), 109100 (24.903), 118100 (24.660)	140.576	18,0%
2021	Códigos 114101 (44.842), 118100 (28.853), 113100 (27.955), 116105 (25.610), 109100 (24.947)	152.207	18,6%
2022	Códigos 114101 (47.426), 118100 (31.167), 116105 (30.292), 120101 (29.101), 109100 (28.275)	166.261	17,8%
2023	Códigos 114101 (49.653), 118100 (34.144), 116105 (32.148), 120101 (31.251), 121109 (29.786)	176.982	17,0%
2024	Códigos 114101 (49.411), 118100 (35.148), 116105 (33.858), 120101 (30.527), 124105 (30.453)	179.397	16,5%

4.2.2 Análisis de variables temporales

El análisis de las variables de tipo fecha constituyó un paso crítico para evaluar la coherencia cronológica de los registros asistenciales y asegurar la correcta construcción posterior de atributos derivados (como la edad y los días de estancia hospitalaria). Los indicadores de formato, cantidad de valores nulos, registros inválidos y rangos temporales identificados se indican en la Tabla 4.6.

En esta auditoría se detectó que las fechas de nacimiento e ingreso presentaron una tasa mínima de valores nulos (0%), lo que demuestra que constituyen campos obligatorios validados por los sistemas informáticos hospitalarios de admisión de la red pública. Sin embargo, se confirmó una alteración en el formato de registro exclusivo para el año 2023, el cual adoptó el estándar dd-mm-yyyy frente al formato ISO yyyy-mm-dd utilizado de manera homogénea en el resto de los años. Por otra parte, las fechas de traslado exhibieron un volumen incremental de valores nulos que osciló entre el 82,77% y el 99,98%, esto sugiere que el traslado interno entre múltiples servicios especializados (como unidad de tratamiento intermedio (UTI), unidad de cuidados intensivos (UCI) o cirugía) es un reflejo directo de la inestabilidad o severidad del paciente, ocurriendo únicamente en una fracción minoritaria de los ingresos asistenciales, mientras que la gran mayoría de la población concentró su estadía en un único servicio base (por ende, la mayoría de fechas de traslado tienden a tener cerca de un 100% de valores nulos).

Otro hallazgo crítico se asoció a la fecha de procedimiento, la cual presentó una gran tasa de valores nulos y registros corruptos que alcanzaron casi el total de episodios (5.808.446), coexistiendo con formatos irreconocibles fuera del año 2019. Por otro lado, respecto a la fecha de intervención, se detectó una gran tasa de valores nulos (49% correspondientes a 2.873.826 registros) y un volumen de registros inválidos de 19.684 filas corruptas, con una distorsión temporal que se extendió de manera inconsistente hasta el año 2090, lo que evidencia errores sistemáticos de digitación por parte de los operadores de la red de salud al ingresar las fechas de las intervenciones en los sistemas locales.

Finalmente, se tomaron las siguientes decisiones para cada variable temporal:

- **Fecha de nacimiento (FECHA_NACIMIENTO) (variable demográfica) y fecha de ingreso (FECHA_INGRESO) (variable hospitalaria):** Estas variables se descartaron en su formato original, pero se destinaron a la generación de la variable derivada EDAD_INGRESO, ya que ambas presentan un 0% de valores nulos reales en toda la cohorte. Además, aunque se detectó un quiebre sistémico en el formato de las fechas durante 2023 (cambio de yyyy-mm-dd a dd-mm-yyyy), este puede resolverse mediante un proceso de parseo robusto. Asimismo, si bien los algoritmos basados en árboles (como Random Forest y XGBoost) no

procesan de forma nativa variables de tipo fecha (*datetime*), la diferencia matemática entre ambas fechas permite calcular la edad del paciente al ingreso hospitalario, un determinante demográfico potencialmente relevante para la evaluación del riesgo crítico en oncología.

- **Fechas de traslado (FECHATRASLADO1 hasta FECHATRASLADO9) (variables hospitalarias):** Estas variables se descartaron completamente debido a su elevado nivel de datos faltantes. En otras palabras, las fechas de traslado no aportan valor predictivo directo, ya que la primera fecha de traslado (FECHATRASLADO1) presenta un 82,77% de valores nulos, proporción que aumenta rápidamente hasta superar el 99% a partir de la cuarta fecha. Además, mantener estas variables en su formato original solo introduciría columnas prácticamente vacías, sin aportar capacidad de generalización a los modelos. Por ende, posteriormente se utilizará una variable categórica asociada a los traslados (SERVICIO_TRASLADO) para generar la variable derivada CANTIDAD_TRASLADOS, la cual sí puede aportar valor predictivo al capturar el número de traslados intrahospitalarios experimentados en cada episodio, constituyendo un indicador directo de inestabilidad clínica.
- **Fecha de alta (FECHAALTA) (variable hospitalaria):** Se descartó su uso en formato original, pero se utilizará para generar la variable derivada DIAS_ESTADIA. Si bien esta fecha, por sí sola, no describe el perfil del paciente, la diferencia entre FECHAALTA y FECHA_INGRESO permite estimar la duración de la estancia hospitalaria. Esta variable constituye potencialmente uno de los indicadores más influyentes en el consumo de recursos y en la severidad hospitalaria, por lo que resulta esencial para la caracterización de grupos oncológicos. Además, la calidad de los datos es excelente, con una tasa cercana al 0% de valores nulos reales. No obstante, esta variable se encuentra sujeta al mismo quiebre de formato detectado en 2023 para la fecha de ingreso.
- **Fecha de procedimiento (FECHAPROCEDIMIENTO1) (variable hospitalaria):** Se descartó completamente para la fase de modelado, ya que esta columna se encuentra vacía o inválida en todos los archivos anuales analizados (2019–2024), por lo que carece de utilidad analítica y predictiva.
- **Fecha de intervención (FECHAINTERV1) (variable hospitalaria):** Se descartó completamente su uso, ya que presenta una elevada tasa de valores nulos (49%), probablemente asociada al porcentaje de pacientes que no requirieron intervención quirúrgica. Adicionalmente, esta variable exhibe un alto nivel de corrupción de datos, evidenciado por la presencia de valores atípicos e inconsistencias lógicas severas, como registros correspondientes al año 2090 en admisiones ocurridas en 2023 o fechas de intervención registradas en 1902

para episodios de 2022. Por consiguiente, la combinación de una baja densidad de datos y un alto nivel de corrupción introduciría ruido excesivo en los modelos.

Es fundamental destacar que, la totalidad de las características analizadas (a excepción de FECHAPROCEDIMIENTO1) registraron un rango válido de meses estrictamente acotado entre 1 y 12, y un rango de días contenido entre 1 y 31. Lo que confirmó que la estructura granular de los datos temporales era matemáticamente válida, lo que legitimó el cálculo con exactitud de las variables derivadas como edad y días de estancia.

Tabla 4.6: Auditoría de consistencia, formato y cobertura de variables temporales (2019-2024).

Variable temporal	Formato detectado (Variación anual)	Valores nulos	Registros inválidos	Rango de años
FECHA_NACIMIENTO	yyyy-mm-dd	0 (0,00%)	21	1894-2024
FECHA_INGRESO	dd-mm-yyyy (2023) / yyyy-mm-dd	0 (0,00%)	70	2011-2024
FECHATRASLADO1	dd-mm-yyyy (2023) / yyyy-mm-dd	4.807.468 (82,77%)	18	2011-2024
FECHATRASLADO2	dd-mm-yyyy (2023) / yyyy-mm-dd	5.475.101 (94,26%)	9	2011-2024
FECHATRASLADO3	dd-mm-yyyy (2023) / yyyy-mm-dd	5.704.842 (98,22%)	1	2011-2024
FECHATRASLADO4	dd-mm-yyyy (2023) / yyyy-mm-dd	5.771.110 (99,36%)	1	2011-2024
FECHATRASLADO5	dd-mm-yyyy (2023) / yyyy-mm-dd	5.794.707 (99,76%)	0	2011-2024
FECHATRASLADO6	dd-mm-yyyy (2023) / yyyy-mm-dd	5.802.255 (99,89%)	0	2011-2024
FECHATRASLADO7	dd-mm-yyyy (2023) / yyyy-mm-dd	5.805.382 (99,95%)	0	2013-2024
FECHATRASLADO8	dd-mm-yyyy (2023) / yyyy-mm-dd	5.806.762 (99,97%)	0	2013-2024
FECHATRASLADO9	dd-mm-yyyy (2023) / yyyy-mm-dd	5.807.482 (99,98%)	0	2014-2024
FECHAALTA	dd-mm-yyyy (2023) / yyyy-mm-dd	18 (0,00%)	0	2019-2024
FECHAPROCEDIMIENTO1	yyyymmdd (2019) / Desconocido	5.808.446 (100,0%)	9	Inválido
FECHAINTERV1	dd-mm-yyyy (2023) / yyyy-mm-dd	2.873.826 (49,48%)	19.684	1911-2090

4.2.3 Análisis de variables categóricas

La caracterización de los episodios hospitalarios exige evaluar cómo se distribuyen las variables que los algoritmos de aprendizaje automático procesarán como atributos de entrada o variables objetivo (en el caso de la mortalidad y severidad). En este contexto, se realizó un análisis de frecuencia para cada variable categórica, con el objetivo de identificar la presencia de categorías mayoritarias o minoritarias que podrían influir en el rendimiento de los modelos predictivos y detectar posibles errores de codificación o grandes volúmenes de datos faltantes que podrían requerir estrategias de imputación o exclusión. Además, el análisis contrastó la distribución de las categorías a lo largo del período 2019–2024 tanto para la cohorte oncológica como para la cohorte control.

4.2.3.1 Variables categóricas objetivo (targets)

Dentro de las variables categóricas objetivo, se encuentran las variables de mortalidad hospitalaria (originalmente denominada TIPOALTA) y de severidad (originalmente denominada IR_29301_SEVERIDAD).

En primer lugar, dentro de los datos GRD se encuentran dos variables que describen la **mortalidad** hospitalaria: IR_29301_MORTALIDAD y TIPOALTA. Sin embargo, la primera es un índice sintético calculado por el sistema de codificación de GRD, siendo redundante retenerlo para el modelado, ya que la variable TIPOALTA es un descriptor categórico directo de la condición de alta del paciente, el cual incluye una categoría específica para la muerte hospitalaria, es decir, es la variable objetivo real y definitiva del desenlace del paciente. De esta forma, se ponderarían los factores de riesgo desde las condiciones clínicas reales del paciente (mortalidad real), en lugar de generar perfiles a través de un índice de predicción o de riesgo calculado por el sistema de codificación.

Como se mencionó, la variable TIPOALTA representa la verdad fundamental (Ground Truth) del desenlace clínico de cada paciente (mortalidad). En el análisis de frecuencias de la Tabla 4.7, se puede observar que la tasa de mortalidad de los pacientes oncológicos duplicó, y en ocasiones triplicó, la tasa de mortalidad de la cohorte control. En específico, para pacientes con cáncer la cantidad de episodios con desenlace de muerte hospitalaria osciló entre el 5,4% y 6,9%, mientras que para el grupo control la tasa de mortalidad se mantuvo entre el 2,3% y 3,7%.

Es de particular interés destacar la tasa de defunción durante la pandemia de COVID-19 en los años 2020 y 2021, donde la mortalidad oncológica alcanzó sus picos máximos históricos (6,9% y 6,5%, respectivamente), a pesar de que el volumen absoluto de decesos (4.462 y 4.423) fue menor que en años previos. Este fenómeno estadístico probablemente se deba a la contracción severa de ingresos hospitalarios durante la pandemia, lo que concentró las admisiones estrictamente en pacientes con neoplasias en estado crítico o terminal. Además, mientras que la mortalidad del grupo control regresó a sus valores de línea base pre pandémicos en 2022 y 2023 (2,6% y 2,3%, respectivamente), la mortalidad oncológica se mantuvo elevada por encima de 5,9% hasta 2024, lo que coincide con las proyecciones de defunciones para la población con cáncer.

Cabe mencionar que, para los algoritmos de aprendizaje automático, la variable TIPOALTA en conjunto de sus 11 categorías (domicilio, fallecido, hospitalización domiciliaria, derivación de otro hospital del servicio, alta voluntaria, derivación de otro hospital de la red nacional, derivación a otros centros (cárcel), fuga del paciente, derivación institución privada (compra de servicios), derivación institución privada (voluntario), no identificada), se binarizará en una variable dicotómica (MORTALIDAD) con las clases Fallecido (1) y Vivo (0), donde esta

clase agrupará los episodios con desenlace de alta voluntaria, domicilio, derivaciones, entre otros, exceptuando las categorías marginales sin información (no identificada y desconocido), las cuales serán eliminadas al tener una distribución cercana al 0% (100 casos en total durante todos los años).

Tabla 4.7: Distribución anual de la condición al egreso (Tipo de Alta, sin procesar): Cohorte oncológica vs. grupo control (2019-2024).

Condición al Egreso (Tipo de Alta)	Cohorte	2019	2020	2021	2022	2023	2024
Domicilio	Oncológica	88.008 (90,0%)	56.334 (86,8%)	58.867 (86,7%)	67.703 (86,7%)	78.385 (86,4%)	84.680 (85,4%)
	Control	964.012 (91,5%)	638.565 (89,1%)	657.403 (87,8%)	770.531 (90,1%)	857.820 (90,4%)	883.172 (89,5%)
Fallecido	Oncológica	5.321 (5,4%)	4.462 (6,9%)	4.423 (6,5%)	4.850 (6,2%)	5.314 (5,9%)	6.009 (6,1%)
	Control	24.263 (2,3%)	25.480 (3,6%)	27.542 (3,7%)	22.529 (2,6%)	19.822 (2,1%)	20.673 (2,1%)
Hosp. Domiciliaria	Oncológica	1.319 (1,3%)	1.471 (2,3%)	2.110 (3,1%)	2.741 (3,5%)	3.531 (3,9%)	4.473 (4,5%)
	Control	11.668 (1,1%)	12.600 (1,8%)	20.293 (2,7%)	20.667 (2,4%)	25.767 (2,7%)	32.259 (3,3%)
Deriv. Hosp. Servicio	Oncológica	1.631 (1,7%)	1.198 (1,8%)	1.069 (1,6%)	1.242 (1,6%)	1.671 (1,8%)	2.147 (2,2%)
	Control	23.575 (2,2%)	16.641 (2,3%)	17.252 (2,3%)	15.246 (1,8%)	18.834 (2,0%)	22.776 (2,3%)
Alta Voluntaria	Oncológica	526 (0,5%)	498 (0,8%)	569 (0,8%)	646 (0,8%)	710 (0,8%)	652 (0,7%)
	Control	9.437 (0,9%)	7.071 (1,0%)	8.490 (1,1%)	10.075 (1,2%)	9.607 (1,0%)	9.999 (1,0%)
Deriv. Red Nacional	Oncológica	659 (0,7%)	584 (0,9%)	541 (0,8%)	560 (0,7%)	688 (0,8%)	755 (0,8%)
	Control	7.756 (0,7%)	6.287 (0,9%)	6.653 (0,9%)	5.979 (0,7%)	6.784 (0,7%)	7.183 (0,7%)
Deriv. Otros Centros (cárcel)	Oncológica	76 (0,1%)	171 (0,3%)	135 (0,2%)	116 (0,1%)	143 (0,2%)	139 (0,1%)
	Control	2.904 (0,3%)	4.225 (0,6%)	3.903 (0,5%)	3.269 (0,4%)	3.354 (0,4%)	3.606 (0,4%)
Deriv. Inst. Privada (Compra Serv.)	Oncológica	144 (0,1%)	97 (0,1%)	112 (0,2%)	91 (0,1%)	142 (0,2%)	167 (0,2%)
	Control	4.267 (0,4%)	2.333 (0,3%)	3.576 (0,5%)	2.282 (0,3%)	2.744 (0,3%)	2.698 (0,3%)
Fuga del Paciente	Oncológica	75 (0,1%)	60 (0,1%)	49 (0,1%)	69 (0,1%)	77 (0,1%)	79 (0,1%)
	Control	4.066 (0,4%)	2.659 (0,4%)	2.544 (0,3%)	3.115 (0,4%)	3.147 (0,3%)	3.220 (0,3%)
Deriv. Inst. Privada (Voluntario)	Oncológica	65 (0,1%)	50 (0,1%)	51 (0,1%)	51 (0,1%)	54 (0,1%)	52 (0,1%)
	Control	1.549 (0,1%)	1.102 (0,2%)	1.327 (0,2%)	1.075 (0,1%)	993 (0,1%)	1.074 (0,1%)

En segundo lugar, la variable de **severidad** hospitalaria (IR_29301_SEVERIDAD) es calculada por el agrupador IR-GRD a partir del diagnóstico principal, diagnósticos secundarios, procedimientos y características clínicas del episodio, expresándose en 4 niveles ordinales: 0 (sin gravedad), 1 (menor), 2 (moderada) y 3 (mayor).

Como se puede observar en la Tabla 4.8, esta variable contiene una cardinalidad baja de 4 categorías, además, posee una distribución de valores nulos y desconocidos cercana al 0% (89 casos en total entre todos los años), lo que la convierte en una variable objetivo de alta calidad para el modelado, por lo cual se decidió retener como variable ordinal sin necesidad de binarizarla ni transformarla.

Específicamente, en el análisis de frecuencias se puede observar que, mientras que en la cohorte de control la mayor proporción de ingresos recae históricamente sobre la severidad menor de nivel 1 (alcanzando hasta un 50,5% en 2019), el paciente oncológico demanda niveles de complejidad clínica más elevados, con una mayor proporción de ingresos en los niveles de severidad moderada (nivel 2) y mayor (nivel 3), alcanzando hasta un 31,4% y 20,2% respectivamente en 2019. En otras palabras, los datos evidencian que los episodios de cáncer están fuertemente dirigidos hacia la derecha de la escala de severidad clínica, ya que la

severidad de nivel 2 (moderada) actúa como la moda estadística de esta cohorte.

Respecto al comportamiento de la severidad mayor (nivel 3) en la cohorte oncológica, se puede observar que, sufrió una escalada crítica a partir de 2020, saltando de un 20,2% en 2019 a representar casi un tercio de las hospitalizaciones (30,5%) al cierre de 2024. Este desplazamiento progresivo hacia los estratos de mayor gravedad podría indicar que las camas de la red oncológica están siendo ocupadas por pacientes con cuadros clínicos cada vez más deteriorados.

Tabla 4.8: Distribución porcentual de los niveles de severidad: Cohorte oncológica vs. grupo control (2019-2024).

Nivel de Severidad	Cohorte	2019	2020	2021	2022	2023	2024
Nivel 0 (Sin gravedad)	Oncológica	20.675 (21,1%)	3.648 (5,6%)	5.689 (8,4%)	7.909 (10,1%)	10.215 (11,3%)	11.081 (11,2%)
	Control	181.842 (17,3%)	76.016 (10,6%)	97.249 (13,0%)	146.863 (17,2%)	183.335 (19,3%)	200.970 (20,4%)
Nivel 1 (Menor)	Oncológica	26.703 (27,3%)	19.058 (29,4%)	19.126 (28,2%)	20.488 (26,2%)	21.770 (24,0%)	23.198 (23,4%)
	Control	531.868 (50,5%)	347.235 (48,4%)	321.010 (42,9%)	352.952 (41,3%)	366.924 (38,7%)	364.060 (36,9%)
Nivel 2 (Moderada)	Oncológica	30.680 (31,4%)	23.807 (36,7%)	23.718 (34,9%)	26.710 (34,2%)	31.917 (35,2%)	34.607 (34,9%)
	Control	211.611 (20,1%)	152.747 (21,3%)	160.104 (21,4%)	186.550 (21,8%)	221.169 (23,3%)	234.258 (23,7%)
Nivel 3 (Mayor)	Oncológica	19.771 (20,2%)	18.413 (28,4%)	19.393 (28,6%)	22.960 (29,4%)	26.813 (29,6%)	30.265 (30,5%)
	Control	128.227 (12,2%)	140.987 (19,7%)	170.620 (22,8%)	168.382 (19,7%)	177.414 (18,7%)	187.359 (19,0%)

4.2.3.2 Variables categóricas de entrada

A continuación, se presenta una lista de las variables categóricas de entrada provenientes de los datos GRD, en donde en base a su cardinalidad y tasa de frecuencias, se justificó su uso, agrupación o descarte para el modelado de desenlaces de riesgo de mortalidad, severidad y consumo de recursos:

1. **Sexo:** Esta variable se decidió retenerla sin necesidad de transformarla, al presentar una cardinalidad perfecta de 2 categorías (Hombre y Mujer), tener una distribución equilibrada y constante a lo largo de los 6 años (entre 59% mujeres y 41% de hombres en la población general y entre 53% de mujeres y 46% de hombres en la cohorte oncológica), contener una tasa de valores desconocidos cercana al 0% (559 casos en total durante todos los años), y además, ser un factor demográfico fundamental en la literatura médica para explicar la severidad de ciertos perfiles clínicos.
2. **Etnia:** Esta variable se decidió transformar y binarizar en una variable que indique si la persona pertenece a un pueblo originario o no (ES_PUEBLO_ORIGINARIO), ya que la variable

tiene 12 categorías (NINGUNO, OTRO, MAPUCHE, AYMARA, PASCUENSE, DIAGUITA, KAWESQAR, QUECHUA, YAGAN, COLLA, LICAN ANTAI, NO RESPONDE), y en ambas cohortes la mayoría de registros pertenecen a personas de ninguna etnia (entre 97% y 98% de casos), mientras dentro de las categorías de etnia, la más frecuente es la mapuche (entre 1,6% y 1,9% para la cohorte total, y entre 1,3% y 1,9% para la oncológica) y para el resto (como aymara y pascuense) las frecuencias bajan del 0,2% a casi 0%. Cabe mencionar que, las categorías NINGUNO y OTRO pertenecerían a la clase de personas que no pertenecen a un pueblo originario (0), ya que en los años 2022 y 2023 la categoría NINGUNO fue reemplazada por OTRO, mientras que el resto de categorías conformarían la clase positiva (1), excluyendo los valores nulos y los registros de NO RESPONDE, que en total registran 20 episodios durante los 6 años, lo que representa una tasa cercana al 0%.

3. **Provincia:** Esta variable se decidió retener y agrupar a nivel regional, ya que cuenta con 57 categorías provinciales, lo que generaría una matriz excesivamente dispersa al procesarla con One-Hot Encoding. Sin embargo, el dato geográfico es valioso, por ende, se plantea mapear y agrupar las 57 provincias en las 16 regiones de Chile (desde Arica y Parinacota hasta Magallanes), lo que reduciría drásticamente la cardinalidad y mantendría la explicabilidad territorial a nivel regional. Cabe mencionar que, dentro de la cohorte total la provincia más frecuente fue Santiago (entre un 26,1% y un 22,9% de casos), seguida por Concepción, Cautín, Cordillera y Valparaíso (con frecuencias de 6,2%, 4,9%, 4,2% y 4,2% respectivamente), mientras que en la cohorte oncológica, la provincia de Santiago concentra entre un 25,4% y un 24% de los casos, seguida por Concepción, Cordillera, Valparaíso y Cautín (con frecuencias de 7,6%, 5,8%, 5,5% y 4,8% respectivamente).
4. **Comuna:** Esta variable se decidió eliminar, ya que cuenta con 346 categorías comunales, lo que generaría una matriz extremadamente dispersa al procesarla (considerando que la comuna más frecuente que es Puente Alto, apenas representa el 4% del volumen total, lo que dejaría cientos de categorías con frecuencias cercanas a cero, lo que diluiría el peso de las variables clínicas críticas e incrementaría el riesgo de sobreajuste del modelo). Además, la distribución territorial ya está contenida en variables más robustas y agrupadas como provincia y servicio de salud (que se listará más adelante), por lo que la eliminación de la comuna no representaría sacrificar información geográfica a nivel macro. Por último, en la cohorte total, la comuna de Puente Alto tiene una frecuencia entre 4,3% y 3,6% de los casos, seguida por La Florida, Maipú, Valparaíso y Arica (con frecuencias de 2,2%, 2,2%, 2,1% y 1,9% respectivamente), mientras que en la cohorte oncológica, la comuna de Puente Alto concentra entre un 4,8% y un 6,6% de los casos, seguida por Valparaíso, La Florida, Maipú y Antofagasta (con frecuencias de 3,1%, 2,6%, 2,5% y 2,2% respectivamente).

5. **Nacionalidad:** Esta variable se decidió transformar y binarizar, ya que cuenta con una cardinalidad de 214 categorías, en donde la categoría CHILE abarca entre el 94% y 93% de los episodios hospitalarios, mientras que el resto de categorías corresponden a nacionalidades extranjeras con frecuencias muy bajas (desde 2,4% para Venezuela y tasas inferiores e iguales a 1% para Perú y el resto de países). Entonces, para evitar la dispersión de datos y rescatar este valor sociológico, se decidió transformar la nacionalidad en una variable dicotómica (ES_EXTRANJERO) de clase 1 para personas extranjeras y 0 para pacientes chilenos, lo que condensa el impacto epidemiológico de la migración sin afectar a los selectores de características. Cabe mencionar que, en la cohorte total la nacionalidad chilena abarcó entre un 94,5% y un 93,5% de los casos, seguida por Venezuela, Perú, Bolivia y Haití (con frecuencias de 1,9%, 0,9%, 0,9% y 0,8% respectivamente). En el caso de la cohorte oncológica, nuevamente la nacionalidad chilena fue la más frecuente con una tasa de entre el 97,5% y el 96,3% de los casos, seguida por Venezuela, Perú, Bolivia y Haití (con frecuencias de 1,2%, 0,5%, 0,3% y 0,3% respectivamente).
6. **Previsión:** Esta variable se decidió transformar y agrupar, ya que es un indicador robusto del nivel socioeconómico del paciente en el sistema chileno, pero al tener mucho ruido en sus 14 categorías (Fonasa Institucional (MAI) A, B, C, D, Fonasa Libre Elección (FMLE_B), FMLE_C, FMLE_D, ISAPRE, PARTICULAR, DIPRECA, CAPREDENA, CAJA DE PREVISION FFAA (SISA), NO CONSIGNADO, NO IDENTIFICADA), se decidió consolidarla en 6 macrocategorías funcionales (FONASA A, B, C, D, FFAA y orden, Privado), eliminando los casos no consignados ni identificados, los cuales suman un total de 763 registros (un 0%). Cabe mencionar que, Fonasa Institucional B es la previsión más frecuente en ambas cohortes (con una frecuencia del 46,1% total y 56,9% oncológica), seguida por la Fonasa Institucional A, D y C (con frecuencias totales de 23,7%, 14,2%, 12% respectivamente y frecuencias oncológicas de 16%, 14,5% y 11,4% respectivamente).
7. **Servicio de salud (SERVICIO_SALUD):** Esta variable indica la red del sistema público a la que pertenece o fue derivado el paciente, pero a diferencia de la comuna, esta columna tiene una cardinalidad manejable de 31 categorías válidas que podría ser asimilable por los selectores de características y algoritmos basados en árboles, además, es de suma importancia estratégica, ya que puede capturar las asimetrías institucionales del país (como diferencias de infraestructura, disponibilidad de centros médicos, presupuestos y tiempos en listas de espera), sin embargo, para optimizar la cardinalidad, se decidió mapear en 5 macrozonas (Norte, Centro, Metropolitana, Centro Sur y Sur Austral) para no colisionar con la granularidad de la variable de región (que se generará a partir de provincia). En la cohorte total, los servicios de salud más frecuente fueron el metropolitano suroriente (9%), del maule (7%), metropolitano occidente (6,5%), metropolitano sur (5,8%) y metropolitano central

(5,4%). Mientras que, en la cohorte oncológica, los servicios de salud más frecuentes fueron el metropolitano suoriente (11%), metropolitano occidente (6,9%), del maule (6,4%), metropolitano central (5,8%) y viña del mar quillota (5,2%).

8. **Tipo de procedencia (TIPO_PROCEDENCIA):** Esta variable se decidió transformar y agrupar, ya que cuenta con 19 categorías con frecuencias desequilibradas (Servicio de emergencia (domicilio), centro especialidades (CDT, CRS, consultorio ADOS. ESP), otros hospitales de la red, APS urgencia (SAPU, SUR, SUC), consulta privada, APS consultorio (CESFAM), otras instituciones de salud (clínicas privadas, de rehabilitación), otros hospitales de red nacional, plan de resolución, estrategia CRR, cirugía mayor ambulatoria (CMA), otras instituciones (cárcel, hogares de ancianos, sename), hospitalización domiciliaria, cardiocirugía pago GRD, posta rural, hospitalización diurna, no identificado, lista de espera, UGCC). Ya que mientras la cohorte total y oncológica los servicios de emergencia a domicilio y el centro de especialidades (CDT, CRS, CONSULTORIO ADOS. ESP) presentan frecuencias de 47% y 31,7% globalmente, y de 29,9% y 56,8% para la cohorte oncológica respectivamente, el resto de categorías presentan frecuencias menores al 8% alcanzando tasas de hasta el 0,1% o 0%, lo que diluiría el peso de esta variable en el modelado. Entonces, se decidió agrupar las categorías en 7 macrocategorías funcionales (urgencia domicilio, urgencia red primaria, ambulatorio especialidad, ambulatorio APS, traslado red pública, traslado privado e institución cerrada), eliminando los casos no identificados y desconocidos, que suman un total de 3.430 registros (aproximadamente un 0,1% del total).
9. **Tipo de ingreso (TIPO_INGRESO):** Esta variable se decidió agrupar ligeramente, ya que tiene una cardinalidad baja de 5 categorías (urgencia, programada, obstetrica, no identificada y no programada), sin embargo, la categoría no programada cuenta con solo 25 registros en la cohorte total (0%), por lo cual se propone mantener las categorías y juntar los registros no programados con los ingresos por urgencia, ya que ambos tipos de ingreso comparten la característica de ser no planificados. Por otro lado, los registros no identificados y nulos cuentan con 304 y 130 registros respectivamente, lo que equivale a un 0%. En específico, en la cohorte total, el tipo de ingreso de urgencia tiene una frecuencia de 51,3%, seguido por programada (32,8%) y obstétrica (16%). En la cohorte oncológica, el tipo de ingreso programada es la más frecuente con una tasa de 58,5%, seguida por urgencia (41,2%) y obstétrica (0,3%).
10. **Especialidad médica (ESPECIALIDAD_MEDICA):** Esta variable se decidió retener, limpiar y agrupar, ya que tiene una cardinalidad alta de 103 categorías, debido principalmente a errores tipográficos y saltos en la codificación del sistema GRD a partir de 2020 (por ejemplo, se renombran categorías como CIRUGIA TORAX a CIRUGIA DE TORAX).

Por ende, se desarrolló un diccionario de homologación para funcionar especialidades equivalentes y condensarlas en 13 macro categorías (cardiovascular, cirugía general, digestivo, gineco obstetricia, hematología, medicina interna y subs, odontología, oncología, pediatría, psiquiatría, respiratorio, traumatología y urgencia). Dentro de la cohorte total, las especialidades médicas más frecuentes fueron obstetricia y ginecología (20,7%), cirugía general (15,1%), medicina interna (14,7%), traumatología y ortopedia (8%) y pediatría (6,1%). Mientras que en la cohorte oncológica, las especialidades médicas más frecuentes fueron cirugía general (24%), medicina interna (18,6%), oncología médica (12,1%), obstetricia y ginecología (8,5%) y urología (7,6%).

11. **Tipo de actividad (TIPO_ACTIVIDAD):** Esta variable se decidió retener y homologar, ya que tiene una cardinalidad baja de 5 categorías (hospitalización, cirugía mayor ambulatoria (CMA), hospitalización en urgencia, hospitalización diurna y no identificado), las cuales tienen inconsistencias temporales. Esta variable es un fuerte determinante del consumo de recursos, sin embargo, el análisis de frecuencias detectó un quiebre en el registro, en donde las categorías de hospitalización diurna y en urgencia dejan de utilizarse a partir del 2020. Por ende, para garantizar la coherencia longitudinal del estudio a lo largo de los 6 años, estas categorías descontinuadas serán fusionadas dentro de la categoría principal de hospitalización y la de cirugía mayor ambulatoria (CMA), por otro lado, los casos de no identificado y desconocido, se eliminarán ya que suman un total de 21 casos (0%). En la cohorte total, el tipo de actividad más frecuente es la hospitalización (82,7%), seguida por la cirugía mayor ambulatoria (CMA) con un 15,3%, mientras que el resto de categorías representan frecuencias menores al 1%. En la cohorte oncológica, la hospitalización también es la categoría más frecuente con un 87,5%, seguida por la cirugía mayor ambulatoria (CMA) con un 8,6%, mientras que el resto de categorías representan frecuencias menores al 4%.
12. **Servicio de ingreso (SERVICIOINGRESO):** Esta variable se decidió retener y agrupar por complejidad, ya que tiene una cardinalidad alta de 92 categorías, sin embargo, puede detallar la infraestructura física del hospital y al igual que con las especialidades, presenta una alta fragmentación por digitación redundante (por ejemplo, categorías como UTI ADULTOS y UNIDAD DE TRATAMIENTO INTERMEDIO). Para ello, se establecerá un mapeo estructurado para agrupar las 92 áreas en 7 macro áreas estructurales absadas en el nivel de consumo de recursos (área quirurgica, cuidados críticos, gineco obstetricia, medicina interna, neuro psiquiatría, oncología y pediatría). En específico, en la cohorte total el servicio de ingreso más frecuente es el de cirugía general (10,4%), seguido por la unidad de recuperación de pabellones (central y CMA) con un 10,1%, medicina interna con un 9,2%, obstetricia con un 8,9% y pediatría con un 4,5%. Mientras que en la cohorte oncológica,

el servicio de ingreso más frecuente es el de cirugía general con un 18,5%, seguido por medicina interna con un 13,8%, oncología médica con un 10,1%, ginecología con un 8,1% y la unidad de recuperación de pabellones (central y CMA) con un 5,5%.

13. **Servicios de traslado (SERVICIOTRASLADO1...9):** Estas variables se decidieron descartar para el modelado, ya que el análisis de frecuencias reveló que la matriz es insosteniblemente dispersa, debido a que el primer traslado (SERVICIOTRASLADO1) posee alrededor de 82,8% de casos con valor nulo, escalando drásticamente hasta un 99% y 100% de nulos entre el cuarto y noveno traslado. Entonces, si se aplica One-Hot Encoding a estas variables, inyectaría cientos de variables vacías, diluyendo el poder estadístico de las variables basales. Sin embargo, el traslado en sí mismo es un factor importante de inestabilidad o complicación, por ende, se propone derivar de la 9 columnas en una única variable numérica discreta que cuente el total de traslados no nulos por episodio (CANTIDAD_TRASLADOS), rescatando la varianza útil de esta información sin penalizar la dimensionalidad del modelo. Respecto al primer traslado (SERVICIOTRASLADO1), se puede observar que, en la cohorte total, hay una alta tasa de nulos (82,8%), seguida por la categoría de medicina (2,2%), unidad de tratamiento intermedio (UTI) adulto (1,6%), cirugía (1,3%) y puerperio (1,1%). Mientras que en la cohorte oncológica, el primer traslado también presenta una alta tasa de nulos (82,5%), seguida por la unidad de tratamiento intermedio (UTI) adulto (3%), medicina (2,1%), cirugía (2,1%) y unidad de cuidados intensivos adulto (1,3%).
14. **Servicio de alta (SERVICIOALTA):** Esta variable se decidió descartar para el modelado, ya que retenerla resulta redundante y tautológico, ya que el servicio de alta va a tener una alta colinealidad tanto con el servicio de ingreso (SERVICIOINGRESO) como con la variable objetivo de mortalidad (TIPOALTA). Es por ello que, al conservar el servicio basal (ingreso) y medir la inestabilidad intrahospitalaria mediante la variable derivada de cantidad de traslados, el estado estructural del paciente queda perfectamente caracterizado sin necesidad de lidiar con esta variable que tiene 89 categorías ruidosas del servicio final, que además, tienen redundancias semánticas equivalentes al servicio de ingreso. Para la cohorte total, el servicio de alta más frecuente es el de cirugía general (11,3%), seguido por medicina (11,3%), unidad de recuperación de pabellones (central y CMA) con un 10,2%, obstetricia con un 8% y pediatría con un 4,8%. Mientras que en la cohorte oncológica, el servicio de alta más frecuente es el de cirugía general con un 19,5%, seguido por medicina con un 15,2%, oncología médica con un 10,6%, ginecología con un 8,1% y la unidad de recuperación de pabellones (central y CMA) con un 5,6%.
15. **Datos neonatales (CONDICIONDEALTONEONATO1...4, SEXORN1...4, RN1ESTADO...4):** Estas 16 variables se decidieron descartar por la cantidad de valores nulos y por su contexto

clínico, ya que las frecuencias demostraron que los valores válidos en estas columnas son estadísticamente inexistentes para la población de interés, pues los nulos alcanzan casi el 100% de los casos en condición de alta del neonato, un 99,9% en el sexo del neonato y un 75,4% en el estado del neonato. Luego para el resto de condiciones de alto, sexo y estados los valores de nulos alcanzan el 100% de los casos, lo que evidencia que estas variables no aportan información útil para el modelado para la población oncológica. Además, un parto en una paciente con un diagnóstico de neoplasia maligna es un evento clínico atípico (un outlier), y retener estas 12 columnas inyectaría vectores de ceros absolutos al conjunto de datos, lo que no aportaría información discriminativa para las variables de severidad, mortalidad o consumo de recursos.

16. **Diagnóstico principal (DIAGNOSTICO01):** Esta variable ya se retuvo y agrupó en la variable de CATEGORIA_CANCER al inicio del procesamiento, en base a las 15 macro categorías de neoplasias malignas (C00–C97) del CIE-10, y se agregó la categoría SIN_CANCER para los casos del grupo control, por lo que se decidió eliminar esta variable de diagnóstico principal para evitar la redundancia y colinealidad con la variable derivada de categoría de cáncer. Cabe mencionar que esta variable tuvo una cardinalidad de 9711 a lo largo del periodo y se redujo a 16 categorías, capturando el motivo basal del episodio para perfilar al paciente, sin diluir el peso de la variable en los algoritmos de selección de características. Cabe mencionar que, en la cohorte total, los diagnósticos principales más frecuentes fueron H26.9 (catarata, no especificada) con frecuencia de 2,6%, K80.2 (cálculo de la vesícula biliar sin colecistitis) con frecuencia de 1,9%, U07.1 (COVID-19, virus identificado) con frecuencia de 1,8%, K35.8 (Apendicitis aguda, otra y no especificada) con frecuencia de 1,8% y O80.0 (Parto único espontáneo, presentación cefálica de vértice) con frecuencia de 1,6%. Mientras que en la cohorte oncológica, los diagnósticos de cáncer principales más frecuentes C50.9 (Tumor maligno de la mama, parte no especificada) con frecuencia de 4,8%, C73 (Tumor maligno de la glándula tiroides) con frecuencia de 2,1%, C16.9 (Tumor maligno del estómago, parte no especificada) con frecuencia de 2% y C61 (Tumor maligno de la próstata) con frecuencia de 2%.
17. **Diagnósticos secundarios (DIAGNOSTICO2...35):** Estas variables se decidieron descartar y sintetizar para el modelado, ya que presentan una cardinalidad extrema y decreciente iniciando en 15.300 categorías únicas en el diagnóstico 2 y descendiendo hasta 799 en el diagnóstico 35. Además, el análisis masivo reveló que la tasa de valores nulos escaló a aceleradamente, de un 13,7% en el diagnóstico 2 a un 52,8% en el diagnóstico 5, luego a un 99% en el diagnóstico 21 y cerca de un 100% en el diagnóstico 35. Por ende, aplicar One-Hot Encoding a estas 34 columnas inyectaría más de 100.000 nuevas dimensiones al conjunto de datos, compuestas casi en su totalidad por ceros, lo que provocaría un

colapso computacional y la pérdida de capacidad de generalización del modelo (debido a la maldición de la dimensionalidad). Sin embargo, el valor clínico de estos diagnósticos secundarios se rescatará a través de las variables derivadas como TIPO_DIAGNOSTICO_ONCO (para indicar si el diagnóstico oncológico aparece en el primer diagnóstico, en los secundarios o ninguno), la variable de carga oncológica CARGA_ONCOLOGICA (que cuantifica la cantidad de diagnósticos oncológicos presentes en el episodio, lo que sirve como una aproximación clínica de metástasis o la presencia de múltiples tumores sincronizados que sirven para medir numéricamente la extensión del cáncer), el número de comorbilidades (que corresponde al conteo de diagnósticos secundarios válidos, excluyendo el cáncer base y códigos administrativos) y la comorbilidad principal COMORBILIDAD_PRINCIPAL (que mapea la primera comorbilidad válida a los 22 macrogrupos de CIE-10 como endocrinas y metabólicas, asignando la etiqueta de NO_APLICA para el grupo control no oncológico). Cabe mencionar que, en el diagnóstico 2, la cohorte total tiene un 13,7% de casos con valor nulo, seguida por el diagnóstico I10 (hipertensión esencial primaria) con una frecuencia de 7%, luego Z37.0 (parto único, nacido vivo) con un 1,9%, J12.8 (neumonía debida a otros virus) con un 1,7% y E11.9 (diabetes mellitus tipo 2 sin complicaciones) con un 1,6%. En la cohorte oncológica, el diagnóstico secundario 2 más frecuente es I10 (hipertensión esencial primaria) con una frecuencia de 8,2%, seguido por los valores nulos con un 6,6%, luego C91.0 (leucemia linfocítica aguda) con un 2,8%, C50.9 (tumor maligno de la mama, parte no especificada) con un 2% y E11.9 (diabetes mellitus tipo 2 sin complicaciones) con un 1,8%.

18. **Procedimientos** (PROCEDIMIENTO1...30): Para estas 30 variables se descartaron las columnas originales de los procedimientos secundarios y se sintetizaron en variables derivadas, ya que tienen una cardinalidad extrema y decreciente, iniciando con 3.999 categorías únicas en el procedimiento 1 y disminuyendo hasta 762 categorías en el procedimiento 30, además, la variable PROCEDIMIENTO2 ya presenta una tasa de nulos de 8,4% que escala drásticamente hasta alcanzar un 99,3% de nulos en el PROCEDIMIENTO30, por lo que aplicar One-Hot Encoding a este bloque inyectaría aproximadamente 30.000 nuevas columnas al conjunto de datos, provocando un sobreajuste masivo y el colapso de la memoria durante el entrenamiento de los algoritmos. Por ende, el valor predictivo de estas columnas se rescató extrayendo solo el primer procedimiento (PROCEDIMIENTO1) agrupándolo en 18 categorías (sistema nervioso, sistema endocrino, oftalmología, otorrinolaringología, odontología maxilofacial, sistema respiratorio, sistema cardiovascular, sistema hematopoyético, sistema digestivo, sistema urinario, reproductor masculino, reproductor femenino, obstetricia y parto, sistema musculoesquelético, piel y mama, imagenología y diagnóstico, terapéutico no quirúrgico y terapéutico y no quirúrgico), mapeadas en base a los capítulos del CIE-9-MC (Clasificación Internacional de Enfermedades - 9na Revisión - Modificación Clínica),

quedando la variable TIPO_PROCEDIMIENTO. Además, se planteó generar la variable derivada de número de procedimientos (que actúa como un indicador del esfuerzo clínico y consumo de recursos) y la clasificación de si es quirúrgico o no el primer procedimiento, en otras palabras, si corresponde a una intervención con incisión o pabellón (capítulos 01 al 86 del CIE-9-MC) o si fue un ingreso puramente médico, terapéutico o de soporte vital. Cabe mencionar que, en la cohorte total, el primer procedimiento fue 73.59 (parto asistido manualmente) con una frecuencia de 5,8%, seguido por 74.1 (cesarea cervical baja) con una frecuencia de 51.23%, 51.23 (colecistectomía laparoscópica) con una frecuencia de 3,8%, 13.41 (facoemulsificación y aspiración catarata) con una frecuencia de 3,8% y 87.03 tomografía axial computerizada cabeza con una frecuencia de 3%. Mientras que en la cohorte oncológica, el primer procedimiento más frecuente fue 99.25 (inyección quimioterápico NCOC) con una frecuencia de 14,9%, seguido por 86.07 (inserción dispositivo acceso vascular totalmente implantable) con una frecuencia de 3,8%, 88.01 (tomografía axial computerizada abdomen) con una frecuencia de 3,3%, 85.23 (mastectomía subtotal) con una frecuencia de 3,2% y 87.41 (tomografía axial computerizada torax) con una frecuencia de 2,8%.

19. **Especialidad de intervención (ESPECIALIDADINTERVENCION):** Esta variable se decidió descartar, ya que aparte de tener una cardinalidad alta de 104 categorías, presenta graves problemas de densidad de la información, ya que entre el 44,8% de los registros son nulos, lo cual es lógicamente esperado ya que no todos los pacientes ingresados requieren intervención quirúrgica. Por lo tanto, mantener una variable tan fragmentada aportará ruido innecesario a los modelos, sobre todo considerando que la variable estructural ESPECIALIDAD_MEDICA ya será retenida y agrupada en el modelo. En específico, en la cohorte total la especialidad de intervención más frecuente es la nula con 44,8% de frecuencia, seguida por cirugía general con un 12,7%, obstetricia y ginecología con un 12%, traumatología y ortopedia con un 7% y oftalmología con un 5,5%. Mientras que en la cohorte oncológica, la especialidad de intervención más frecuente es la nula con un 53,3% de frecuencia, seguida por cirugía general con un 20,1%, urología con un 6,2%, obstetricia y ginecología con un 5,8% y cirugía de cabeza, cuello y maxilofacial con un 1,6%.
20. **Uso de pabellón (USOSPABELLON):** Esta variable se decidió descartar, ya que tiene una gran cantidad de nulos (49%) y además, según las tablas maestras de GRD, debería tener una 8 categorías: 1 (pabellón central u obstétrico), 2 (pabellón ambulatorio), 3 (sala de procedimiento), 4 (pabellón hemodinamia), 5 (pabellón de urgencia), 6 (pabellón de urgencia habilitado en UCI), 7 (hospital de campaña) y 8 (operativos especiales). Sin embargo, en el análisis se descubrieron 71 categorías, en donde hubo corrupción de formato (por ejemplo, en algunos casos se ingresaron otros números, fechas y caracteres corruptos, demostrando que este campo almacenó información basura en lugar del código esperado). Además, no

se puede asumir que los valores nulos signifiquen que no se ha usado pabellón, ya que la variable registra un 100% de valores nulos para todo el año 2020 y ninguna actividad quirúrgica aunque se haya visto reducida por la pandemia, pudo haber llegado a solo 7 casos a nivel país. Cabe mencionar que, la cohorte total presenta una frecuencia de nulos del 49%, seguida por la categoría 1 (pabellón central u obstétrico) con un 31,5%, luego la categoría 2 (pabellón ambulatorio) con un 9,2%, la categoría 3 (sala de procedimiento) con un 5,1% y la categoría 4 (pabellón hemodinamia) con un 2%. En la cohorte oncológica, nuevamente la categoría de nulos es la más frecuente con un 55,7%, seguida por la categoría 1 (pabellón central u obstétrico) con un 29,4%, luego la categoría 2 (pabellón ambulatorio) con un 6,7%, la categoría 3 (sala de procedimiento) con un 3,9% y la categoría 4 (pabellón hemodinamia) con un 2,6%.

21. **Código GRD (IR_29301_COD_GRD):** Esta variable se descartó ya que es el resultado determinista del algoritmo de facturación, calculado por GRD posteriormente combinando diagnósticos, procedimientos y edad. Dado que los modelos de aprendizaje automático buscarán caracterizar la severidad y consumo de recursos (cuyo peso ponderado se extrae de este mismo código), incluir generaría una colinealidad perfecta, además, la variable tiene una cardinalidad muy alta de 1.671 categorías, a las cuales si se les aplica One-Hot Encoding colapsarían la capacidad de generalización de los modelos. Dentro de los códigos más frecuentes en la cohorte total se encuentran 022360 (3,2%), 146101 (3,1%), 146121 (2,3%), 146131 (2,3%) y 134161 (1,6%). Mientras que en la cohorte oncológica, los códigos GRD más frecuentes son 174132 (5,7%), 174133 (2,8%), 174131 (2,5%), 161201 (2,5%) y 092420 (2,4%).
22. **Probabilidad de mortalidad GRD (IR_29301_MORTALIDAD):** Esta variable se descartó, ya que se trata de un índice sintético calculado por el sistema GRD, sin embargo, retenerlo es redundante y contraproducente, ya que el conjunto de datos ya cuenta con una variable objetivo real y definitiva para el desenlace del paciente, que corresponde al tipo de alta (TIPOALTA), binarizada en vivo o fallecido. Cabe mencionar que esta variable tiene 4 categorías: 0 (sin gravedad), 1 (menor), 2 (moderada) y 3 (mayor), en donde para la cohorte total la categoría 1 tiene una frecuencia de 52,1%, seguida por la categoría 0 con un 16,3%, luego la categoría 2 con un 16,2% y la categoría 3 con un 15,4%. En la cohorte oncológica, la categoría 2 es la más frecuente con un 32,8%, seguida por la categoría 3 con un 31,2%, luego la categoría 1 con un 24,2% y la categoría 0 con un 11,9%. Esto indica que la población oncológica tiene una mayor proporción de casos con mortalidad moderada y mayor, lo que es consistente con la naturaleza de la enfermedad y su impacto en la salud del paciente.

23. **Hospital de procedencia (HOSPPROCEDENCIA):** Esta variable se decidió descartar, ya que tiene una cardinalidad muy alta de 518 categorías, además tiene una densidad insuficiente, ya que en total hay 87,9% de casos con valor nulo y 90,8% de casos con valor nulo en la cohorte oncológica, lo que indica que esta variable no aporta información útil para el modelado y podría introducir ruido innecesario. El estudio de frecuencias indica que 9 de cada 10 pacientes ingresan de forma directa o la derivación inter hospitalaria específica no se registra de manera sistemática en la red. Entonces, inyectar 518 columnas para explicar un fenómeno que solo ocurre en menos del 10% de la muestra penalizaría al modelo sin aportar valor generalizable. Por otro lado, el impacto epidemiológico de las derivaciones ya está sintetizado a través de la variable macro de TIPO_PROCEDENCIA. En específico, para la cohorte total la categoría de nulos es la más frecuente con un 87,9%, seguida por el hospital San Pablo de Coquimbo con un 1,6%, luego el hospital clínico de Magallanes Dr. Lautaro Navarro Avaria con un 0,9%, el hospital San José de Coronel con un 0,8% y el hospital Carlos Van Buren de Valparaíso con un 0,3%. Mientras que en la cohorte oncológica, nuevamente la categoría de nulos es la más frecuente con un 90,8%, seguida por el hospital San Pablo de Coquimbo con un 1,5%, luego el hospital clínico de Magallanes Dr. Lautaro Navarro Avaria con un 0,8%, el hospital Carlos Van Buren de Valparaíso con un 0,7% y el hospital San José de Coronel con un 0,4%.

4.2.4 Análisis de variables numéricas

4.2.4.1 Variable numérica objetivo (consumo de recursos)

Dentro de los datos GRD, se encuentra la variable numérica continua IR_29301_PES0, la cual representa el consumo de recursos hospitalarios respecto al caso promedio nacional, asignado por el sistema GRD a cada episodio hospitalario. Por definición del sistema GRD, el peso relativo de 1,0 equivale al consumo promedio de recursos para un paciente estándar, mientras que valores superiores a 1,0 indican una mayor intensidad en la utilización de camas, insumos, horas médicas y procedimientos. Para comprender la exigencia estructural y de recursos que imponen las neoplasias sobre la red pública, se extrajeron las estadísticas descriptivas globales del período 2019-2024, contrastando la cohorte oncológica frente a la población de control. Estos resultados se consolidan en la Tablas 4.10, 4.11 y 4.9.

En primer lugar, la auditoría certificó una calidad excepcional en el registro

administrativo del consumo, ya que de los 5,8 millones de episodios, solo se detectaron 89 valores nulos (cerca del 0%), de los cuales apenas 4 pertenecen a la cohorte oncológico. Por otro lado, los episodios con costo valorizado en cero fueron marginales (4.906 a nivel global), correspondiendo usualmente a ingresos anulados, fugas tempranas o trámites estrictamente administrativos que no usaron recursos medibles.

Por otro lado, este análisis estadístico demostró la alta complejidad financiera y operativa del paciente oncológico, ya que la media del peso GRD en la cohorte con cáncer (1,30) supera en un 38,3% al consumo medio del grupo de control (0,94). Esta asimetría es aún más evidente al observar la mediana (el valor central de la distribución), en donde la mitad de los episodios se resuelven con un peso de hasta 0,66, el paciente oncológico típico requiere un peso de 1,02, situándose por defecto por encima de la norma basal del sistema hospitalario, lo que prueba que el paciente oncológico base requiere aproximadamente un 50% más de esfuerzo financiero que el paciente estándar.

Al analizar las medidas de tendencia central, se observa que la media aritmética es considerablemente superior a la mediana en todos los años y cohortes, lo que confirma un fuerte sesgo hacia la derecha en la distribución, en otras palabras, la gran mayoría de los ingresos hospitalarios consumen recursos limitados, pero existe una minoría de casos extremadamente costosos que arrastran el promedio general hacia arriba. Sin embargo, al comparar las métricas de las cohortes, se observa que la mediana del paciente oncológico (1,02) supera a la media del grupo de control (0,94), lo que significa que el punto de normalidad operativa o basal para un caso de cáncer equivale estructuralmente a un caso complejo para el resto de las especialidades hospitalarias.

Respecto a las evolución temporal y variabilidad, se captura un profundo impacto probablemente causado por la pandemia de COVID-19 en la gestión de camas de la red pública, ya que durante los años 2020 y 2021, la media de consumo en la población total saltó de 0,84 a 1,11, acompañada por una expansión brusca en la desviación estándar (*Std*), que alcanzó su máximo de 1,41 en 2021. Este fenómeno es consistente con la contracción asistencial detallada previamente en la mortalidad, pues al suspenderse las hospitalizaciones de baja complejidad (casos menos costosos), el sistema retuvo exclusivamente los episodios críticos asociados a la pandemia (como ventilación mecánica, cuadros respiratorios graves y urgencias impostergables), en donde la cohorte oncológica no fue ajena a este efecto, ya que elevó su media de consumo desde 1,16 en 2019 hasta un histórico 1,35 en 2021, estabilizándose levemente en 1,33 hacia el año 2024.

En torno al comportamiento de la dispersión de los datos, se observa que el coeficiente de variación (CV), que estandariza la desviación respecto a la media (permite medir qué tan dispersos están los datos respecto a su propia media), alcanza un valor global elevado de

1, 20 en el grupo de control, lo que refleja una demanda asistencial altamente heterogénea, donde coexisten intervenciones de muy bajo costo con procedimientos excepcionalmente caros. Por el contrario, el grupo oncológico presenta un CV menor (0,88), lo que demuestra que el consumo en oncología no solo es más alto, sino que es estructuralmente constante y homogéneo en los rangos de alta complejidad.

En relación con el rango intercuartílico (IQR), que agrupa al 50% central de los pacientes, corrobora que el grupo de cáncer posee un rango más amplio de consumo normal ($IQR = 0,62$) comparado con el resto del hospital ($IQR = 0,57$). Y al observar los máximos absolutos (*Max*), se detecta que los pacientes de control alcanzan el techo empírico del sistema de agrupamiento GRD (20,64), sin embargo, la frecuencia relativa de valores atípicos severos (*Outliers*) es significativamente mayor en oncología (8,59%) que en el grupo control (6,82%). Esta contradicción de menor tope máximo absoluto mayor densidad de valores extremos confirma que los episodios excepcionalmente costosos en cáncer (como fallas orgánicas múltiples o reconstrucciones masivas) no constituyen eventos raros aislados, sino que son una característica propia y esperable de la progresión de la enfermedad.

Finalmente, al analizar estadísticamente la variable, se concluye que tiene una calidad excelente al presentar casi un 0% de nulos en todos los años, aunque se detectó entre un 7,39% de valores atípicos (*outliers*) superiores en el grupo oncológico, con máximos que alcanzaron los 17,14 puntos de peso, lo que representan a la subpoblación crítica (con probablemente estadías prolongadas, múltiples cirugías o uso intensivo de UCI). Por ende, se decidió mantener y discretizar la variable objetivo en terciles, con el fin de convertirla en una variable categórica ordinal de consumo bajo, medio y alto, mediante cuantiles (*q-cut*), lo que permitirá aplicar algoritmos de clasificación y perfilamiento, garantizando el balanceo de clases necesario para que los selectores de características funcionen correctamente.

Tabla 4.9: Estadística descriptiva anual del Peso Relativo GRD: Población Total (2019-2024).

Año	Total	Nulos	Ceros	Max	Media	Mediana	Std	CV	IQR	Outliers (N)	% Outliers
2019	1.151.398	21	470	20,64	0,84	0,63	0,92	1,09	0,52	69.619	6,05%
2020	781.911	0	190	20,64	1,01	0,69	1,21	1,20	0,61	56.307	7,20%
2021	816.909	0	365	20,64	1,11	0,71	1,41	1,27	0,69	57.798	7,08%
2022	932.837	23	724	20,64	0,97	0,69	1,14	1,17	0,57	70.520	7,56%
2023	1.039.587	30	1.682	20,64	0,96	0,69	1,09	1,13	0,56	78.487	7,55%
2024	1.085.813	15	1.475	20,64	0,97	0,69	1,09	1,12	0,56	82.593	7,61%
GLOBAL	5.808.455	89	4.906	20,64	0,97	0,69	1,14	1,17	0,58	428.964	7,39%

Además, cabe mencionar que las distribuciones, visualizadas a través de diagramas de caja (*boxplots*) en la Figura 4.3, confirman que el consumo de recursos presenta un fuerte sesgo hacia la derecha en todas las poblaciones. Sin embargo, la cohorte oncológica exhibe una dispersión intercuartílica mayor ($IQR = 0,62$) y una tasa superior de valores atípicos severos (8,59%), los cuales no representan errores de registro, sino casos clínicos de complejidad extrema (como estadías prolongadas en UCI post quirúrgicas).

Tabla 4.10: Estadística descriptiva anual del Peso Relativo GRD: Cohorte Oncológica (2019-2024).

Año	Total	Nulos	Ceros	Max	Media	Mediana	Std	CV	IQR	Outliers (N)	% Outliers
2019	97.829	0	13	17,14	1,16	0,97	0,95	0,82	0,53	7.063	7,22%
2020	64.926	0	4	14,24	1,32	1,02	1,14	0,86	0,63	5.349	8,24%
2021	67.926	0	21	17,14	1,35	1,05	1,23	0,90	0,70	5.065	7,46%
2022	78.069	2	47	14,24	1,34	1,04	1,22	0,91	0,64	6.992	8,96%
2023	90.715	0	80	14,24	1,33	1,03	1,19	0,89	0,63	8.437	9,30%
2024	99.153	2	76	14,24	1,33	1,03	1,20	0,90	0,65	8.882	8,96%
GLOBAL	498.618	4	241	17,14	1,30	1,02	1,15	0,88	0,62	42.848	8,59%

Tabla 4.11: Estadística descriptiva anual del Peso Relativo GRD: Grupo Control (2019-2024).

Año	Total	Nulos	Ceros	Max	Media	Mediana	Std	CV	IQR	Outliers (N)	% Outliers
2019	1.053.569	21	457	20,64	0,82	0,59	0,91	1,11	0,45	81.803	7,76%
2020	716.985	0	186	20,64	0,98	0,67	1,22	1,24	0,58	51.466	7,18%
2021	748.983	0	344	20,64	1,08	0,69	1,42	1,31	0,65	60.849	8,12%
2022	854.768	21	677	20,64	0,94	0,66	1,13	1,19	0,57	59.610	6,97%
2023	948.872	30	1.602	20,64	0,93	0,66	1,07	1,16	0,57	64.099	6,76%
2024	986.660	13	1.399	20,64	0,93	0,67	1,07	1,14	0,56	66.785	6,77%
GLOBAL	5.309.837	85	4.665	20,64	0,94	0,66	1,13	1,20	0,57	361.966	6,82%




Figura 4.3: Distribución y valores atípicos del Peso Relativo GRD por cohorte de estudio.

Con el fin de validar la discretización por cuantiles (terciles) de la variable continua de peso (consumo de recursos) y así formular un problema de clasificación de tres clases ordinales, se analizó la estabilidad temporal y poblacional de los terciles como se ve en la Tabla 4.12, ya que dado el severo sesgo a la derecha de la distribución, era imperativo demostrar que esta técnica matemática no generó estratos desbalanceados que puedan perjudicar el aprendizaje de los algoritmos.

Esta tabla muestra el éxito de la discretización operativa, ya que al aplicar la técnica de cortes dinámicos sobre la cohorte total, la variable objetivo logró un balanceamiento natural casi perfecto, gravitando sistemáticamente en torno al 33,3% por categoría. Además, resulta relevante que, al segmentar y analizar exclusivamente a la cohorte oncológica, la distribución de los terciles se mantuvo excepcionalmente equilibrada (Bajo: 33,5%, Medio: 33,4%, Alto: 33,0%), lo que confirma que la definición del target es estadísticamente sólida, garantizando que los modelos cuenten con un volumen equivalente de ejemplos para aprender los factores de riesgo en cada nivel de complejidad financiera, mitigando cualquier riesgo de sub representación durante la etapa de modelado.

Tabla 4.12: Distribución de clases del Consumo de Recursos tras la discretización global (2019-2024).

Cohorte	Nivel Bajo (Tercil 1)	%	Nivel Medio (Tercil 2)	%	Nivel Alto (Tercil 3)	%
Cohorte Total	1.922.961	33,10%	1.913.233	32,94%	1.972.172	33,95%
Cohorte Oncológica	167.201	33,53%	166.838	33,46%	164.575	33,00%
Grupo Control	1.859.140	35,01%	1.651.087	31,09%	1.799.525	33,89%

Además del equilibrio global, era necesario demostrar que la técnica de discretización no fuera susceptible a distorsiones temporales, particularmente frente al impacto estadístico que generó la pandemia de COVID-19 sobre las medias de consumo bruto. Para ello, se auditó la distribución de los terciles año a año, como se ve en la Tabla 4.13, en la cual se puede observar que, a pesar de las marcadas diferencias estructurales entre la cohorte oncológica (cuya media de consumo era naturalmente superior) y la cohorte de control, la aplicación de umbrales generó divisiones virtualmente simétricas en todos los años evaluados, las cuales oscilaron entre un 31,6% y 34,6%, lo que confirma la estabilidad temporal de la variable objetivo y lo ideal de su uso para el modelado predictivo. Cabe mencionar que, incluso durante las caídas de ingresos registradas en la pandemia de 2020 y 2021, donde los volúmenes absolutos disminuyeron severamente y los pesos relativos promedio aumentaron, las proporciones porcentuales dentro de cada nivel de consumo fluctuaron en un margen de error estadísticamente despreciable de $\pm 1,7\%$ respecto al tercio ideal (33,3%).

Esta constancia longitudinal asegura que el aprendizaje de los algoritmos de clasificación no estará sesgado por años atípicos y valida la viabilidad de utilizar esta variable sintética como un indicador fiable para la planificación de recursos en futuros escenarios

hospitalarios.

Tabla 4.13: Distribución anual de los niveles de Consumo de Recursos (Terciles) por cohorte (2019-2024).

Nivel de Consumo	Cohorte	2019	2020	2021	2022	2023	2024
Bajo (Tercil 1)	Pob. Total	382.292 (33,2%)	266.719 (34,1%)	269.717 (33,0%)	316.599 (33,9%)	346.173 (33,3%)	359.714 (33,1%)
	Oncológica	32.334 (33,1%)	21.927 (33,8%)	22.918 (33,7%)	26.985 (34,6%)	30.341 (33,5%)	32.722 (33,0%)
	Control	348.407 (33,1%)	248.329 (34,6%)	254.526 (34,0%)	294.529 (34,5%)	321.771 (33,9%)	325.952 (33,0%)
Medio (Tercil 2)	Pob. Total	378.943 (32,9%)	249.359 (31,9%)	270.321 (33,1%)	299.085 (32,1%)	340.627 (32,8%)	358.018 (33,0%)
	Oncológica	32.409 (33,1%)	21.233 (32,7%)	22.320 (32,9%)	25.725 (33,0%)	31.106 (34,3%)	34.306 (34,6%)
	Control	353.599 (33,6%)	226.370 (31,6%)	239.995 (32,0%)	274.435 (32,1%)	310.908 (32,8%)	327.515 (33,2%)
Alto (Tercil 3)	Pob. Total	390.142 (33,9%)	265.833 (34,0%)	276.871 (33,9%)	317.130 (34,0%)	352.757 (33,9%)	368.066 (33,9%)
	Oncológica	33.086 (33,8%)	21.766 (33,5%)	22.688 (33,4%)	25.357 (32,5%)	29.268 (32,3%)	32.123 (32,4%)
	Control	351.542 (33,4%)	242.286 (33,8%)	254.462 (34,0%)	285.783 (33,4%)	316.163 (33,3%)	333.180 (33,8%)

4.2.4.2 Análisis de variables numéricas de entrada

Dentro de las variables numéricas de entrada, solo se identificaron las variables neonatales correspondientes a los pesos (en gramos) de los recién nacidos al nacer (PESORN1 hasta PESORN4).

1. **Pesos de recién nacidos (PESORN1...4):** se descartaron completamente, ya que al igual que se concluyó con las variables categóricas neonatales, la cohorte de este estudio está delimitada a episodios cuyo diagnóstico es una neoplasia maligna, y que una paciente oncológica curse un parto durante la misma hospitalización es un evento estadísticamente marginal (un outlier clínico a nivel poblacional), por ende, retener estas variables inyectaría cuatro columnas de ruido absoluto que están llenas de valores nulos y ceros (puesto que PESORN1 hasta PESORN4 contienen entre 99% y 100% de valores nulos, como se ve en la tabla 4.14), lo cual consumiría memoria sin aportar varianza matemática que los algoritmos puedan usar para el perfilamiento.

Tabla 4.14: Auditoría de completitud y estadísticos descriptivos globales de variables neonatales (2019-2024).

Variable / Cohorte	Total Episodios	Valores Ausentes (N y %)	Ceros	Media	Mediana	Std
PESORN1 (Pob. Total)	5.808.455	5.012.484 (86,30%)	60	3.183,4	3.268,0	678,4
PESORN1 (Oncológica)	498.618	497.982 (99,87%)	2	2.978,5	3.160,0	819,8
PESORN1 (Control)	5.309.837	4.514.502 (85,02%)	58	3.183,5	3.269,0	678,2
PESORN2 (Pob. Total)	5.808.455	5.799.859 (99,85%)	6	2.259,8	2.349,0	642,1
PESORN3 (Pob. Total)	5.808.455	5.808.380 ($\approx$ 100%)	0	1.546,5	1.635,0	621,5
PESORN4 (Pob. Total)	781.911	781.910 ($\approx$ 100%)	0	780,0	780,0	—

4.3 RESULTADOS DEL PROCESAMIENTO DE VARIABLES OBJETIVO

Luego del análisis sobre las tres variables objetivo (*targets*) de mortalidad, severidad y consumo de recursos, se aplicó una depuración estricta sobre estas, aplicándose una política de exclusión completa para los registros que presentaran valores nulos o desconocidos en el desenlace hospitalario, para así garantizar la legitimidad del *Ground Truth* sobre el cual aprenderán los modelos analíticos. Cabe mencionar que, los resultados del impacto de esta depuración sobre la muestra anual se detallan en la Tabla 4.15.

Tabla 4.15: Auditoría de pérdida de datos por depuración de variables objetivo (2019-2024).

Año	Episodios Iniciales	Registros Eliminados (Target Nulo / %)	Episodios Finales Útiles (<i>Dataset Real</i>)
2019	1.151.398	80 (0,01%)	1.151.318
2020	781.911	23 (0,00%)	781.888
2021	816.909	0 (0,00%)	816.909
2022	932.837	23 (0,00%)	932.814
2023	1.039.587	30 (0,00%)	1.039.557
2024	1.085.813	15 (0,00%)	1.085.798
Total	5.808.455	171 (0,00%)	5.808.284

Como se observa en la Tabla 4.15, el impacto de la eliminación de registros incompletos fue estadísticamente marginal, alcanzando su punto máximo en el año 2019 con apenas 80 filas descartadas (0,01% de la muestra). Para el resto de años, la pérdida de datos rondó el 0,00%, consolidando un conjunto de datos analítico final de gran envergadura y con etiquetas completamente fiables. En total, de los 5.808.455 episodios iniciales, solo se eliminaron 171 registros por tener valores nulos en las variables objetivo, lo que representa una tasa de pérdida de datos del 0,00%.

A continuación, las Tablas 4.16, 4.17 y 4.18 presentan la distribución definitiva de las variables objetivo de Mortalidad, Severidad y Consumo de Recursos respectivamente, tras la depuración de registros con desenlaces nulos y la aplicación de cortes estocásticos (*Terciles*) para la discretización del consumo.

Tabla 4.16: Frecuencias definitivas del target Mortalidad por cohorte (2019-2024).

Clase / Cohorte	2019	2020	2021	2022	2023	2024
Vivo (0) - Oncológica	92.503	60.463	63.503	73.218	85.401	93.144
Vivo (0) - Control	1.029.231	691.483	721.441	832.235	929.034	965.980
Vivo (0) - Pob. Total	1.121.734	751.946	784.944	905.453	1.014.435	1.059.124
Fallecido (1) - Oncológica	5.321	4.462	4.423	4.849	5.314	6.007
Fallecido (1) - Control	24.263	25.480	27.542	22.512	19.808	20.667
Fallecido (1) - Pob. Total	29.584	29.942	31.965	27.361	25.122	26.674

Al observar la Tabla 4.16 (Mortalidad), se verifica que la población oncológica exhibe una tasa de mortalidad significativamente más alta en comparación con el grupo de control. En general, la tasa de mortalidad para la cohorte oncológica es de 6,09% (de 498.608, 468.232

Tabla 4.17: Frecuencias definitivas del target Severidad (Niveles 0 al 3) por cohorte (2019-2024).

Nivel / Cohorte	2019	2020	2021	2022	2023	2024
Nivel 0 - Oncológica	20.675	3.648	5.689	7.909	10.215	11.081
Nivel 0 - Control	181.841	76.016	97.249	146.863	183.335	200.970
Nivel 0 - Pob. Total	202.516	79.664	102.938	154.772	193.550	212.051
Nivel 1 - Oncológica	26.703	19.058	19.126	20.488	21.770	23.198
Nivel 1 - Control	531.838	347.220	321.010	352.952	366.924	364.060
Nivel 1 - Pob. Total	558.541	366.278	340.136	373.440	388.694	387.258
Nivel 2 - Oncológica	30.675	23.807	23.718	26.710	31.917	34.607
Nivel 2 - Control	211.595	152.742	160.104	186.550	221.169	234.258
Nivel 2 - Pob. Total	242.270	176.549	183.822	213.260	253.086	268.865
Nivel 3 - Oncológica	19.771	18.412	19.393	22.960	26.813	30.265
Nivel 3 - Control	128.220	140.985	170.620	168.382	177.414	187.359
Nivel 3 - Pob. Total	147.991	159.397	190.013	191.342	204.227	217.624

Tabla 4.18: Frecuencias definitivas del target Consumo de Recursos (Terciles 0 al 2) por cohorte.

Tercil / Cohorte	2019	2020	2021	2022	2023	2024
Tercil 0 (Bajo) - Onco	10.304	4.463	5.948	7.038	8.998	10.188
Tercil 0 (Bajo) - Control	374.358	262.242	266.729	309.561	338.757	352.112
Tercil 0 (Bajo) - Pob. Total	384.662	266.705	272.677	316.599	347.755	362.300
Tercil 1 (Medio) - Onco	21.605	22.658	24.915	20.558	23.684	31.300
Tercil 1 (Medio) - Control	363.550	233.995	248.701	285.453	322.150	334.153
Tercil 1 (Medio) - Pob. Total	385.155	256.653	273.616	306.011	345.834	365.453
Tercil 2 (Alto) - Onco	65.915	37.804	37.063	50.471	58.033	57.663
Tercil 2 (Alto) - Control	315.586	220.726	233.553	259.733	287.935	300.382
Tercil 2 (Alto) - Pob. Total	381.501	258.530	270.616	310.204	345.968	358.045

sobreviven y 30.376 fallecen), mientras que para el grupo de control es de 2,64% (de 5.309.676, 5.169.404 sobreviven y 140.272 fallecen). Cabe mencionar que, esta diferencia de tasas de mortalidad se mantiene constante a lo largo de los años, confirmando la gravedad intrínseca del cáncer como condición clínica.

Por otro lado, al inspeccionar la Tabla 4.18 (Consumo de Recursos), al desglosar el comportamiento interno por cohorte, se observa que la población oncológica está masivamente desplazada hacia el **Tercil 2 (Alto)**. Por ejemplo, en el año 2024, de un total de 99.151 episodios oncológicos, 57.663 casos (el 58,16%) se concentraron en el estrato de mayor consumo financiero, mientras que solo un 10,28% (10.188 casos) calificó en el Tercil Bajo. Por el contrario, el grupo de control exhibió un comportamiento orientado hacia el Tercil Bajo (0) de forma sistemática durante todo el periodo.

Este comportamiento confirma que el cáncer impone una huella de consumo intrínsecamente severa sobre la red asistencial, validando la necesidad de entrenar modelos predictivos capaces de aislar estas reglas de asignación presupuestaria. Asimismo, los datos de severidad (Tabla 4.17) respaldan esta tendencia, ya que se consolida al Nivel 2 (severidad moderada) y Nivel 3 (severidad mayor) como los entornos normativos para el paciente oncológico (alcanzando casi el 62% de los casos, en específico, 171.434 casos de nivel 2 y 137.614 casos de nivel 3), mientras que el grupo de control posee más del 59,7% de sus casos bajo el estrato de Severidad Menor (1) y sin gravedad (0) (886.274 casos de nivel 0 y 2.284.004 casos de nivel 1).

4.4 RESULTADOS DEL PROCESAMIENTO DE VARIABLES DE ENTRADA

Tras la depuración de las variables objetivo, se procesaron las variables categóricas de entrada con el objetivo de reducir la alta cardinalidad de los atributos mediante agrupaciones semánticas (ingeniería de características) y aplicar exclusiones sobre aquellos episodios que presentaran valores nulos o desconocidos en los campos obligatorios, con el fin de mejorar la calidad de los datos y garantizar la fiabilidad de los modelos predictivos que se entrenarán posteriormente. En consecuencia, para validar que la limpieza no distorsionó la muestra original, se auditó la pérdida iterativa de registros desde la base inicial de 5.808.284 episodios (obtenida tras el procesamiento de las variables objetivo), consolidando el impacto general de esta reducción de cardinalidad y depuración en la Tabla 4.19.

Tabla 4.19: Resumen de reducción de cardinalidad y depuración anual de nulos por variable categórica.

Atributo original y procesado	Cardinalidad	2019	2020	2021	2022	2023	2024	Nulos	F. restantes
SEXO → SEXO	2 → 2	139	134	63	52	39	116	543	5.807.741
ETNIA → ES_PUEBLO_ORIGINARIO	12 → 2	4	0	0	0	0	0	4	5.807.737
PROVINCIA → REGION_RESIDENCIA	57 → 16	808	623	40	43	280	393	2.187	5.805.550
NACIONALIDAD → ES_EXTRANJERO	214 → 2	20.590	3.024	0	0	0	0	23.614	5.781.936
PREVISION → TIPO_PREVISION	14 → 6	3.508	982	9	59	24	39	4.621	5.777.315
SERVICIO_SALUD → TIPO_SERVICIO_SALUD	31 → 5	7	250	466	56	723	567	2.069	5.775.246
TIPO_PROCEDENCIA → TIPO_PROCEDENCIA	19 → 7	207	95	3.089	2	2	5	3.400	5.771.846
TIPO_INGRESO → TIPO_INGRESO	5 → 3	13	18	1	33	55	43	163	5.771.683
ESPECIALIDAD_MEDICA → ESPECIALIDAD_MEDICA	103 → 18	31	20	0	0	0	0	51	5.771.632
TIPO_ACTIVIDAD → TIPO_ACTIVIDAD	5 → 2	3	0	0	0	0	0	3	5.771.629
SERVICIOINGRESO → SERVICIOINGRESO	92 → 7	2.781	185	3.653	5.495	7.401	8.131	27.646	5.743.983
PROCEDIMIENTO1 → TIPO_PROCEDIMIENTO	3.999 → 17	3	0	3	5	11	13	35	5.743.948

Tras la aplicación de estas transformaciones (agrupaciones y exclusión de nulos), se logró reducir la cardinalidad de las variables categóricas de entrada de manera significativa, en donde destaca la variable de nacionalidad, que se redujo de 214 categorías a un indicador binario de migración (extranjero o chileno), las especialidades médicas, que se agruparon desde 103 categorías hacia 18 macro áreas funcionales, y los procedimientos, que se consolidaron desde 3.999 códigos específicos hacia 17 categorías funcionales. Por otro lado, al evaluar la cantidad de episodios eliminados para la depuración de nulos, se concluyó que la pérdida global acumulada fue de 64.336 episodios, lo que representa aproximadamente un 1,1% del volumen inicial.

Respecto al impacto de la eliminación de filas incompletas en las variables objetivo, se verificó que la mayoría de los episodios a eliminar no estuviesen fuertemente con desenlaces clínicos específicos (como alta mortalidad o severidad extrema), lo que podría distorsionar el *Ground Truth* sobre el cual aprenderán los algoritmos, en especial si se eliminan registros con desenlaces minoritarios (como desenlace de fallecimiento).

Para descartar este fenómeno y garantizar una auditoría transparente, se desglosó

el impacto de la exclusión de nulos de manera individual para cada una de las 12 variables categóricas procesadas y se registró en distintas tablas cómo se distribuyeron las filas eliminadas en cada clase de los *targets* de Mortalidad, Severidad y Consumo de Recursos, separando el efecto sobre la cohorte oncológica frente a la población de control.

Como se ven en las Tablas 4.20, 4.21, 4.22, 4.23, 4.24, 4.25, ??, ??, ??, ??, 4.30 y 4.31, la eliminación de nulos y valores desconocidos para cada variable implicó una pérdida de registros que no superó el 0,5% de la muestra de 5.808.284 tras la depuración de las variables objetivo, y en la mayoría de los casos, la pérdida fue inferior al 0,1%. En total, tras la eliminación de los valores nulos y desconocidos, se recortaron 64.336 episodios (un 1,1% de la muestra), en donde 3.481 episodios correspondieron a la cohorte oncológica (un 0,06% de la muestra) y 60.545 episodios a la población de control (un 1,04% de la muestra), por lo que se concluyó que la limpieza de nulos no distorsionó la muestra original ni introdujo un sesgo de eliminación hacia desenlaces clínicos específicos, ya que la mayoría de los episodios eliminados correspondieron a desenlaces de supervivencia (clase mayoritaria).

En específico, se analizó el impacto del procesamiento de las siguientes variables:

- **Sexo:** las filas con valor DESCONOCIDO en el campo de sexo tuvieron una frecuencia estadísticamente marginal, representando un total de 543 episodios eliminados, que corresponde a un 0,0093% de la muestra. Como se ve en la tabla 4.20, en la cohorte oncológica, la pérdida máxima fue de 31 casos, que equivale a un 0,0005% de los casos. Por ende, se aprobó la eliminación directa de los registros nulos, ya que no se identificó un sesgo de eliminación hacia desenlaces clínicos críticos, ya que en los casos oncológicos, la mayoría de los episodios eliminados correspondieron a desenlaces de supervivencia (que es la clase mayoritaria), casos de severidad moderada (12 episodios) y consumo de recursos alto (22 casos).
- **Etnia:** al principio tenía como clase mayoritaria el valor de NINGUNO, pero a partir de 2022, esta categoría desaparece en favor del valor OTRO, sin embargo, la binarización aplicada a esta variable (para indicar si un paciente es o no parte de un pueblo originario) permitió neutralizar este cambio de criterio del registro GRD, sumado que las etnias específicas representaban consistentemente menos del 2% de la muestra anual. En relación con los registros nulos, como se ve en la tabla 4.21, esta variable presentó apenas 4 episodios con valor nulo pertenecientes a la muestra control, correspondiendo a un 0,0001% de la muestra, por lo que se aprobó la eliminación directa de los 4 registros. Además, la mayoría de los episodios eliminados correspondieron a desenlaces de supervivencia (clase mayoritaria), severidad menor (nivel 1) y consumo medio y alto (tercil 2 y 3).
- **Provincia (región de residencia):** la agrupación en 16 regiones de esta variable representa

un punto de equilibrio óptimo para evitar problemas como la maldición de la dimensionalidad. En relación con los registros nulos, como se ve en la tabla 4.22, esta variable presentó 2.187 episodios con valor nulo (un 0,0377% de la muestra), de los cuales 103 pertenecen a la cohorte oncológica y 2.084 a la población de control (un 0,0018% y 0.0359% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia (clase mayoritaria), severidad menor (nivel 1) y consumo de recursos bajo (tercil 1).

- **Nacionalidad (es extranjero):** la binarización de esta variable permitió reducir su cardinalidad de 214 categorías a un indicador binario de migración (extranjero o chileno), lo que es relevante para evitar problemas de dimensionalidad, considerando que la categoría **Chile** abarcaba aproximadamente un 94% de los registros y aplicar técnicas de *One-Hot Encoding* sobre las 213 categorías restantes inyectaría una cantidad masiva de columnas vacías (matrices dispersas). En relación con los registros nulos, como se ve en la tabla 4.23, esta variable presentó 23.614 episodios con valor nulo (un 0,4066% de la muestra), de los cuales 1.165 pertenecen a la cohorte oncológica y 22.449 a la población de control (un 0,0201% y 0.3874% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia (clase mayoritaria), severidad menor (nivel 1) y consumo de recursos bajo (tercil 1).
- **Previsión (tipo de previsión):** la reducción de cardinalidad de esta variable desde 14 categorías hacia 6 categorías funcionales (PRIVADO, FFAA Y ORDEN, FONASA A, B, C y D) permitió reducir la dimensionalidad del espacio de características, agrupando categorías con frecuencias cercanas al 1% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.24, esta variable presentó 4.621 episodios con valor nulo (un 0,0796% de la muestra), de los cuales 353 pertenecen a la cohorte oncológica y 4.268 a la población de control (un 0,0061% y 0.0735% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad menor (nivel 1) y consumo de recursos bajo (tercil 1).
- **Servicio de salud (tipo de servicio de salud):** la reducción de cardinalidad de esta variable desde 31 categorías hacia 5 categorías funcionales (Macrozona Norte, RM, Centro, Centro Sur y Sur Austral) permitió disminuir la dimensionalidad del espacio de características, agrupando categorías con frecuencias entre el 1% y 3% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.25, esta variable presentó 2.069 episodios con

valor nulo (un 0,0356% de la muestra), de los cuales 104 pertenecen a la cohorte oncológica y 1.965 a la población de control (un 0,0018% y 0.0338% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad menor (nivel 1) y consumo de recursos alto (tercil 3).

- **Tipo de procedencia:** la reducción de cardinalidad de esta variable desde 19 categorías hacia 7 categorías funcionales (Ambulatorio APS, especialidad, institución cerrada, traslado privado, traslado red pública, urgencia domicilio y red primaria) permitió disminuir la dimensionalidad del espacio de características, agrupando categorías con frecuencias entre el 1% y 2% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.26, esta variable presentó 3.400 episodios con valor nulo (un 0,0585% de la muestra), de los cuales 87 pertenecen a la cohorte oncológica y 3.313 a la población de control (un 0,0015% y 0.057% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad sin gravedad (nivel 0) y consumo de recursos bajo (tercil 1).
- **Tipo de ingreso:** la eliminación de valores nulos y categóricos de esta variable permitió reducir su cardinalidad desde 5 categorías hacia 3 categorías funcionales (Urgencia, Electivo y Obstetrico). En relación con los registros nulos, como se ve en la tabla 4.27, esta variable presentó 163 episodios con valor nulo (un 0,0028% de la muestra), de los cuales 17 pertenecen a la cohorte oncológica y 146 a la población de control (un 0,0003% y 0.0025% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad menor (nivel 1) y consumo de recursos medio (tercil 2).
- **Especialidad médica:** la reducción de cardinalidad de esta variable desde 103 categorías hacia 18 categorías funcionales permitió disminuir la dimensionalidad del espacio de características, agrupando categorías con frecuencias cercanas al 1% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.28, esta variable presentó 51 episodios con valor nulo (un 0,0009% de la muestra), de los cuales 20 pertenecen a la cohorte oncológica y 31 a la población de control (un 0,0003% y 0.0005% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad sin gravedad (nivel 0) y consumo de recursos bajo (tercil 1).
- **Tipo de actividad:** la agrupación de categorías permitió reducir la cardinalidad de esta variable desde 5 categorías hacia 2 categorías funcionales (Hospitalización tradicional y ambulatorio CMA), lo que permitió resolver la desaparición de categorías (como

hospitalización en urgencia y diurna) en los años posteriores a 2019. En relación con los registros nulos, como se ve en la tabla 4.29, esta variable presentó 3 episodios con valor nulo (un 0,00001% de la muestra) pertenecientes a la cohorte control, por lo que se aprobó la eliminación directa de los registros nulos. Además, los 3 episodios correspondieron al desenlace de supervivencia, severidad sin gravedad (nivel 0) y consumo de recursos bajo (tercil 1).

- **Servicio de ingreso:** la reducción de cardinalidad de esta variable desde 92 categorías hacia 7 categorías funcionales permitió disminuir la dimensionalidad del espacio de características, agrupando categorías con frecuencias entre el 2% y 3% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.30, esta variable presentó 27.646 episodios con valor nulo (un 0,476% de la muestra), de los cuales 1.958 pertenecen a la cohorte oncológica y 25.688 a la población de control (un 0,0337% y 0.4423% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad mayor (nivel 3) y consumo de recursos alto (tercil 3).
- **Procedimiento 1 (tipo de procedimiento):** la reducción de cardinalidad de esta variable desde 3.999 códigos específicos hacia 17 categorías funcionales permitió disminuir la dimensionalidad del espacio de características, agrupando categorías con frecuencias menores al 1% de la muestra. En relación con los registros nulos, como se ve en la tabla 4.31, esta variable presentó 35 episodios con valor nulo (un 0,0006% de la muestra), de los cuales 3 pertenecen a la cohorte oncológica y 32 a la población de control (un 0,00005% y 0.0006% respectivamente), por lo que se aprobó la eliminación directa de los registros nulos. Además, la mayoría de los episodios eliminados corresponden a desenlaces clínicos de supervivencia, severidad moderada (nivel 2) y consumo de recursos alto (tercil 3).

Tabla 4.20: Impacto de la exclusión de nulos en SEX0 sobre las variables objetivo.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	28	484	512
Mortalidad (1: Fallecido)	3	28	31
Severidad (0: Sin gravedad)	6	80	86
Severidad (1: Menor)	7	204	211
Severidad (2: Moderada)	12	119	131
Severidad (3: Mayor)	6	109	115
Consumo (0: Bajo)	2	169	171
Consumo (1: Medio)	7	174	181
Consumo (2: Alto)	22	169	191
Total Filas Faltantes	31 (0.0005%)	512 (0.0088%)	543 (0.0093%)

Tabla 4.21: Impacto de la exclusión de nulos en ETNIA (ES_PUEBLO_ORIGINARIO).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	0	3	3
Mortalidad (1: Fallecido)	0	1	1
Severidad (0: Sin gravedad)	0	0	0
Severidad (1: Menor)	0	3	3
Severidad (2: Moderada)	0	1	1
Severidad (3: Mayor)	0	0	0
Consumo (0: Bajo)	0	0	0
Consumo (1: Medio)	0	2	2
Consumo (2: Alto)	0	2	2
Total Filas Faltantes	0 (0%)	4 (0.0001%)	4 (0.0001%)

Tabla 4.22: Impacto de la exclusión de nulos en PROVINCIA (REGION_RESIDENCIA).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	97	2.022	2.119
Mortalidad (1: Fallecido)	6	62	68
Severidad (0: Sin gravedad)	6	545	551
Severidad (1: Menor)	54	950	1.004
Severidad (2: Moderada)	25	259	284
Severidad (3: Mayor)	18	330	348
Consumo (0: Bajo)	10	952	962
Consumo (1: Medio)	29	557	586
Consumo (2: Alto)	64	575	639
Total Filas Faltantes	103 (0.0018%)	2.084 (0.0359%)	2.187 (0.0377%)

Tabla 4.23: Impacto de la exclusión de nulos en NACIONALIDAD (ES_EXTRANJERO).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	1.039	21.892	22.931
Mortalidad (1: Fallecido)	126	557	683
Severidad (0: Sin gravedad)	111	4.556	4.667
Severidad (1: Menor)	299	11.303	11.602
Severidad (2: Moderada)	512	4.405	4.917
Severidad (3: Mayor)	243	2.185	2.428
Consumo (0: Bajo)	106	8.736	8.842
Consumo (1: Medio)	349	8.195	8.544
Consumo (2: Alto)	710	5.518	6.228
Total Filas Faltantes	1.165 (0.0201%)	22.449 (0.3874%)	23.614 (0.4066%)

Tabla 4.24: Impacto de la exclusión de nulos en PREVISION (TIPO_PREVISION).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	326	4.081	4.407
Mortalidad (1: Fallecido)	27	187	214
Severidad (0: Sin gravedad)	185	424	609
Severidad (1: Menor)	59	2.503	2.562
Severidad (2: Moderada)	61	695	756
Severidad (3: Mayor)	48	646	694
Consumo (0: Bajo)	39	1.740	1.779
Consumo (1: Medio)	64	1.246	1.310
Consumo (2: Alto)	250	1.282	1.532
Total Filas Faltantes	353 (0.0061%)	4.268 (0.0735%)	4.621 (0.0796%)

Tabla 4.25: Impacto de la exclusión de nulos en SERVICIO_SALUD (TIPO_SERVICIO_SALUD).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	96	1.911	2.007
Mortalidad (1: Fallecido)	8	54	62
Severidad (0: Sin gravedad)	3	38	41
Severidad (1: Menor)	40	1.190	1.230
Severidad (2: Moderada)	32	377	409
Severidad (3: Mayor)	29	360	389
Consumo (0: Bajo)	5	679	684
Consumo (1: Medio)	36	609	645
Consumo (2: Alto)	63	677	740
Total Filas Faltantes	104 (0.0018%)	1.965 (0.0338%)	2.069 (0.0356%)

Tabla 4.26: Impacto de la exclusión de nulos en TIPO_PROCEDENCIA.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	87	3.298	3.385
Mortalidad (1: Fallecido)	0	15	15
Severidad (0: Sin gravedad)	14	2.101	2.115
Severidad (1: Menor)	26	851	877
Severidad (2: Moderada)	18	309	327
Severidad (3: Mayor)	29	52	81
Consumo (0: Bajo)	12	1.466	1.478
Consumo (1: Medio)	32	1.379	1.411
Consumo (2: Alto)	43	468	511
Total Filas Faltantes	87 (0.0015%)	3.313 (0.057%)	3.400 (0.0585%)

Tabla 4.27: Impacto de la exclusión de nulos en TIPO_INGRESO.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	17	145	162
Mortalidad (1: Fallecido)	0	1	1
Severidad (0: Sin gravedad)	0	4	4
Severidad (1: Menor)	3	68	71
Severidad (2: Moderada)	9	51	60
Severidad (3: Mayor)	5	23	28
Consumo (0: Bajo)	0	38	38
Consumo (1: Medio)	6	63	69
Consumo (2: Alto)	11	45	56
Total Filas Faltantes	17 (0.0003%)	146 (0.0025%)	163 (0.0028%)

Tabla 4.28: Impacto de la exclusión de nulos en ESPECIALIDAD_MEDICA.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	19	31	50
Mortalidad (1: Fallecido)	1	0	1
Severidad (0: Sin gravedad)	0	23	23
Severidad (1: Menor)	7	4	11
Severidad (2: Moderada)	7	2	9
Severidad (3: Mayor)	6	2	8
Consumo (0: Bajo)	1	24	25
Consumo (1: Medio)	2	5	7
Consumo (2: Alto)	17	2	19
Total Filas Faltantes	20 (0.0003%)	31 (0.0005%)	51 (0.0009%)

Tabla 4.29: Impacto de la exclusión de nulos en TIPO_ACTIVIDAD.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	0	3	3
Mortalidad (1: Fallecido)	0	0	0
Severidad (0: Sin gravedad)	0	3	3
Severidad (1: Menor)	0	0	0
Severidad (2: Moderada)	0	0	0
Severidad (3: Mayor)	0	0	0
Consumo (0: Bajo)	0	3	3
Consumo (1: Medio)	0	0	0
Consumo (2: Alto)	0	0	0
Total Filas Faltantes	0 (0.0000%)	3 (0.0001%)	3 (0.0001%)

Tabla 4.30: Impacto de la exclusión de nulos en SERVICIOINGRESO.

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	1.843	24.420	26.263
Mortalidad (1: Fallecido)	115	1.268	1.383
Severidad (0: Sin gravedad)	43	2.664	2.707
Severidad (1: Menor)	480	9.119	9.599
Severidad (2: Moderada)	479	4.975	5.454
Severidad (3: Mayor)	956	8.930	9.886
Consumo (0: Bajo)	79	8.017	8.096
Consumo (1: Medio)	337	7.657	7.994
Consumo (2: Alto)	1.542	10.014	11.556
Total Filas Faltantes	1.958 (0.0337%)	25.688 (0.4423%)	27.646 (0.4760%)

Tabla 4.31: Impacto de la exclusión de nulos en PROCEDIMIENTO1 (TIPO_PROCEDIMIENTO).

Variable Objetivo (Clase)	Oncológico	Control	Total
Mortalidad (0: Vivo)	3	32	35
Mortalidad (1: Fallecido)	0	0	0
Severidad (0: Sin gravedad)	0	3	3
Severidad (1: Menor)	0	9	9
Severidad (2: Moderada)	2	14	16
Severidad (3: Mayor)	1	6	7
Consumo (0: Bajo)	0	7	7
Consumo (1: Medio)	2	6	8
Consumo (2: Alto)	1	19	20
Total Filas Faltantes	3 (0.00005%)	32 (0.0006%)	35 (0.0006%)

4.5 RESULTADOS DE LA GENERACIÓN DE VARIABLES DERIVADAS

Para capturar la complejidad clínica y operativa se sintetizó la información granular de las matrices de diagnósticos, procedimientos y fechas para construir 7 nuevos atributos analíticos: uno categórico y 6 numéricos continuos.

4.5.1 Análisis de las variables derivadas categóricas

El primer atributo categórico derivado fue la bandera binaria `ES_QUIRURGICO`, la cual discrimina si el episodio clínico requirió o no el ingreso a pabellón, analizando el primer código CIE-9 de la matriz de procedimientos. Como se observa en la Tabla 4.32, la red pública presenta una carga marcadamente intervencionista, con una proporción de episodios quirúrgicos que escaló desde un 59,15% en 2019 hasta consolidarse sobre el 61% a partir de 2022.

Tabla 4.32: Proporción anual de episodios médicos versus quirúrgicos (2019-2024).

Clase Operativa	2019	2020	2021	2022	2023	2024
0 (Médico)	458.805 (40,85%)	322.514 (41,53%)	337.260 (41,66%)	348.798 (37,62%)	386.651 (37,50%)	412.644 (38,33%)
1 (Quirúrgico)	664.419 (59,15%)	454.043 (58,47%)	472.325 (58,34%)	578.271 (62,38%)	644.371 (62,50%)	663.847 (61,67%)

El segundo atributo, `COMORBILIDAD_PRINCIPAL`, se diseñó de manera exclusiva para perfilar a la cohorte oncológica, mapeando la macro-categoría CIE-10 de su patología concomitante más relevante. Como lo demuestra la Tabla ??, más del 90% del *dataset* se etiqueta como `NO_APLICA` al corresponder al grupo de control. Dentro de los pacientes oncológicos, destacan como comorbilidades dominantes las enfermedades del **Sistema Circulatorio** (creciendo de un 1,58% a un 1,70%), seguidas por los trastornos del **Sistema Digestivo** y las enfermedades **Endocrinas y Metabólicas**, evidenciando el alto grado de pluripatología que acompaña al cáncer.

4.5.2 Comportamiento de las Variables Numéricas Derivadas

Para dimensionar la densidad de la hospitalización, se calcularon seis variables continuas: la edad empírica al ingreso (`EDAD`), la duración real del episodio (`DIAS_ESTADIA`), la movilidad interna (`CANTIDAD_TRASLADOS`), la densidad intervencionista (`NUM_PROCEDIMIENTOS`),

Tabla 4.33: Distribución anual exhaustiva de la variable derivada Comorbilidad Principal (2019-2024).

Macro-Categoría CIE-10	2019	2020	2021	2022	2023	2024
Códigos Prov. (COVID-19)	50 (0,00%)	1.420 (0,18%)	1.748 (0,22%)	1.608 (0,17%)	584 (0,06%)	371 (0,03%)
Endocrinas y Metabólicas	8.453 (0,75%)	5.423 (0,70%)	6.474 (0,80%)	7.559 (0,82%)	8.912 (0,86%)	9.822 (0,91%)
Infecciosas y Parasitarias	2.291 (0,20%)	1.779 (0,23%)	1.758 (0,22%)	1.971 (0,21%)	2.419 (0,23%)	2.674 (0,25%)
Materno-Infantiles y Cong.	573 (0,05%)	477 (0,06%)	377 (0,05%)	517 (0,06%)	579 (0,06%)	575 (0,05%)
No Aplica (Grupo Control)	1.026.821 (91,42%)	711.905 (91,67%)	741.800 (91,63%)	849.540 (91,64%)	940.943 (91,26%)	978.172 (90,87%)
Ojo y Oído	1.067 (0,09%)	541 (0,07%)	655 (0,08%)	1.033 (0,11%)	1.292 (0,13%)	1.323 (0,12%)
Piel y Tejido Subcutáneo	912 (0,08%)	647 (0,08%)	659 (0,08%)	714 (0,08%)	878 (0,09%)	1.092 (0,10%)
Sangre e Inmunidad	5.989 (0,53%)	4.510 (0,58%)	4.263 (0,53%)	4.706 (0,51%)	5.558 (0,54%)	6.329 (0,59%)
Síntomas y Hallazgos	2.942 (0,26%)	2.378 (0,31%)	2.543 (0,31%)	2.789 (0,30%)	3.261 (0,32%)	3.691 (0,34%)
Sin Comorbilidad (Onco puro)	25.182 (2,24%)	12.244 (1,58%)	11.788 (1,46%)	12.438 (1,34%)	13.579 (1,32%)	12.915 (1,20%)
Sistema Circulatorio	17.781 (1,58%)	11.798 (1,52%)	12.597 (1,56%)	14.701 (1,59%)	16.605 (1,61%)	18.280 (1,70%)
Sistema Digestivo	8.427 (0,75%)	7.243 (0,93%)	7.991 (0,99%)	8.947 (0,97%)	11.131 (1,08%)	12.088 (1,12%)
Sistema Genitourinario	5.779 (0,51%)	4.513 (0,58%)	5.286 (0,65%)	6.116 (0,66%)	7.268 (0,70%)	8.462 (0,79%)
Sistema Músculoesquelético	1814 (0,16%)	1.353 (0,17%)	1.436 (0,18%)	1.802 (0,19%)	2.310 (0,22%)	2.482 (0,23%)
Sistema Nervioso	1.863 (0,17%)	1.410 (0,18%)	1.471 (0,18%)	1.620 (0,17%)	1.961 (0,19%)	2.287 (0,21%)
Sistema Respiratorio	6.944 (0,62%)	4.455 (0,57%)	4.033 (0,50%)	5.486 (0,59%)	7.129 (0,69%)	8.377 (0,78%)
Trastornos Mentales	2.908 (0,26%)	1.570 (0,20%)	1.564 (0,19%)	1.774 (0,19%)	2.034 (0,20%)	2.269 (0,21%)
Traumatismos y Enven.	3.428 (0,31%)	2.891 (0,37%)	3.142 (0,39%)	3.748 (0,40%)	4.579 (0,44%)	5.282 (0,49%)

la morbilidad (NUM_COMORBILIDADES) y la dispersión tumoral (CARGA_ONCOLOGICA). La Tabla 4.34 resume sus estadísticos de tendencia central y dispersión.

Tabla 4.34: Estadística descriptiva de las variables numéricas derivadas (resumen 2019 vs 2024).

Variable Derivada	Año	Mín - Máx	Media	Std	Outliers (N)	Outliers (%)
CANTIDAD_TRASLADOS	2019	0 - 9	0,22	0,62	164.536	14,65%
	2024	0 - 9	0,24	0,65	170.890	15,87%
NUM_PROCEDIMIENTOS	2019	0 - 30	6,75	5,26	42.307	3,77%
	2024	0 - 30	8,00	6,12	35.744	3,32%
NUM_COMORBILIDADES	2019	0 - 35	3,19	2,76	54.551	4,86%
	2024	0 - 35	4,32	3,77	43.551	4,05%
CARGA_ONCOLOGICA	2019	0 - 8	0,15	0,45	136.375	12,14%
	2024	0 - 10	0,17	0,50	144.511	13,42%
EDAD (Años)	2019	0 - 124	43,09	25,86	0	0,00%
	2024	0 - 108	45,68	25,45	0	0,00%
DIAS_ESTADIA	2019	0 - 2322	5,29	12,80	121.998	10,86%
	2024	0 - 645	5,64	12,02	106.661	9,91%

El análisis descriptivo revela un aumento sistémico en la densidad hospitalaria: la cantidad media de procedimientos escaló de 6,75 a 8,00 por episodio, mientras que la cantidad de comorbilidades documentadas ascendió de 3,19 a 4,32. Esto sugiere no solo un envejecimiento progresivo de la población admitida (cuya media etaria pasó de 43 a casi 46 años), sino también una mejora en la exhaustividad del registro clínico por parte del personal de salud a nivel nacional.

4.5.3 Depuración de Anomalías Temporales

La derivación matemática de las variables cronológicas (EDAD y DIAS_ESTADIA) permitió someter a prueba la consistencia empírica de las fechas de ingreso, nacimiento y alta hospitalaria. El escaneo de sustracción detectó la presencia de valores lógicamente imposibles (estadías o edades con resultado negativo). Como se documenta en la Tabla 4.35, este fenómeno correspondió a errores reales de digitación en los sistemas de admisión hospitalaria (por ejemplo, registrar una fecha de alta anterior a la fecha de ingreso).

Dado que los algoritmos paramétricos son altamente sensibles a valores continuos negativos en métricas de duración, estos registros corruptos fueron forzados a valores nulos (NaN) y posteriormente eliminados del *dataset* final.

La pérdida documentada de 132 episodios (combinando ambas fallas) frente a un universo de más de 5,7 millones de registros representa una fracción de error del 0,002%. Con la exclusión de estas filas anómalas, se declara oficialmente el término de la fase de preparación de datos, consolidando una matriz de entrenamiento que se encuentra 100% libre de valores nulos (*Missing Values*) e inconsistencias cronológicas.

Tabla 4.35: Auditoría de eliminación de episodios con anomalías cronológicas (Edades y Estadías negativas).

Año	Pacientes Iniciales	Estadías Negativas	Edades Negativas	Pacientes Finales Útiles
2019	1.123.224	0	0	1.123.224
2020	776.557	10	1	776.546
2021	809.585	0	0	809.585
2022	927.069	1	7	927.061
2023	1.031.022	0	10	1.031.012
2024	1.076.491	50	53	1.076.438
TOTAL	5.743.948	61	71	5.743.866

CAPÍTULO 5. CONCLUSIONES

La carrera de Ingeniería de Ejecución en Computación e Informática antecede la aparición del Departamento de Ingeniería Informática por diez años. Ella comenzó a dictarse en 1972 bajo la responsabilidad del Centro de Computación de la UTE (CECUTE) y se regularizó su creación por medio del Decreto 944 de 1975, el que establece su dependencia de la Facultad de Ingeniería. Los primeros Ingenieros de Ejecución en Computación e Informática comenzaron a titularse en el año 1976 (Delgado, 2016).

GLOSARIO

CMS: Un Sistema de gestión de contenidos (Content Management System en inglés, abreviado CMS) es un programa que permite crear una estructura de soporte (framework) para la creación y administración de contenidos, principalmente en páginas web, por parte de los participantes. Consiste en una interfaz que controla una o varias bases de datos donde se aloja el contenido del sitio. El sistema permite manejar de manera independiente el contenido y el diseño. Así, es posible manejar el contenido y darle en cualquier momento un diseño distinto al sitio sin tener que darle formato al contenido de nuevo, además de permitir la fácil y controlada publicación en el sitio a varios editores.

Copyleft: Es una forma de licencia y puede ser usado para modificar el derecho de autor de obras o trabajos, tales como software de computadoras, documentos, música, y obras de arte. Bajo tales licencias pueden protegerse una gran diversidad de obras, tales como programas informáticos, arte, cultura y ciencia, es decir prácticamente casi cualquier tipo de producción creativa.

Creative Commons: Es una organización no gubernamental sin ánimo de lucro que desarrolla planes para ayudar a reducir las barreras legales de la creatividad, por medio de nueva legislación y nuevas tecnologías. Fue fundada por Lawrence Lessig, profesor de derecho en la Universidad de Stanford y especialista en ciberderecho, que la presidió hasta marzo de 2008.

Distribución GNU/Linux: Versión de GNU/Linux que agrupa una serie de programas, que es organizada y mantenida adelante por algún grupo, empresa o institución.

Drupal: Es un programa de código abierto, con licencia GNU/GPL, escrito en PHP, desarrollado y mantenido por una activa comunidad de usuarios. Destaca por la calidad de su código y de las páginas generadas, el respeto de los estándares de la web, y un énfasis especial en la usabilidad y consistencia de todo el sistema.

RSS: Es el acrónimo de Really Simple Syndication, una familia de formatos utilizada para publicar frecuentemente contenidos actualizados, como entradas de blogs o titulares de noticias. Un documento RSS puede contener un resumen de su contenido de un sitio web asociado o su texto completo.

REFERENCIAS BIBLIOGRÁFICAS

- Alsinglawi, B., Alshari, O., Alorjani, M., Mubin, O., Alnajjar, F., Novoa, M., & Darwish, O. (2022). An explainable machine learning framework for lung cancer hospital length of stay prediction. *Scientific Reports*, 12(1).
- Chen, Q., Cherry, D. R., Nalawade, V., Qiao, E. M., Kumar, A., Lowy, A. M., Simpson, D. R., & Murphy, J. D. (2021). Clinical data prediction model to identify patients with early-stage pancreatic cancer. *JCO Clinical Cancer Informatics*, 5, 279–287.
- Chen, T., & Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, (pp. 785–794). ACM.
URL <https://dl.acm.org/doi/10.1145/2939672.2939785>
- Cid, C., Dawson, N., Medina, C., Espinoza, A., & Bastías, G. (2024). Lecciones y desafíos del uso de los grupos relacionados por el diagnóstico en Chile. *Revista Panamericana de Salud Pública*, 48.
- Clapes UC (2023). Gestión hospitalaria pública en Chile y el mecanismo de pago GRD. Tech. rep., Pontificia Universidad Católica de Chile.
URL https://assets.clapesuc.cl/Mecanismo_GRD_17_Nov_final_v2_e4d6520d7f.pdf
- DEIS (2023). Norma técnica n° 820: Estándares de información de salud. Tech. Rep. Exento N° 231, Departamento de Estadísticas e Información de Salud, Ministerio de Salud de Chile, Santiago, Chile. Publicado en el Diario Oficial el 12 de enero de 2023.
- Delgado, F. (2016). *Piñera es el presidenciable con más exposición en la prensa según investigación Usach*. Recuperado el Martes 29 de Julio de 2016, de <http://www.biobiochile.cl/noticias/nacional/politica/2016/06/20/pinera-es-el-presidenciable-con-mas-exposicion-en-la-prensa-segun-investigacion-usach.shtml>.
- Departamento de Estadísticas e Información de Salud (DEIS) (2018). Manual con orientaciones de codificación para el capítulo II "tumores [neoplasias]" para el tipo de actividad hospitalización. Tech. rep., Ministerio de Salud de Chile.
URL <https://repositoriodeis.minsal.cl/ContenidoSitioWeb2020/uploads/2018/07/Orientaciones-de-codificaci%C3%B3n-para-el-Cap%C3%ADtulo-II-de-la-CIE-10.pdf>
- Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1), 1–26.
URL <https://projecteuclid.org/journals/annals-of-statistics/volume-7/issue-1/Bootstrap-Methods-Another-Look-at-the-Jackknife/10.1214/aos/1176344552.full>
- Fondo Nacional de Salud (FONASA) (2023). Informe trimestral programa 05: Implementación GRD hospitales públicos (glosa 03). Tech. rep., Ministerio de Salud, Gobierno de Chile.
URL https://www.senado.cl/site/presupuesto/2023/cumplimiento/Glosas%202023/16%20Salud/1602_19576_08112023_FONASA.pdf
- Fondo Nacional de Salud (FONASA) (2024). Visor público de grupos relacionados por el diagnóstico (GRD). Plataforma de datos abiertos. Accedido en línea.
URL <https://public.tableau.com/views/PropuestaTableroGRD/PropuestaTableroGRD?%3AshowVizHome=no>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Series in Statistics. Springer Science & Business Media, 2 ed.

- Huang, R. J., Kwon, N. S.-E., Tomizawa, Y., Choi, A. Y., Hernandez-Boussard, T., & Hwang, J. H. (2022). A comparison of logistic regression against machine learning algorithms for gastric cancer risk prediction within real-world clinical data streams. *JCO Clinical Cancer Informatics*, 6, e2200039.
- Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in science & engineering*, 9(3), 90–95.
- Hwang, S., Urbanowicz, R., Lynch, S., Vernon, T., Bresz, K., Giraldo, C., et al. (2023). Toward predicting 30-day readmission among oncology patients: Identifying timely and actionable risk factors. *JCO Clinical Cancer Informatics*, 7.
- Jacobson, D., Cadieux, B., Higano, C. S., Henry, D. H., Bachmann, B. A., Rehn, M., Stopeck, A. T., & Saad, H. (2022). Risk factors associated with skeletal-related events following discontinuation of denosumab treatment among patients with bone metastases from solid tumors: A real-world machine learning approach. *Journal of Bone Oncology*, 34.
- Lai, S.-W., Fan, Y.-L., Zhu, Y.-H., Zhang, F., Guo, Z., Wang, B., et al. (2022). Machine learning-based dynamic prediction of lateral lymph node metastasis in patients with papillary thyroid cancer. *Frontiers in Endocrinology*, 13.
- Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of machine learning research*, 18(17), 1–5.
- Li, J., Tian, Y., Zhu, Y., Zhou, T., Li, J., Ding, K., & Li, J. (2020). A multicenter random forest model for effective prognosis prediction in collaborative clinical research network. *Artificial Intelligence in Medicine*, 103.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.) *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, (pp. 4765–4774). Curran Associates, Inc.
URL https://papers.nips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html
- Luo, X., Kan, X., Wang, D., Shi, Y., Zhu, S., Chen, Z., Wang, C., Zhu, W., Wang, X., & Sun, W. (2025). Development and validation of an explainable machine learning model for predicting prognosis in sepsis patients with a history of cancer who were admitted to the intensive care unit. *Journal of International Medical Research*, 53(8).
- McKinney, W., et al. (2010). Data structures for statistical computing in python. In *Proceedings of the 9th Python in Science Conference*, vol. 445, (pp. 51–56).
- Metamodelo (2024a). Análisis de producción en salud 2024.
URL <https://www.metamodelo.cl/2024/12/16/analisis-produccion-salud-2024/>
- Metamodelo (2024b). Mecanismo de pago por grd explicado en fácil.
URL <https://www.metamodelo.cl/2024/01/30/mecanismo-de-pago-por-grd-explicado-en-facil/>
- Ministerio de Salud de Chile (2022). Plan nacional del cáncer 2022-2027. Tech. rep., Subsecretaría de Salud Pública, Gobierno de Chile.
URL <https://www.iccp-portal.org/sites/default/files/plans/Plan-Nacional-de-Cancer-2022-2027.pdf>
- Ministerio de Salud de El Salvador (2024). Clasificación internacional de procedimientos en medicina (cie-9-mc) - versión 2024. Tech. rep.
URL <https://www.salud.gob.sv/wp-content/uploads/2024/11/clasificacion-internacional-de-procedimientos-CIE-9MC-version-2024-lista-tabular-el-salvador.pdf>

- Molnar, C. (2020). *Interpretable Machine Learning*. Lulu.com. <https://christophm.github.io/interpretable-ml-book/>.
- OECD (2024). Abordando el impacto del cáncer en la salud, la economía y la sociedad: Chile. OECD: Organisation for Economic Co-operation and Development.
URL https://www.oecd.org/es/publications/2024/11/tackling-the-impact-of-cancer-on-health-the-db760f3f/chile_5e85efac.html
- Organización Mundial de la Salud (OMS) (2022). Cáncer: Datos y cifras. Accedido en línea.
URL <https://www.who.int/es/news-room/fact-sheets/detail/cancer>
- Organización Panamericana de la Salud (OPS) y Organización Mundial de la Salud (OMS) (2018). *Clasificación Estadística Internacional de Enfermedades y Problemas Relacionados con la Salud, Décima Revisión (CIE-10). Volumen 1*. Washington, D.C.: OPS.
URL <https://ais.paho.org/classifications/chapters/pdf/volume1.pdf>
- Orrego, C., Vega, F., Cuevas, J. P., Arias, A., & Bustos-Medina, L. (2025). Perfil clínico, demográfico y anatomopatológico de pacientes con cáncer pulmonar en el hospital de temuco (2019-2023). *Revista Médica de Chile*, 153(2), 104–110.
- Ortega-Ceavichay, A., Villarroel-Pulgar, J., & Martínez-Rondanelli, B. (2023). Mortalidad por cáncer oral y orofaríngeo en Chile entre los años 1955 al 2021. *Revista Médica de Chile*, 151(10), 1303–1308.
- Pardo, P. L. (2025). Una fotografía sobre el cáncer en Chile: artículo presenta la realidad de esta enfermedad en la última década y los desafíos para su investigación. Facultad de Ciencias Biológicas, UC.
URL <https://biologia.uc.cl/una-fotografia-sobre-el-cancer-en-chile-articulo-presenta-la-realidad>
- Parra-Soto, S., Petermann-Rocha, F., Martínez-Sanguinetti, M. A., Leiva-Ordeñez, A. M., Troncoso-Pantoja, C., Ulloa, N., Díaz-Martínez, X., & Celis-Morales, C. (2020). Cáncer en Chile y en el mundo: una mirada actual y su futuro escenario epidemiológico. *Revista Médica de Chile*, 148(10), 1489–1495.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in python. *Journal of machine learning research*, 12(Oct), 2825–2830.
- Peterson, D. J., Ostberg, N. P., Blayney, D. W., Brooks, J. D., & Hernandez-Boussard, T. (2021). Machine learning applied to electronic health records: Identification of chemotherapy patients at high risk for preventable emergency department visits and hospital admissions. *JCO Clinical Cancer Informatics*, 5, 1106–1126.
- Probst, P., Wright, M. N., & Boulesteix, A.-L. (2019). Hyperparameters and tuning strategies for random forest. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 9(3).
- Raschka, S., Patterson, J., & Nolet, C. (2020). Machine learning in python: Main developments and technology trends in data science, machine learning, and artificial intelligence. *Information*, 11(4), 193.
- Rubio, N., Monsalve, V., Molina, P., & Lineros, V. (2021). Comportamiento del cáncer de tiroides en la unidad de cirugía adulto del hospital clínico hermina Martín de Chillán. período 2017 al 2019. *Revista de Cirugía*, 73(6), 663–667.
- Schröer, C., Kruse, F., & Gómez, J. M. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, 181, 526–534.
- Sigesa (2019a). Chile es la referencia de América Latina en el uso de GRD.
URL <https://www.sigesa.com/chile-es/>

Sigesa (2019b). Grupos relacionados por el diagnóstico (grd).

URL <https://www.sigesa.com/grd/>

Sociedad Castellano-Manchega de Patología Respiratoria (SOCAMPAR) (2023). Artículo original. *Revista SOCAMPAR*. Reemplaza el campo 'title' y 'author' con los datos exactos del artículo si los necesitas detallar en tu bibliografía.

URL <https://revista-socampar.com/images/articulos/ArticulosSeparadosNum18/Original%203.pdf>

Wodchis, W. P., Arthurs, E., Khan, A. I., Gandhi, S., MacKinnon, M., & Sussman, J. (2016). Cost trajectories for cancer patients. *Current Oncology*, 23(Suppl 1), S64–S75.

Yamashita, T., Wakata, Y., Nakaguma, H., Nohara, Y., Hato, S., Kawamura, S., et al. (2022). Machine learning for classification of postoperative patient status using standardized medical data. *Computer Methods and Programs in Biomedicine*, 214.

Yuan, Q., Cai, T., Hong, C., Du, M., Johnson, B. E., Lanuti, M., Cai, T., & Christiani, D. C. (2021). Performance of a machine learning algorithm using electronic health record data to identify and estimate survival in a longitudinal cohort of patients with lung cancer. *JAMA Network Open*, 4(7).

Zhou, L., Mao, C., Fu, T., Ding, X., Bertolaccini, L., Liu, A., Zhang, J., & Li, S. (2024). Development of an ai model for predicting hypoxia status and prognosis in non-small cell lung cancer using multi-modal data. *Translational Lung Cancer Research*, 13(12), 3642–3656.

ANEXO A. TÍTULO DEL ANEXO EJEMPLO

El 15 de junio del 2012 la Agencia Acreditadora Colegio de Ingenieros de Chile S.A., otorga la acreditación de la carrera de Ingeniería Civil Informática de la Universidad de Santiago de Chile sede Santiago, en sus jornadas diurna y vespertinas por un plazo de 5 años.

APÉNDICE A. TÍTULO DEL APÉNDICE EJEMPLO

El 15 de junio del 2012 la Agencia Acreditadora Colegio de Ingenieros de Chile S.A., otorga la acreditación de la carrera de Ingeniería Civil Informática de la Universidad de Santiago de Chile sede Santiago, en sus jornadas diurna y vespertinas por un plazo de 5 años.